LAPORAN PROYEK
UJIAN TENGAH SEMESTER

KLASIFIKASI KELAS HARGA LAPTOP BERDASARKAN SPESIFIKASI TEKNIS MENGGUNAKAN ARSITEKTUR MULTI-LAYER PERCEPTRON (MLP) DENGAN HYPERPARAMETER TUNING

Dosen Pengampu: Syanti Irviantina, S.Kom., M.Kom.

Mata Kuliah: Deep Learning

Kelompok: 4

Disusun oleh:

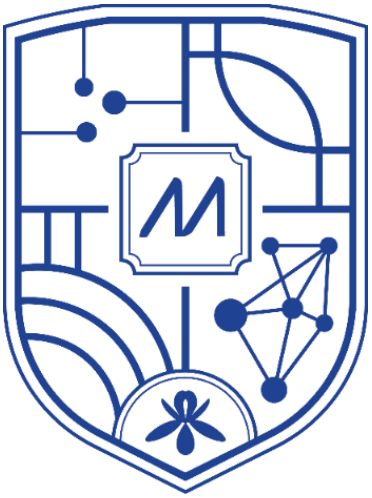
231112463 - Purba Tua Siregar

231111899 - Havidz Andrian

231112313 - Mikkael Raynala Tampubolon

231112081 - Ipaldi Jagarojes Sembiring

231112747 - Muhammad Dhani Irvansyah



PROGRAM STUDI S-1 TEKNIK INFORMATIKA

FAKULTAS INFORMATIKA

UNIVERSITAS MIKROSKIL

MEDAN

2026/2027

DAFTAR ISI

LAPORAN PROYEK 1

1. Kompleksitas Masalah 1

1.1 Latar Belakang dan Permasalahan 1

1.2 Alasan Masalah Dianggap Kompleks 1

1.3 Tantangan, Rumusan Masalah, dan Tujuan 2

1.4 Perkembangan dari Tugas Proyek 2 2

DATASET YANG DIGUNAKAN 3

2.1 Sumber, Sifat, dan Format Dataset 3

2.2 Pembentukan Kategori Harga dan Perkiraan IDR 3

2.3 Kompleksitas dan Kualitas Dataset 4

EXPLORATORY DATA ANALYSIS (EDA) 5

3.1 Distribusi Kelas dan Kondisi Harga 5

3.2 Histogram Fitur Numerik 5

3.3 Korelasi Antarfitur 6

3.4 Contoh Sampel Setiap Kelas 7

3.5 Temuan EDA dan Dampaknya pada Preprocessing 7

PREPROCESSING DATA 8

4.1 Pembersihan dan Rekayasa Fitur 8

4.2 Penanganan Missing Value dan Outlier 8

4.3 Standardisasi, Encoding, dan Dimensi Fitur 8

4.4 Pembagian Data dan Pencegahan Data Leakage 9

4.5 Augmentasi, Keseimbangan Data, dan Pipeline Tensor 10

MODEL YANG DIGUNAKAN 11

5.1 Jenis dan Alasan Pemilihan Model 11

5.2 Arsitektur Baseline, Regularized, dan Tuned MLP 11

5.3 Konfigurasi Pelatihan dan Hyperparameter Tuning 12

5.4 Alasan Model Hasil Tuning Menjadi Fokus 13
5.5 Dua Fitur Unik dan Bukti Dampaknya 13
HASIL EVALUASI DAN ANALISIS 15
6.1 Metrik Evaluasi dan Dasar Pemakaiannya 15
6.2 Hasil Tiga Model pada Data Testing 15
6.3 Grafik Accuracy dan Loss pada Model Utama 16
6.4 Confusion Matrix dan Analisis Per Kelas 17
6.5 Perbandingan Ablasi dan Stabilitas Multi-Seed 18
6.6 Pengujian Sensitivitas dan Keterbatasan Generalisasi 20
TEKNOLOGI YANG DIGUNAKAN 21
7.1 Bahasa Pemrograman, Library, dan Lingkungan Eksperimen 21
7.2 Teknologi Aplikasi dan Hosting 21
DEPLOYMENT DAN DEMONSTRASI 22
8.1 Status Publikasi dan Keselarasan Model 22
8.2 Tahapan Deployment Hugging Face Spaces SDK Static 23
8.3 *User Interface Website*, Dual Mode, dan Dual Price 24
8.4 Demonstrasi Prediksi Kustom, Batch, dan Video 26
LAMPIRAN TEKNIS DAN BUKTI KODE 28
9.1 Screenshot Preprocessing dan Pencegahan Kebocoran Data 28
9.2 Screenshot Arsitektur Model dan Hyperparameter Tuning 28
9.3 Screenshot Dua Fitur Unik 30
9.4 Screenshot Pembuatan Paket SDK Static 31
9.5 Daftar Grafik dan Tabel Pendukung 32
DAFTAR PUSTAKA 33
TAUTAN LENGKAP PROYEK UTS 34

DAFTAR GAMBAR

Gambar 1. Distribusi kelas, harga laptop, dan jenis GPU pada data analisis 5
Gambar 2. Histogram 10 fitur numerik dan variasi nilai spesifikasi laptop 6
Gambar 3. Matriks korelasi fitur numerik terhadap harga asli dan kelas target 7
Gambar 4. Diagram arsitektur MLP hasil tuning: 83 fitur masukan menjadi tiga probabilitas kelas 11
Gambar 5. Peringkat 10 percobaan KerasTuner dan hubungan learning rate dengan skor validasi 13
Gambar 6. Perubahan coverage dan F1 pada confidence threshold serta peringkat permutation importance 14
Gambar 7. Perbandingan akurasi validasi bobot akhir dan akurasi testing ketiga MLP . 16
Gambar 8. Kurva accuracy training dan validation MLP hasil tuning 16
Gambar 9. Kurva loss training dan validation MLP hasil tuning 17
Gambar 10. Confusion matrix Model 3 pada 153 data uji 18
Gambar 11. Perbandingan F1 makro validasi pada studi ablasi A-F 19
Gambar 12. Prediksi preset Budget pada tampilan gelap: kelas Entry-Level (98,59%) . 25
Gambar 13. Input kustom High-End pada tampilan terang: confidence 100,00% (Softmax)25
Gambar 14. Preset katalog 48 laptop dari data training pada tampilan gelap 26
Gambar 15. Pengujian batch JSON 72 laptop pada tampilan terang 27
Gambar 16. Screenshot kode pemisahan data dan preprocessing yang dipelajari dari training 29
Gambar 17. Screenshot fungsi arsitektur baseline dan regularisasi MLP 29
Gambar 18. Screenshot kode penentuan ruang pencarian dan KerasTuner RandomSearch 30
Gambar 19. Screenshot kode pengujian confidence threshold pada model hasil tuning 31
Gambar 20. Screenshot kode permutation importance pada data validasi 31
Gambar 21. Screenshot kode pemeriksaan dan daftar berkas SDK Static 32

DAFTAR TABEL

Tabel 1. Komponen akhir dan kebutuhan pembuktian perubahan dari Tugas Proyek 2 ... 2
Tabel 2. Identitas dan struktur dataset yang digunakan ... 3
Tabel 3. Definisi kelas harga laptop dengan dua mata uang ... 3
Tabel 4. Hasil audit kualitas dan duplikasi dataset ... 4
Tabel 5. Distribusi kelas harga dalam dataset analisis ... 5
Tabel 6. Contoh laptop berlabel dari data uji ... 7
Tabel 7. Sebaran nilai kosong sebelum imputasi pada setiap subset ... 8
Tabel 8. Kelompok fitur utama untuk pemodelan ... 9
Tabel 9. Pembagian data pada percobaan utama ... 9
Tabel 10. Ringkasan arsitektur ketiga model ... 11
Tabel 11. Konfigurasi utama MLP hasil KerasTuner ... 12
Tabel 12. Dampak dua fitur unik pada eksperimen ... 14
Tabel 13. Perbandingan metrik pengujian tiga model ... 15
Tabel 14. Analisis keberhasilan dan kesalahan menurut kelas ... 18
Tabel 15. Ablasi model pada validasi ... 19
Tabel 16. Stabilitas lima seed pada data validasi ... 19
Tabel 17. Teknologi dan versi berdasarkan keluaran notebook ... 21
Tabel 18. Status bukti deployment dan hasil pengujian yang tersedia ... 22
Tabel 19. Berkas aplikasi dan perannya pada SDK Static ... 23
Tabel 20. Contoh prediksi benar dan salah dari data testing notebook ... 27
Tabel 21. Rekapitulasi pengujian batch pada aplikasi Hugging Face ... 27
Tabel 22. Tautan publik proyek UTS Kelompok 4 ... 35

KONTRIBUSI MASING-MASING ANGGOTA KELOMPOK

Pengembangan proyek dilakukan bersama oleh lima anggota Kelompok 4, mulai dari persiapan dataset dan notebook hingga evaluasi model, aplikasi, laporan, serta presentasi. Ringkasan berikut mengikuti pembagian kerja yang disampaikan kelompok; seluruh anggota perlu memastikan rincian kontribusinya sesuai pekerjaan yang benar-benar dilakukan sebelum pengumpulan.

1. 231111899 - Havidz Andrian: Bertanggung jawab dalam pencarian dan pemilihan dataset laptop dari Kaggle, penyusunan kode dasar eksperimen, serta pengembangan source code notebook untuk membangun sistem klasifikasi menggunakan arsitektur MLP dengan hyperparameter tuning. Berkontribusi dalam pencarian dan pemilihan platform deployment Hugging Face Spaces SDK Static melalui diskusi kelompok, serta mendukung integrasi dan pengujian aplikasi bersama anggota lainnya. Dalam presentasi, bertugas sebagai moderator dan menjelaskan latar belakang, dataset, serta tahapan awal eksperimen pada Google Colab.
2. 231112747 - Muhammad Dhani Irvansyah: Berkontribusi dalam pengembangan eksperimen, khususnya peninjauan tahapan preprocessing, pembagian dataset, penanganan nilai kosong, transformasi fitur numerik dan kategorikal, serta penyusunan input pipeline. Turut mendukung penyesuaian kode, pengujian proses pengolahan data, dan penyusunan dokumentasi proyek. Dalam presentasi, bertugas menjelaskan proses preprocessing, persiapan data, serta arsitektur MLP pada Google Colab.
3. 231112081 - Ipaldi Jagarojes Sembiring: Berkontribusi dalam pengembangan dan evaluasi model, termasuk pembahasan hyperparameter tuning, pemeriksaan metrik evaluasi, analisis confusion matrix, dan interpretasi hasil pengujian. Turut mendukung penerapan serta analisis dua fitur unik, yaitu confidence threshold dan permutation importance, sekaligus membantu memastikan kesesuaian hasil eksperimen dengan laporan. Dalam presentasi, bertugas menjelaskan proses optimasi, hasil evaluasi, analisis kesalahan prediksi, dan penerapan kedua fitur unik.
4. 231112463 - Purba Tua Siregar: Berkontribusi dalam pengembangan dan pengujian proyek, khususnya pemeriksaan hasil klasifikasi, kesesuaian fitur masukan, serta kemudahan penggunaan antarmuka aplikasi. Turut mendukung pengujian formulir spesifikasi laptop, penggunaan preset, dan pemeriksaan keluaran berupa kelas harga, confidence score, serta distribusi probabilitas. Dalam presentasi, bertugas

mendemonstrasikan fitur Input Spesifikasi Kustom dan menjelaskan hasil prediksi menggunakan Preset Budget.

5. 231112313 - Mikkael Raynala Tampubolon: Berkontribusi dalam pengembangan proyek, pembahasan pemodelan, serta pengujian fitur prediksi massal pada aplikasi. Turut mendukung penyusunan variasi data pengujian, pemeriksaan proses pembacaan berkas CSV, XLSX, dan JSON, serta analisis penyajian hasil klasifikasi dan confidence score. Dalam presentasi, bertugas mendemonstrasikan fitur Batch Upload, menjelaskan distribusi hasil prediksi dari ketiga format berkas, serta menyampaikan penutup proyek.

BUKTI PENGERJAAN BERSAMA





LAPORAN PROYEK

1. Kompleksitas Masalah

1.1 Latar Belakang dan Permasalahan

Harga laptop dipengaruhi oleh banyak komponen teknis yang saling berkaitan. Kapasitas RAM yang besar belum tentu menunjukkan laptop dengan kelas harga tinggi apabila jenis prosesor, kartu grafis, penyimpanan, dan karakteristik perangkat lainnya berbeda. Karena itu, hubungan spesifikasi dan kelas harga tidak cukup dijelaskan oleh satu aturan sederhana. Kami mengangkat masalah klasifikasi kelas harga laptop agar sistem dapat mempelajari kombinasi spesifikasi tersebut secara bersamaan.

Proyek menggunakan dataset katalog laptop dari Kaggle dengan label harga dalam rupee India (INR). Kami mengelompokkan harga menjadi tiga kelas, yaitu Entry-Level, Mid-Range, dan High-End. Kelas tersebut merupakan kategori buatan berdasarkan batas numerik yang ditentukan dalam notebook, bukan pengelompokan resmi produsen maupun ukuran langsung terhadap kualitas laptop.

Fokus metode sesuai judul adalah pembangunan *Multi-Layer Perceptron* (MLP) sebagai jaringan saraf berlapis penuh, kemudian pencarian konfigurasi menggunakan KerasTuner RandomSearch. Dua MLP lain digunakan sebagai pembanding untuk menilai apakah model hasil tuning mengalami peningkatan terhadap arsitektur awal dan rancangan regularisasi manual.

1.2 Alasan Masalah Dianggap Kompleks

Data spesifikasi memuat campuran nilai numerik, kategorikal, dan teks semi-terstruktur dari katalog. Variasi penamaan prosesor, jenis RAM, kartu grafis, ukuran layar, serta masa garansi perlu dinormalisasi terlebih dahulu sebelum dapat dipelajari model. Beberapa spesifikasi mempunyai rentang angka yang jauh berbeda, sehingga jaringan yang menerima data mentah langsung berpotensi lebih sensitif terhadap fitur berskala besar.

Kesulitan tambahan muncul dari dua karakteristik data: nilai kosong pada jumlah inti dan jumlah thread prosesor, serta spesifikasi laptop yang berulang dengan nama produk yang sama atau mirip. Audit notebook menemukan 78 baris duplikat persis, 137 pengulangan nama model, dan 172 pengulangan kombinasi spesifikasi teknis. Karena itu, hasil pengujian melalui pemisahan acak harus dibaca dengan mempertimbangkan kemiripan produk antarbagian data.

1.3 Tantangan, Rumusan Masalah, dan Tujuan

Tantangan penelitian ini meliputi pengolahan fitur campuran tanpa menggunakan harga sebagai input, pemilihan konfigurasi jaringan yang tidak terlalu sederhana maupun terlalu rumit, pengendalian overfitting, serta evaluasi yang membedakan peran data latih, validasi, dan pengujian. Pertanyaan penelitian yang ditangani adalah bagaimana membangun pipeline data laptop, bagaimana kinerja MLP hasil tuning dibandingkan pembandingnya, dan bagaimana menilai batas kepercayaan serta pengaruh fitur pada prediksi.

Tujuan yang ditetapkan adalah menghasilkan pipeline preprocessing yang dapat dipakai ulang, melatih tiga arsitektur MLP dengan Model 3 sebagai fokus tuning, mengevaluasi klasifikasi menggunakan metrik per kelas dan F1 makro, menguji dua fitur unik, serta mempersiapkan satu paket inferensi untuk aplikasi Hugging Face Spaces SDK Static.

1.4 Perkembangan dari Tugas Proyek 2

Notebook akhir memperlihatkan adanya audit duplikasi, imputasi berdasarkan kelompok seri prosesor, pemisahan train/validation/test, pembandingan tiga MLP, RandomSearch, dua fitur tambahan, pengujian ablasi, dan ekspor untuk aplikasi statis. Namun, artefak Tugas Proyek 2 yang menjadi pembanding tidak dilampirkan karena kemarin untuk topik pada tugas 2 berbeda dengan topik pada uts yang kami pilih. Oleh sebab itu, kami tidak menyatakan bahwa seluruh komponen tersebut merupakan penambahan baru dari Tugas Proyek 2 tanpa bukti versi sebelumnya.

Tabel 1. Komponen akhir dan kebutuhan pembuktian perubahan dari Tugas Proyek 2

Komponen pada notebook akhir	Bukti saat ini	Status perbandingan TP2
Audit EDA dan duplikasi	Tersedia pada Section 2	Perbedaan dengan TP2 belum diverifikasi
Imputasi dan preprocessing dari training	Tersedia pada Section 3	Perbedaan dengan TP2 belum diverifikasi
MLP baseline, regularisasi, dan tuning	Tersedia pada Section 5-7	Perbedaan dengan TP2 belum diverifikasi
Dua fitur unik, ablasi, multi-seed	Tersedia pada Section 11-12	Perbedaan dengan TP2 belum diverifikasi
Ekspor SDK Static	Kode tersedia pada Section 13	Implementasi akhir belum diuji

Sumber: Analisis isi UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(3).ipynb, Section 2-13; artefak TP2 tidak disertakan.

DATASET YANG DIGUNAKAN

2.1 Sumber, Sifat, dan Format Dataset

Dataset diperoleh dari halaman Kaggle *Laptop Specifications and Prices Dataset* yang diterbitkan pada repositori anshsahu111. Notebook memuat mekanisme unduhan melalui kagglehub dan membaca dua berkas CSV, yaitu laptops_uncleaned.csv dan laptops_cleaned_v1.csv. Data menggambarkan katalog laptop dengan spesifikasi dan harga, sehingga diperlakukan sebagai data observasional berbasis katalog, bukan data sintetis. Riwayat pengambilan sampel dan kelengkapan pasar tidak dapat dibuktikan hanya dari berkas yang tersedia.

Berkas mentah terdiri atas 1.020 baris dan 12 kolom. Berkas hasil ekstraksi awal terdiri atas 1.018 baris dan 22 kolom. Audit menunjukkan dua baris yang tidak masuk ke berkas bersih berasal dari entri Lenovo ThinkBook Plus Gen 6 Rollable dengan pemetaan kolom yang tidak teratur. Notebook tidak merekonstruksi dua baris tersebut secara spekulatif; seluruh eksperimen mengikuti 1.018 baris dalam berkas cleaned_v1.

Tabel 2. Identitas dan struktur dataset yang digunakan

Aspek	Keterangan
Sumber	Kaggle, anshsahu111/laptop-specifications-and-prices-dataset
Format	CSV (mentah dan ekstraksi awal)
Ukuran mentah	1.020 baris × 12 kolom
Ukuran analisis	1.018 baris × 22 kolom
Masukan model	19 atribut asli → 83 fitur tertransformasi
Keluaran	3 kelas harga; softmax
Sifat data	Katalog laptop; data observasional
Mata uang target	INR; IDR sekadar ekuivalen ilustratif

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(3).ipynb, Section 1-3.

2.2 Pembentukan Kategori Harga dan Perkiraan IDR

Harga asli dalam dataset menggunakan rupee India (INR). Kami menerapkan batas kelas yang tetap agar label konsisten: di bawah ₹50.000 sebagai Entry-Level, ₹50.000 sampai dengan ₹85.000 sebagai Mid-Range, dan di atas ₹85.000 sebagai High-End. Sebagai bantuan membaca nominal, laporan menambahkan perkiraan rupiah dengan kurs acuan ilustratif 1 INR ≈ Rp192,549 pada 9 November 2026. Kurs tersebut bukan kurs transaksi, tidak memengaruhi kelas, dan tidak membuktikan kesamaan harga jual di Indonesia.

Tabel 3. Definisi kelas harga laptop dengan dua mata uang

Kelas	Rentang INR asli	Ekuivalen IDR ilustratif
Entry-Level	< ₹50.000	< Rp9.627.450
Mid-Range	₹50.000-₹85.000	Rp9.627.450-Rp16.366.665
High-End	> ₹85.000	> Rp16.366.665

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(3).ipynb, Section 2; kurs ilustratif dibekukan pada 9 November 2026.

2.3 Kompleksitas dan Kualitas Dataset

Kompleksitas dataset tidak berasal dari jumlah observasi yang sangat besar, melainkan dari variasi bentuk data dan hubungan antarspecifikasi. Fitur numerik antara lain rating, jumlah core, jumlah thread, kapasitas RAM, kapasitas penyimpanan, ukuran layar, resolusi, PPI, dan masa garansi. Fitur kategorikal mencakup merek, seri prosesor, tipe RAM, jenis penyimpanan, merek dan tipe GPU, sistem operasi, serta informasi layar sentuh. Kolom harga tidak diberikan kepada model sebagai fitur prediktor.

Tabel 4. Hasil audit kualitas dan duplikasi dataset

Jenis pemeriksaan	Temuan tersimpan
Nilai core_num kosong	22 nilai
Nilai threads_num kosong	77 nilai
Duplikasi baris persis (tanpa ID)	78 baris
Nama model yang berulang	137 pengulangan
Spesifikasi + harga identik	82 pengulangan
Spesifikasi teknis identik	172 pengulangan
Model sama di train dan test	24 nama model

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(3).ipynb, Section 2-3.

Baris dengan spesifikasi ekstrem, seperti RAM sebesar 64 GB atau lebih, diperiksa dan tidak dihapus otomatis. Nilai yang jarang tidak selalu merupakan kesalahan; keputusan membuang data tanpa pemeriksaan dapat menghilangkan karakteristik laptop kelas premium. Karena terdapat contoh produk berulang, satu metrik dari pemisahan acak tidak cukup untuk membuktikan kinerja pada seluruh produk laptop yang belum pernah dilihat model.

EXPLORATORY DATA ANALYSIS (EDA)

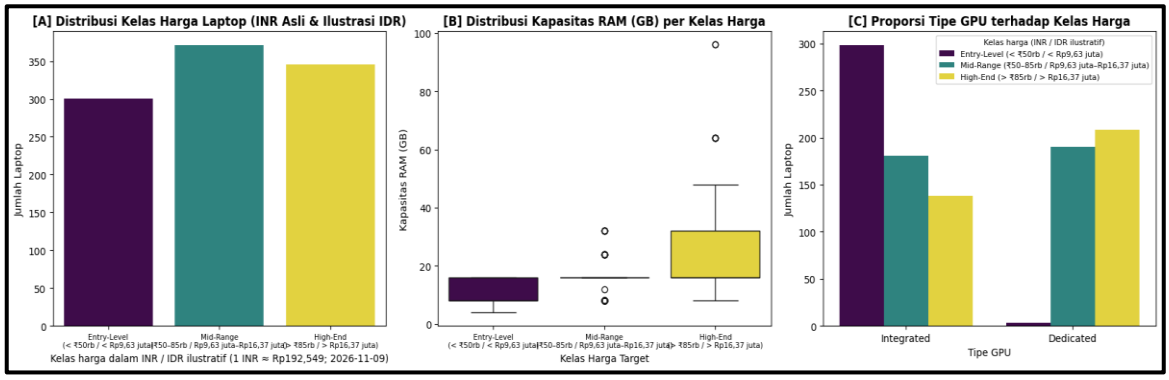
3.1 Distribusi Kelas dan Kondisi Harga

Distribusi label relatif seimbang: kelas Entry-Level berjumlah 301 sampel (29,57%), Mid-Range 371 sampel (36,44%), dan High-End 346 sampel (33,99%). Selisih antarkelas tetap diperhatikan saat menafsirkan akurasi, sehingga laporan tidak hanya bergantung pada jumlah prediksi benar secara keseluruhan.

Tabel 5. Distribusi kelas harga dalam dataset analisis

Kategori	Jumlah	Persentase
Entry-Level	301	29,57%
Mid-Range	371	36,44%
High-End	346	33,99%
Total	1.018	100,00%

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(3).ipynb, Section 2.

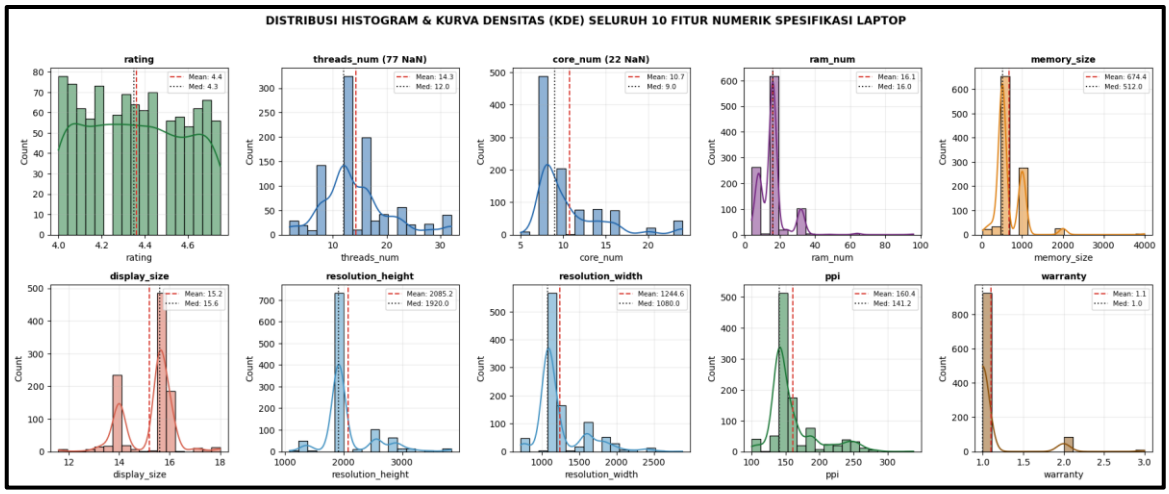


Gambar 1. Distribusi kelas, harga laptop, dan jenis GPU pada data analisis

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(3).ipynb, output grafik Section 2.

3.2 Histogram Fitur Numerik

Histogram menunjukkan distribusi fitur numerik yang tidak seragam. Nilai kapasitas dan komponen layar mempunyai rentang yang jauh lebih lebar dibandingkan fitur seperti rating. Kondisi ini mendukung penerapan standardisasi berdasarkan statistik training, bukan membiarkan perbedaan satuan membentuk bobot awal yang tidak seimbang.

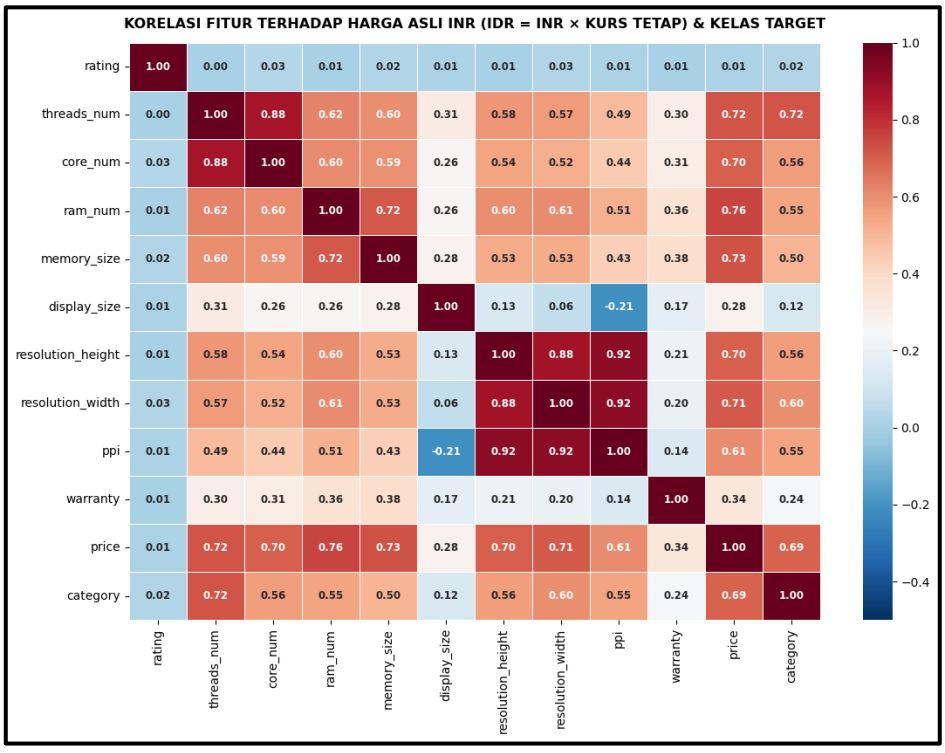


Gambar 2. Histogram 10 fitur numerik dan variasi nilai spesifikasi laptop

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(3).ipynb, output grafik Section 2.

3.3 Korelasi Antarfitur

Matriks korelasi menggambarkan hubungan linear antarfitur numerik dan representasi kelas harga, tanpa berarti hubungan tersebut bersifat sebab-akibat. Fitur resolusi dan PPI saling terkait secara matematis karena PPI berasal dari ukuran serta resolusi layar. Kami tetap mempertahankan fitur itu dalam ruang pencarian awal dan memeriksa pengaruhnya melalui permutation importance agar interpretasi tidak semata-mata berdasarkan korelasi linear.



Gambar 3. Matriks korelasi fitur numerik terhadap harga asli dan kelas target

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(3).ipynb, output grafik Section 2.

3.4 Contoh Sampel Setiap Kelas

Contoh observasi berikut diambil dari tabel evaluasi Section 8, yang menautkan harga sebenarnya dengan kelas yang digunakan sebagai label. Nama model hanya dipakai sebagai identitas observasi dan tidak menjadi input untuk MLP.

Tabel 6. Contoh laptop berlabel dari data uji

Kelas aktual	Contoh sampel	Harga asli / ekuivalen
Entry-Level	Lenovo IdeaPad 3 82XQ008TIN	₹42.990 (≈ Rp8.277.682)
Mid-Range	HP Victus 15-fa1274TX	₹84.990 (≈ Rp16.364.740)
High-End	HP Omen 16-xf0081AX	₹135.999 (≈ Rp26.186.471)

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(3).ipynb, Section 8, tabel contoh prediksi benar dan salah.

3.5 Temuan EDA dan Dampaknya pada Preprocessing

Hasil EDA menjadi alasan untuk melakukan empat tindakan utama: memastikan penyetaraan data kategorikal sebelum encoding, mengisi nilai kosong dengan median yang dipelajari dari training, melakukan standardisasi numerik, dan memperlakukan duplikasi sebagai keterbatasan generalisasi. Proporsi tiga kelas yang tidak terlalu jauh berbeda tidak mendorong penggunaan oversampling otomatis, karena perubahan distribusi data tanpa kebutuhan jelas dapat menghasilkan evaluasi yang lebih sulit ditafsirkan.

Analisis jumlah kata atau word count tidak diterapkan karena objek penelitian bukan data teks; teks spesifikasi hanya diolah untuk mengekstraksi fitur yang dapat dipelajari. Sampel per kelas disajikan melalui identitas laptop, harga, dan label, bukan ilustrasi citra.

PREPROCESSING DATA

4.1 Pembersihan dan Rekayasa Fitur

Pengolahan dimulai dengan pemeriksaan struktur CSV, penyeragaman data kategori, dan pengubahan spesifikasi yang semula berupa teks menjadi angka atau kategori. Informasi RAM diuraikan menjadi kapasitas serta jenis memori, sedangkan kerapatan piksel layar atau PPI dihitung dari resolusi dan ukuran layar. Proses rekayasa fitur bersifat deterministik dan tidak menggunakan label harga untuk menghitung statistik imputasi.

Dua catatan katalog yang tidak masuk ke versi cleaned_v1 tidak dimasukkan kembali secara manual karena pemetaan atribut pada baris sumbernya tidak konsisten. Audit tetap mencatatnya agar perubahan jumlah baris dari 1.020 menjadi 1.018 dapat ditelusuri.

4.2 Penanganan Missing Value dan Outlier

Ditemukan 77 nilai kosong pada threads_num dan 22 pada core_num. Kami membagi data lebih dahulu, lalu menerapkan GroupMedianImputer yang mempelajari median menurut seri prosesor (iter) hanya dari data training. Apabila jumlah data tidak mencukupi pada suatu kelompok atau kelompoknya belum dikenal, digunakan median keseluruhan yang juga dihitung dari training. Metode tersebut mengurangi risiko informasi validasi dan testing masuk ke tahap pembelajaran preprocessing.

Tabel 7. Sebaran nilai kosong sebelum imputasi pada setiap subset

Subset	threads_num	core_num	Total
Training (712)	54	18	72
Validation (153)	12	3	15
Testing (153)	11	1	12
Keseluruhan	77	22	99

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(3).ipynb, Section 3.

Penanganan outlier dilakukan secara konservatif. Notebook mengaudit nilai spesifikasi ekstrem, tetapi tidak memangkas semua observasi berdasarkan aturan IQR karena perangkat premium memang dapat mempunyai RAM atau penyimpanan yang jauh lebih besar. Angka harga juga tidak dipakai dalam standardisasi atau imputasi fitur prediktor.

4.3 Standardisasi, Encoding, dan Dimensi Fitur

Setelah imputasi, fitur numerik diproses oleh StandardScaler untuk menempatkan nilainya pada skala yang dapat dibandingkan. Fitur kategorikal diproses dengan OneHotEncoder(handle_unknown="ignore") sehingga kategori baru tidak menyebabkan

kegagalan transformasi. Pipeline dipelajari dari data training; data validasi dan testing hanya menjalankan transform dengan parameter yang sudah dibekukan.

Tabel 8. Kelompok fitur utama untuk pemodelan

Jenis	Contoh atribut	Prosedur
Numerik (10)	rating, core_num, threads_num, ram_num, memory_size, display_size, resolution_height, resolution_width, warranty, ppi	Median kelompok (jika diperlukan) dan StandardScaler
Kategorikal (9)	brand_name, processor_brand, iter, ram_type, memory_type, gpu_brand, gpu_type, os, Touch_Screen	OneHotEncoder dengan kategori dari training
Target (1)	price_class (0, 1, 2)	Softmax 3 kelas; tidak menjadi fitur masukan
Kolom audit	price, price_idr, model	Tidak digunakan sebagai input jaringan

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(3).ipynb, Section 2-4.

Hasil gabungan preprocessing mempunyai 83 kolom numerik bertipe float32. Jumlah tersebut berasal dari 10 fitur numerik dan representasi one-hot dari sembilan fitur kategorikal. Dimensi transformasi perlu diperiksa setiap kali preprocessor dan model dimuat kembali agar data baru masuk ke layer input dengan urutan kolom yang sama.

4.4 Pembagian Data dan Pencegahan Data Leakage

Pemisahan dilakukan secara stratified dengan proporsi 70% training, 15% validation, dan 15% testing. Training digunakan untuk mempelajari parameter MLP serta seluruh statistik preprocessing; validasi digunakan untuk tuning, callback, dan pemilihan confidence threshold; testing digunakan untuk mengevaluasi konfigurasi yang sudah ditetapkan. Proporsi ini menjaga representasi kelas dalam tiap subset.

Tabel 9. Pembagian data pada percobaan utama

Subset	Jumlah	Entry-Level	Mid-Range	High-End
Training	712	211	259	242
Validation	153	45	56	52
Testing	153	45	56	52

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(3).ipynb, Section 3.

Audit nama produk menunjukkan 24 nama model muncul di training dan testing. Ini tidak membuktikan label target langsung bocor melalui input, tetapi meningkatkan risiko

estimasi terlalu optimistis terhadap laptop yang mirip. Sebagai analisis sensitivitas, notebook juga melakukan pembagian group-disjoint berdasarkan nama model, yang akan dibahas terpisah pada evaluasi.

4.5 Augmentasi, Keseimbangan Data, dan Pipeline Tensor

Augmentasi citra atau teks tidak digunakan karena dataset berupa data tabular spesifikasi. Kami tidak menerapkan SMOTE maupun oversampling pada percobaan inti karena distribusi kelas masih relatif berimbang dan perlu menjaga arti kategori harga. Setelah preprocessing, data dibangun menjadi train_ds, val_ds, dan test_ds menggunakan tf.data.Dataset.from_tensor_slices; hanya training yang diacak. Seluruh subset menggunakan batch berukuran 32 dan prefetch untuk menyiapkan data secara efisien.

Pemeriksaan pada notebook mengonfirmasi bentuk tensor training (712, 83), validasi (153, 83), dan testing (153, 83), dengan tipe fitur float32 dan label int64. Label mempunyai rentang 0, 1, dan 2, tanpa NaN dan infinity setelah transformasi.

MODEL YANG DIGUNAKAN

5.1 Jenis dan Alasan Pemilihan Model

Model utama adalah Deep Neural Network (DNN) dengan arsitektur Multi-Layer Perceptron. Lapisan Dense memungkinkan jaringan menggabungkan pengaruh fitur numerik dan kategorikal yang sudah diubah menjadi vektor. Arsitektur CNN tidak dipilih karena dataset tidak memiliki hubungan ketetanggaan dua dimensi seperti piksel pada citra. Proyek tidak menggunakan arsitektur CNN ataupun transfer learning.

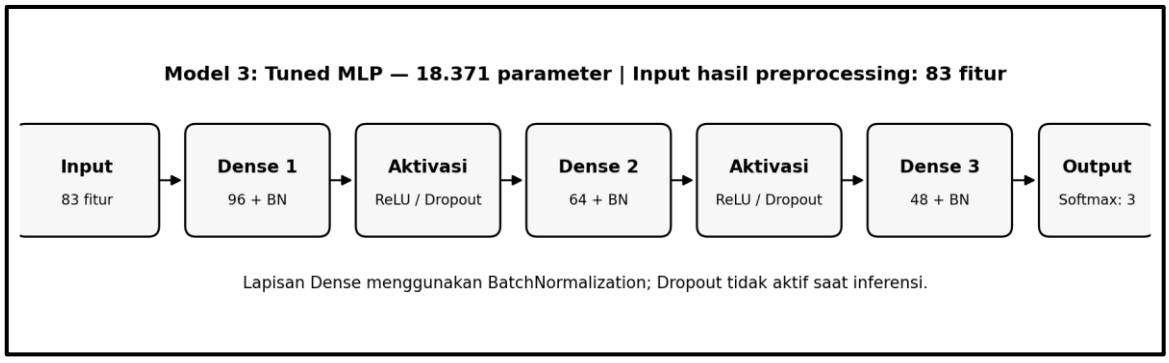
5.2 Arsitektur Baseline, Regularized, dan Tuned MLP

Tabel 10. Ringkasan arsitektur ketiga model

Model	Hidden layer	Penguatan pelatihan	Parameter
Model 1 - Baseline	64 → 32	SGD; tanpa BN/Dropout/L2	7.555
Model 2 - Regularized	128 → 64 → 32	Adam; BN; Dropout; L2	22.083
Model 3 - Tuned	96 → 64 → 48	KerasTuner; Adam; BN; Dropout; L2	18.371

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(3).ipynb, Section 5-7.

Pada model hasil tuning, vektor masukan berisi 83 fitur. Lapisan Dense pertama menggunakan 96 neuron, dilanjutkan Batch Normalization, ReLU, dan Dropout 0,2. Lapisan kedua menggunakan 64 neuron dengan pemrosesan serupa, sedangkan lapisan ketiga berisi 48 neuron sebelum softmax pada tiga kelas. Jumlah parameter hasil model.summary() adalah 18.371, yang terdiri atas 17.955 parameter trainable dan 416 parameter nontrainable Batch Normalization.



Gambar 4. Diagram arsitektur MLP hasil tuning: 83 fitur masukan menjadi tiga probabilitas kelas

Sumber: Disusun ulang dari model.summary() notebook Section 7; ukuran layer dan jumlah parameter mengikuti output aktual.

5.3 Konfigurasi Pelatihan dan Hyperparameter Tuning

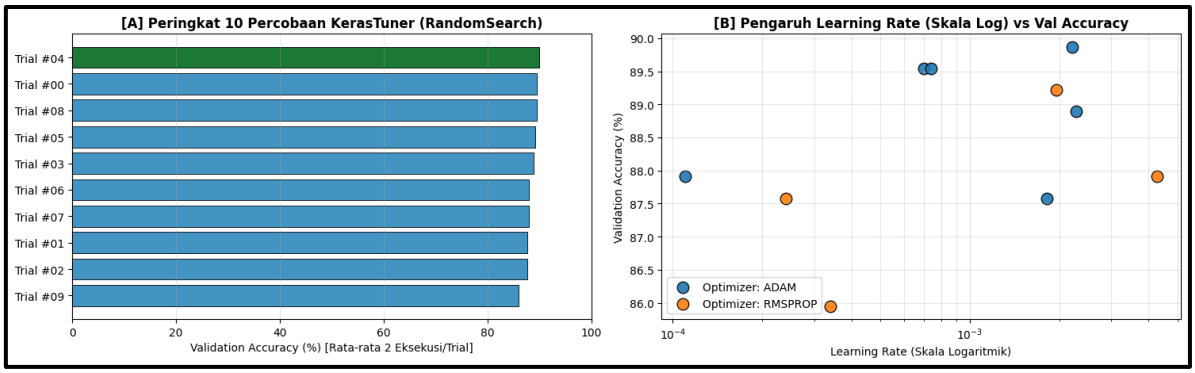
Model 1 menjadi baseline menggunakan SGD dengan learning rate 0,01 dan maksimal 50 epoch. Model 2 menggunakan Adam dengan learning rate 0,001, Batch Normalization, Dropout 0,3/0,2, L2, dan callback EarlyStopping. Model 3 diperoleh melalui KerasTuner RandomSearch dengan 10 trial serta dua eksekusi pada setiap trial. Ruang pencarian mencakup jumlah hidden layer, jumlah neuron, optimizer, learning rate, Dropout, dan nilai L2, dengan sampel skala logaritmik untuk parameter kontinu tertentu.

Tabel 11. Konfigurasi utama MLP hasil KerasTuner

Hyperparameter	Hasil pada notebook
Trial terbaik	Trial #04
Jumlah hidden layer	3
Neuron tiap hidden layer	96, 64, 48
Optimizer	Adam
Learning rate awal	0,0022119679
Dropout	0,2 pada dua layer awal
Regularisasi L2	0,0000195287
Jumlah parameter	18.371
Epoch retraining	36; bobot terbaik dari epoch 21
Loss	SparseCategoricalCrossentropy
Batch	32
Monitoring	ReduceLROnPlateau, EarlyStopping, ModelCheckpoint, CSVLogger

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(3).ipynb, Section 6-7, output pelatihan dan hasil best_hp.

Setelah pencarian selesai, model dibangun ulang dari hyperparameter yang terpilih, lalu dilatih menggunakan ReduceLROnPlateau dan EarlyStopping. Retraining berhenti pada epoch ke-36 dan mengembalikan bobot dari epoch ke-21 karena validation loss mencapai minimum pada titik tersebut. Akurasi validasi puncak 90,20% pada epoch lain bukan metrik dari bobot yang akhirnya digunakan. Perbedaan tersebut dinyatakan secara terpisah pada hasil evaluasi.



Gambar 5. Peringkat 10 percobaan KerasTuner dan hubungan learning rate dengan skor validasi
Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(3).ipynb, output grafik Section 6.

5.4 Alasan Model Hasil Tuning Menjadi Fokus

Fokus proyek ditetapkan oleh judul, yaitu MLP dengan hyperparameter tuning. Karena itu, Model 3 menjadi model utama untuk evaluasi, interpretasi fitur, dan rancangan deployment. Model 1 dan Model 2 tetap dilaporkan sebagai pembanding yang membantu menjelaskan dampak perubahan arsitektur serta keterbatasan tuning dengan ruang pencarian dan sumber daya yang tersedia. Model utama tidak diganti hanya berdasarkan akurasi testing yang lebih tinggi pada pembanding.

5.5 Dua Fitur Unik dan Bukti Dampaknya

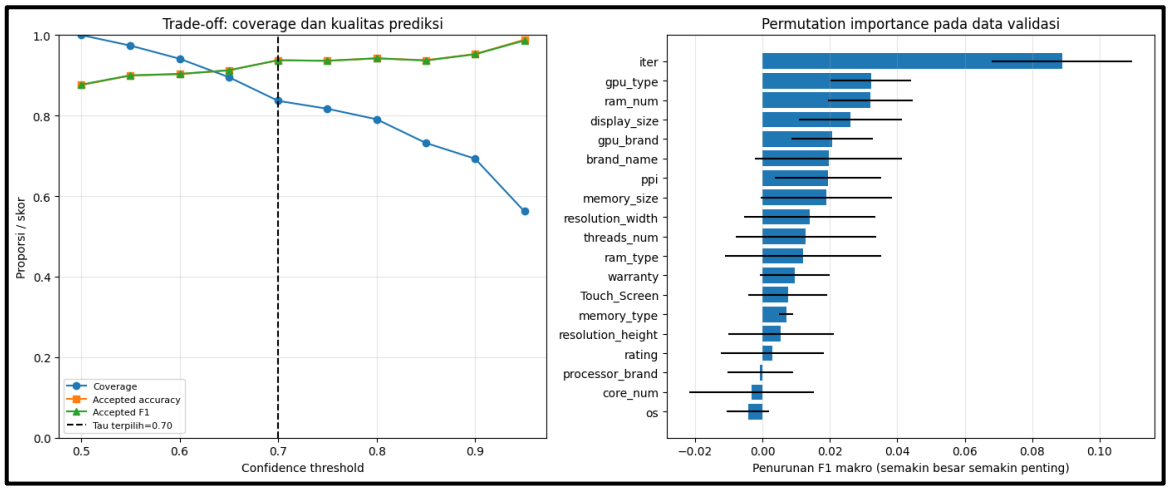
Fitur unik pertama ialah confidence threshold untuk menandai prediksi dengan skor probabilitas tertinggi di bawah ambang terpilih. Ambang 0,70 dipilih pada data validasi, dengan kriteria keseimbangan antara cakupan prediksi yang diterima dan F1 makro. Mekanisme ini tidak mengubah probabilitas model, melainkan menambah status “Perlu Ditinjau” ketika kepastian keluaran relatif rendah.

Fitur kedua ialah permutation importance pada data validasi. Nilai satu fitur asli diacak berulang sebanyak 10 kali, lalu penurunan F1 makro dibandingkan dengan skor dasar. Pengacakan dilakukan di tingkat kolom fitur asli, bukan pada satu indikator one-hot secara terpisah, sehingga satu kategori tetap diperlakukan sebagai satu atribut. Metode tersebut membantu mengidentifikasi fitur yang paling diandalkan jaringan, tetapi tidak membuktikan pengaruh kausal.

Tabel 12. Dampak dua fitur unik pada eksperimen

Fitur	Indikator utama	Hasil nyata
Confidence threshold	Ambang terpilih dari validation	0,70
Confidence threshold	Coverage data test	126/153 (82,35%)
Confidence threshold	Akurasi pada prediksi diterima	89,68%
Confidence threshold	Kesalahan yang ditandai untuk ditinjau	14 dari 27 kesalahan
Permutation importance	Penurunan F1 terbesar: iter	0,08892
Permutation importance	Penurunan F1: gpu_type	0,03215
Permutation importance	Penurunan F1: ram_num	0,03196

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(3).ipynb, Section 11.



Gambar 6. Perubahan coverage dan F1 pada confidence threshold serta peringkat permutation importance

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(3).ipynb, output grafik Section 11.

HASIL EVALUASI DAN ANALISIS

6.1 Metrik Evaluasi dan Dasar Pemakaiannya

Kami memakai accuracy untuk melihat jumlah prediksi benar secara keseluruhan; precision untuk menilai ketepatan prediksi suatu kelas; recall untuk mengukur seberapa banyak anggota kelas aktual dikenali; dan F1 makro untuk merangkum kemampuan tiga kelas dengan bobot yang sama. Confusion matrix dipakai untuk melihat arah kesalahan, sedangkan loss dan learning curve membantu menilai perkembangan training serta jarak terhadap validation.

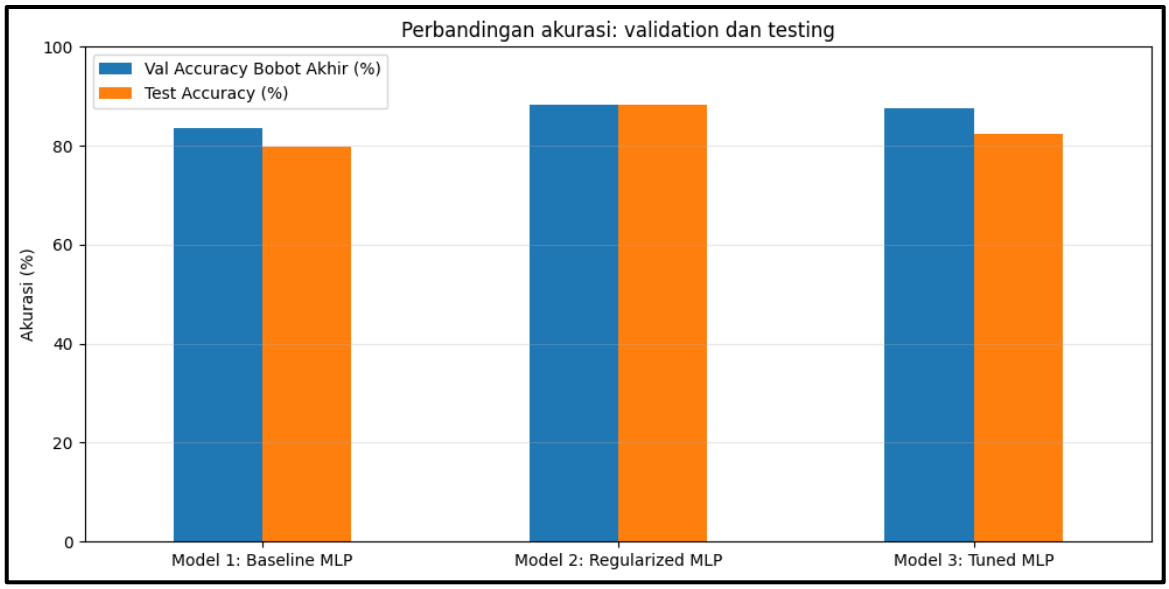
6.2 Hasil Tiga Model pada Data Testing

Tabel 13. Perbandingan metrik pengujian tiga model

Model	Accuracy	Precision makro	Recall makro	F1 makro
Model 1 - Baseline	79,74%	0,7974	0,8065	0,7990
Model 2 - Regularized	88,24%	0,8824	0,8887	0,8843
Model 3 - Tuned (utama)	82,35%	0,8244	0,8323	0,8256

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(3).ipynb, Section 8 dan Section 10.

Model 3 mencapai 126 prediksi benar dari 153 data uji, sehingga 27 contoh masih salah klasifikasi. Dibandingkan Model 1, akurasi meningkat 2,61 poin persentase dan F1 makro meningkat sekitar 0,0266. Akan tetapi, Model 2 memperoleh akurasi dan F1 lebih tinggi daripada Model 3. Dengan demikian, manfaat tuning tidak boleh dinyatakan sebagai kemenangan terhadap seluruh model pembanding; hasil menunjukkan peningkatan terhadap baseline dan adanya keterbatasan pencarian parameter yang digunakan.

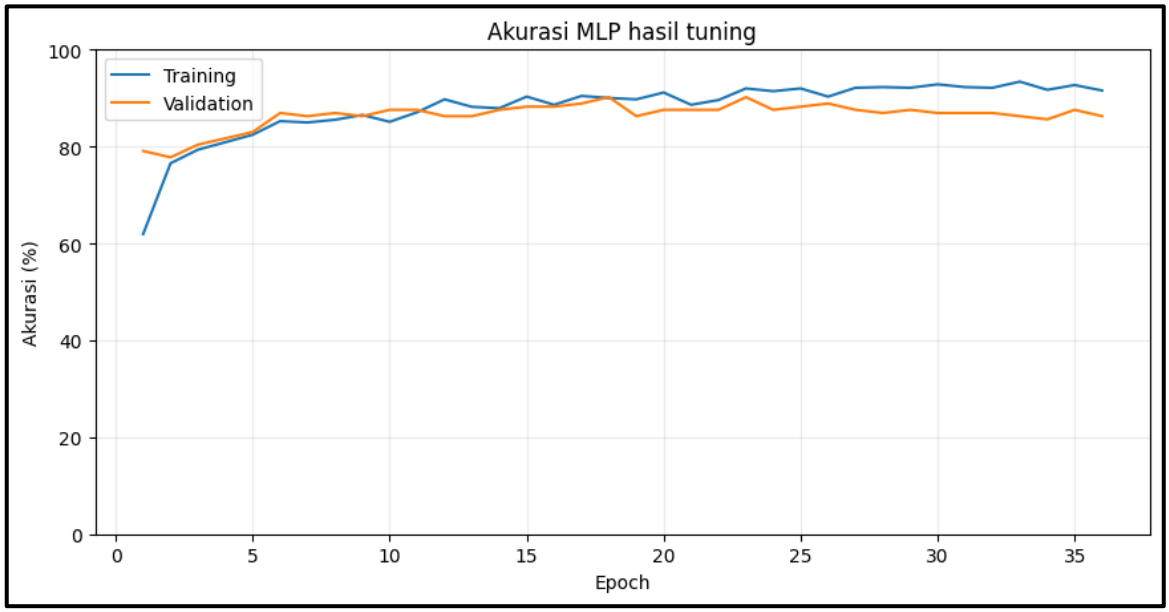


Gambar 7. Perbandingan akurasi validasi bobot akhir dan akurasi testing ketiga MLP

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(3).ipynb, output grafik Section 10.

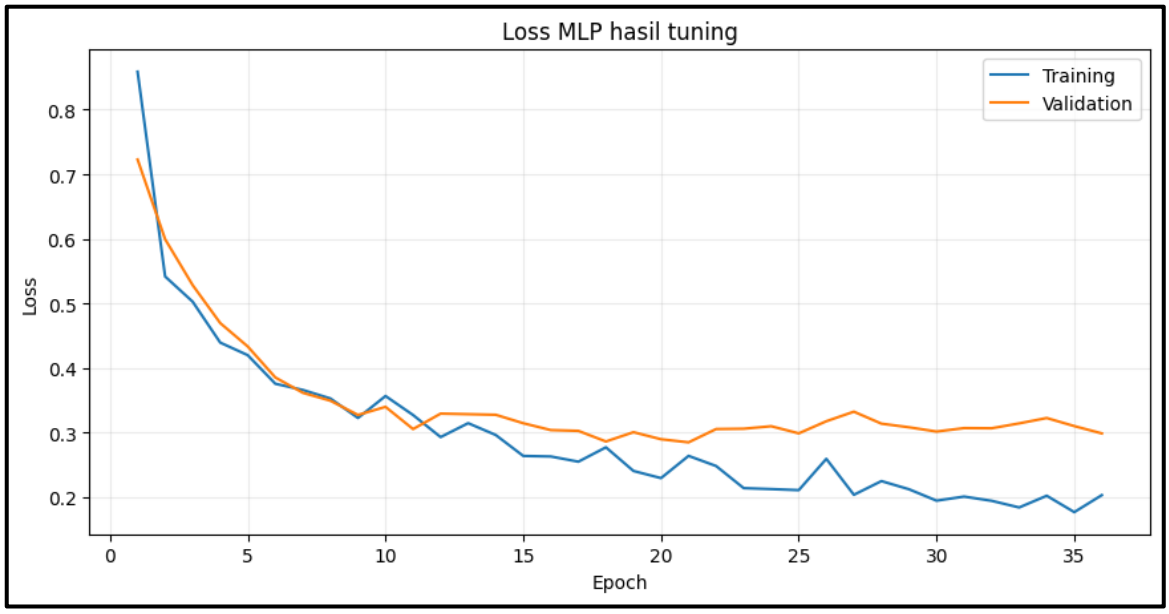
6.3 Grafik Accuracy dan Loss pada Model Utama

Kurva training dan validation memperlihatkan bahwa pembelajaran model pada awal pelatihan berlangsung cukup cepat, kemudian perbaikannya melambat. Model terbaik menurut validation loss dipulihkan dari epoch 21. Saat pelatihan berlanjut hingga epoch 36, selisih kurva training dan validation perlu dipandang sebagai indikasi kemampuan generalisasi yang terbatas, bukan bukti model selalu akan menghasilkan prediksi yang benar pada data baru.



Gambar 8. Kurva accuracy training dan validation MLP hasil tuning

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(3).ipynb, output grafik Section 14, diekstrak dari riwayat Section 7.

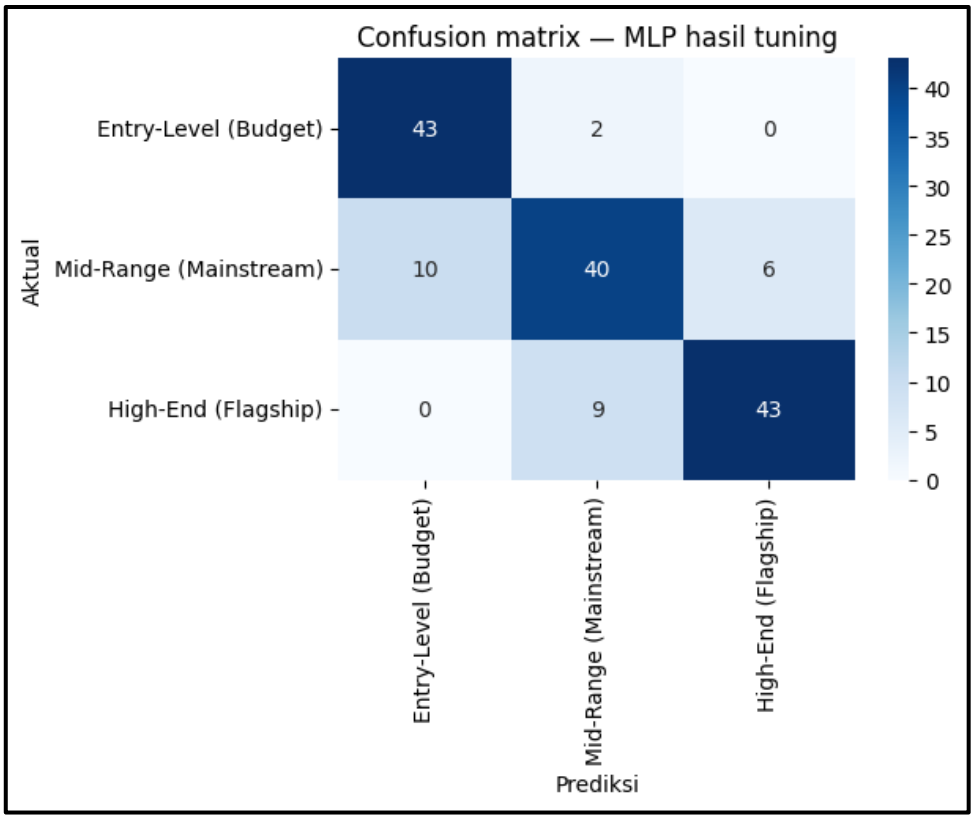


Gambar 9. Kurva loss training dan validation MLP hasil tuning

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(3).ipynb, output grafik Section 14, diekstrak dari riwayat Section 7.

6.4 Confusion Matrix dan Analisis Per Kelas

Confusion matrix memperlihatkan kelas Entry-Level memperoleh 43 prediksi benar dari 45 sampel, dengan dua sampel bergeser ke Mid-Range. Dari 56 sampel Mid-Range, hanya 40 yang tepat, 10 diprediksi Entry-Level, dan enam diprediksi High-End. Pada kelas High-End, 43 dari 52 sampel benar dan sembilan diprediksi Mid-Range. Karena itu, Mid-Range memiliki recall terendah, yaitu sekitar 71,43%.



Gambar 10. Confusion matrix Model 3 pada 153 data uji

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(3).ipynb, output grafik Section 14 (evaluasi model dari Section 8).

Tabel 14. Analisis keberhasilan dan kesalahan menurut kelas

Kelas aktual	Benar	Salah	Recall
Entry-Level (45)	43	2	95,56%
Mid-Range (56)	40	16	71,43%
High-End (52)	43	9	82,69%

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(3).ipynb, Section 8/14, confusion matrix model utama.

Kelas Mid-Range lebih sering keliru karena spesifikasinya dapat bertumpang tindih dengan laptop pada kelas lebih murah maupun lebih mahal. Penjelasan ini merupakan interpretasi yang masuk akal berdasarkan pola kesalahan, bukan pembuktian penyebab untuk setiap perangkat. Pemeriksaan lebih rinci memerlukan penelusuran contoh salah klasifikasi dan fitur yang memengaruhinya.

6.5 Perbandingan Ablasi dan Stabilitas Multi-Seed

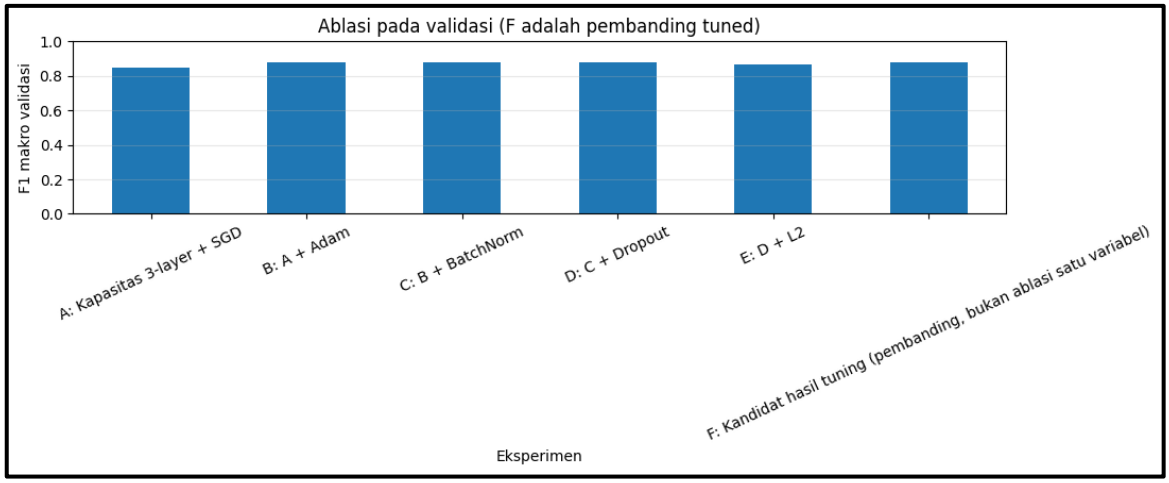
Eksperimen ablasi menggunakan arsitektur yang dikendalikan secara bertahap. Percobaan A memakai SGD, B mengganti optimizer menjadi Adam, C menambah Batch Normalization, D menambah Dropout, dan E menambah regularisasi L2. Kandidat F

adalah model hasil tuning sebagai pembanding, bukan satu langkah tambahan langsung pada rangkaian ablasi.

Tabel 15. Ablasi model pada validasi

Skenario	Accuracy validasi	F1 makro validasi	Loss validasi
A. Kapasitas 3 layer + SGD	84,97%	0,8502	0,3794
B. A + Adam	87,58%	0,8763	0,3273
C. B + BatchNorm	87,58%	0,8758	0,3035
D. C + Dropout	87,58%	0,8771	0,2814
E. D + L2	86,93%	0,8694	0,3023
F. Hasil tuning (pembanding)	87,58%	0,8769	0,2849

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(3).ipynb, Section 12.



Gambar 11. Perbandingan F1 makro validasi pada studi ablasi A-F

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(3).ipynb, output grafik Section 12.

Penambahan Adam dari skenario A ke B meningkatkan F1 makro validasi dari 0,8502 menjadi 0,8763. Penambahan Batch Normalization dan Dropout mengubah loss, tetapi tidak secara konsisten menaikkan accuracy. L2 pada skenario E justru menurunkan skor relatif terhadap D pada eksekusi ini. Hasil tersebut menegaskan bahwa pengaruh regularisasi bergantung pada konfigurasi dan kondisi eksperimen, bukan sekadar jumlah teknik yang ditambahkan.

Tabel 16. Stabilitas lima seed pada data validasi

Model	Rerata accuracy	SD accuracy (pp)	Rerata F1 ± SD
Model 1 - Baseline	84,97%	2,01	0,84979 ± 0,02031
Model 2 - Regularized	87,45%	0,55	0,87490 ± 0,00528
Model 3 - Tuned	87,71%	0,85	0,87765 ± 0,00865

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(3).ipynb, Section 12, seed 42/52/62/72/82.

Model 3 memiliki rerata F1 validasi tertinggi pada lima seed yang digunakan, tetapi selisih reratanya kecil. Simpangan baku dalam tabel bersifat deskriptif untuk lima ulangan pelatihan pada pembagian data yang sama; angka tersebut tidak dapat diperlakukan sebagai interval kepercayaan hasil populasi laptop secara umum.

6.6 Pengujian Sensitivitas dan Keterbatasan Generalisasi

Pada pemisahan tambahan yang memastikan nama model laptop tidak bertumpang tindih antarsubset, evaluasi memakai 713 data training, 160 validasi, dan 145 testing, dengan overlap nama model nol. Akurasi validasi yang tercatat adalah 88,75% dan akurasi pengujian sebesar 82,07%, dengan F1 makro testing sekitar 0,8246. Eksperimen ini merupakan uji sensitivitas, bukan benchmark independen, karena ruang tuning sebelumnya telah dirancang dengan pemisahan acak.

Hasil uji tambahan tersebut menunjukkan bahwa perubahan cara membagi data dapat mengubah ukuran sampel dan gambaran generalisasi. Selain itu, sebagian produk memiliki spesifikasi identik dengan harga berbeda, sehingga jaringan tidak selalu dapat memisahkan kelas hanya dari informasi teknis yang tersedia. Dataset mencerminkan katalog dari satu sumber dan tidak mewakili seluruh variasi harga pasar Indonesia.

TEKNOLOGI YANG DIGUNAKAN

7.1 Bahasa Pemrograman, Library, dan Lingkungan Eksperimen

Seluruh eksperimen dijalankan dalam notebook Python melalui Google Colab. Berdasarkan keluaran Section 1, runtime menggunakan Python 3.13.18 pada sistem Linux x86_64 dengan akselerator CPU standar. Informasi ini mengikuti lingkungan yang benar-benar tercetak pada sesi notebook, bukan spesifikasi GPU yang diasumsikan tersedia.

Tabel 17. Teknologi dan versi berdasarkan keluaran notebook

Komponen	Versi / peran
Python	3.13.18
TensorFlow / Keras	2.21.0; definisi, training, evaluasi MLP
KerasTuner	1.4.8; RandomSearch hyperparameter
scikit-learn	1.6.1; splitting, preprocessing, metrik
pandas	2.2.3; tabel dan pengolahan data
NumPy	2.4.6; operasi matriks dan tensor
joblib	1.6.0; penyimpanan preprocessor
Google Colab	Notebook; Linux x86_64; CPU Standard
Matplotlib	Visualisasi EDA dan evaluasi (versi tidak dicetak)
Kagglehub	Akuisisi dataset (versi tidak dicetak)

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(3).ipynb, Section 1 dan penggunaan library di Section 2-14.

7.2 Teknologi Aplikasi dan Hosting

Aplikasi hasil penelitian dipublikasikan melalui Hugging Face Spaces dengan SDK Static, bukan Gradio. Halaman index.html menyajikan antarmuka pengguna, style.css mengatur tampilan, app.js menangani input dan penampilan hasil, serta inference.js menjalankan transformasi fitur dan perhitungan MLP di browser. Berkas model_browser.json dan preprocessing_browser.json menyiapkan bobot serta statistik training untuk inferensi tanpa backend Python.

Aplikasi LAPTOP-CLASSIFIER menggunakan Hugging Face Spaces SDK Static untuk menjalankan inferensi di browser dengan model hasil tuning. Bukti UI memperlihatkan prediksi kustom dan pemrosesan batch; tampilan dua tema tidak mengubah bobot model. Rentang harga disajikan dalam INR asli dan IDR ilustratif, sedangkan hasil Softmax adalah tingkat keyakinan prediksi, bukan akurasi keseluruhan model.

DEPLOYMENT DAN DEMONSTRASI

8.1 Status Publikasi dan Keselarasan Model

Aplikasi LAPTOP-CLASSIFIER telah dipublikasikan sebagai Hugging Face Space dengan SDK Static. Tangkapan layar yang direkam pada 9 November 2026 menunjukkan status Space “Running”, tersedianya formulir prediksi kustom, dua tema warna, serta hasil prediksi massal dari CSV, XLSX, JSON, dan preset katalog data latih. Dengan adanya bukti penggunaan tersebut, pembahasan deployment tidak lagi hanya berupa rencana antarmuka.

Alamat deploy aplikasi: https://huggingface.co/spaces/Xkazuya/LAPTOP-CLASSIFIER. Repository penelitian, notebook final, tabel, grafik, dan source frontend: https://github.com/x-kzy/UTS-DEEP-LEARNING. Notebook juga tersedia pada Google Colab melalui tautan di Bagian B. Dokumentasi video dapat dilampirkan melalui tautan terpisah setelah video diunggah dengan akses publik.

Model produksi yang ditampilkan di antarmuka adalah Model 3: Tuned MLP dengan 83 fitur hasil preprocessing, tiga hidden layer berukuran 96, 64, dan 48, serta tiga keluaran softmax. Hasil evaluasi model yang dilaporkan tetap berasal dari notebook: akurasi testing 82,35% (126/153) dan F1 makro 0,8256. Angka confidence prediksi pada website tidak boleh dipertukarkan dengan akurasi tersebut.

Tabel 18. Status bukti deployment dan hasil pengujian yang tersedia

Komponen	Temuan dan batas verifikasi
Repository GitHub	https://github.com/x-kzy/UTS-DEEP-LEARNING
Hugging Face Spaces	https://huggingface.co/spaces/Xkazuya/LAPTOP-CLASSIFIER
Model MLP utama	Model 3 Tuned MLP, 83 fitur → 96–64–48 → 3 kelas; hasil notebook tersimpan
Input kustom	Bukti dua prediksi kustom: Entry-Level 98,59% dan High-End 100,00% (Softmax yang dibulatkan; bukan akurasi penelitian).
Input batch	Screenshot mengonfirmasi pemrosesan preset 48, CSV 18, XLSX 40, dan JSON 72
Video demonstrasi	

Sumber: Screenshot pengujian Space yang diberikan kelompok; source aplikasi dan notebook final serta README GitHub.

8.2 Tahapan Deployment Hugging Face Spaces SDK Static

Hugging Face Spaces dipilih karena dapat menyajikan aplikasi yang dapat diakses melalui URL publik. SDK Static memungkinkan aplikasi dijalankan menggunakan HTML, CSS, dan JavaScript tanpa server Python untuk setiap prediksi. Arsitektur ini sesuai dengan model MLP tabular yang bobot dan parameter preprocessing-nya telah disiapkan dalam bentuk berkas statis.

Alur deployment yang digunakan mencakup tujuh langkah: (1) melatih dan memilih Model 3 di Google Colab; (2) menyimpan bobot jaringan, parameter Batch Normalization, median imputasi, StandardScaler, kategori OneHotEncoder, dan label; (3) mengekspor artefak model dan preprocessing ke JSON; (4) menyediakan index.html, style.css, app.js, inference.js, dan pembaca XLSX; (5) membuat Space LAPTOP-CLASSIFIER dengan pilihan SDK Static/Blank; (6) mengunggah berkas ke root Space dan melakukan commit; serta (7) memeriksa pemuatan model, input kustom, prediksi batch, dan ekspor hasil pada tab App.

Saat pengguna memilih preset atau mengisi spesifikasi, app.js melakukan validasi dan membentuk data input; inference.js memulihkan urutan 83 fitur menggunakan statistik dan kategori dari training, lalu menjalankan perhitungan layer Dense, Batch Normalization, aktivasi, dan softmax. Nilai PPI dihitung dari resolusi serta diagonal layar. Dengan demikian, server Hugging Face hanya menyajikan berkas website; inferensi berlangsung di browser.

Tabel 19. Berkas aplikasi dan perannya pada SDK Static

Berkas	Kegunaan pada aplikasi
README.md	Metadata Hugging Face: sdk: static dan app_file: index.html
index.html, style.css	Susunan antarmuka, formulir, tab, responsivitas, tema terang dan gelap
app.js, inference.js	Validasi input, transformasi fitur, inferensi MLP, probabilitas, dan penyajian hasil
xlsx-lite.js	Pembacaan dan ekspor berkas spreadsheet XLSX di browser
model_browser.json	Bobot Dense, bias, dan konfigurasi jaringan terlatih
preprocessing_browser.json	Median imputasi, statistik StandardScaler, dan kategori OneHotEncoder
feature_schema.json, class_labels.json	Urutan fitur, rentang input, label, dan konversi harga ilustratif

Berkas	Kegunaan pada aplikasi
evaluation_results.json, model_parity_reference.json	Ringkasan hasil notebook dan contoh pemeriksaan kesetaraan inferensi
presets.json, catalog_presets.json	Contoh input kustom dan katalog preset yang diekspor dari data latih

Sumber: Notebook Section 13; arsip source website serta dokumentasi repository x-kzy/UTS-DEEP-LEARNING.

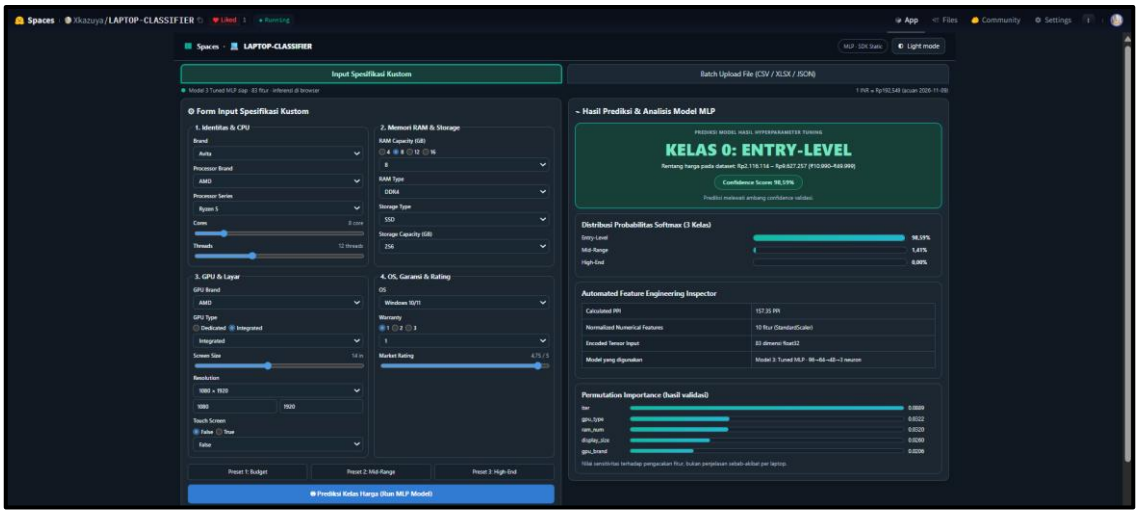
Perubahan source HTML/JavaScript yang dikirimkan kelompok telah memuat footer "UTS ● DEEP LEARNING ● KELOMPOK 4 ● LAPTOP CLASSIFIER" dan keterangan "Sumber output: Notebook UTS". Meski demikian, kecocokan byte demi byte seluruh berkas Space yang sedang online dengan salinan lokal tidak dapat dipastikan hanya dari screenshot. Pengujian paritas diperlukan untuk membuktikan keluaran JavaScript sama dengan Keras untuk input yang sama.

8.3 *User Interface Website*, Dual Mode, dan Dual Price

Website menyediakan dua tab utama, yaitu Input Spesifikasi Kustom dan Batch Upload File. Formulir kustom menampilkan merek laptop, merek dan seri prosesor, jumlah core dan threads, kapasitas dan tipe RAM, penyimpanan, merek serta tipe GPU, ukuran dan resolusi layar, touchscreen, sistem operasi, garansi, dan rating. Input disediakan dalam bentuk dropdown, radio button, slider, atau angka, sesuai jenis atribut; opsi kategorikal diambil dari encoder dan artefak dataset training.

Pengguna dapat berpindah antara Light Mode dan Dark Mode tanpa mengubah input atau bobot model. Penyajian harga juga menggunakan dua mata uang (dual price): kelas ditentukan dengan ambang asli INR, sedangkan IDR hanya padanan ilustratif berdasarkan kurs acuan tetap 1 INR ≈ Rp192,549 pada 9 November 2026. Sistem memprediksi kelas harga dan probabilitas softmax, bukan harga jual individual yang dijamin berlaku di Indonesia.

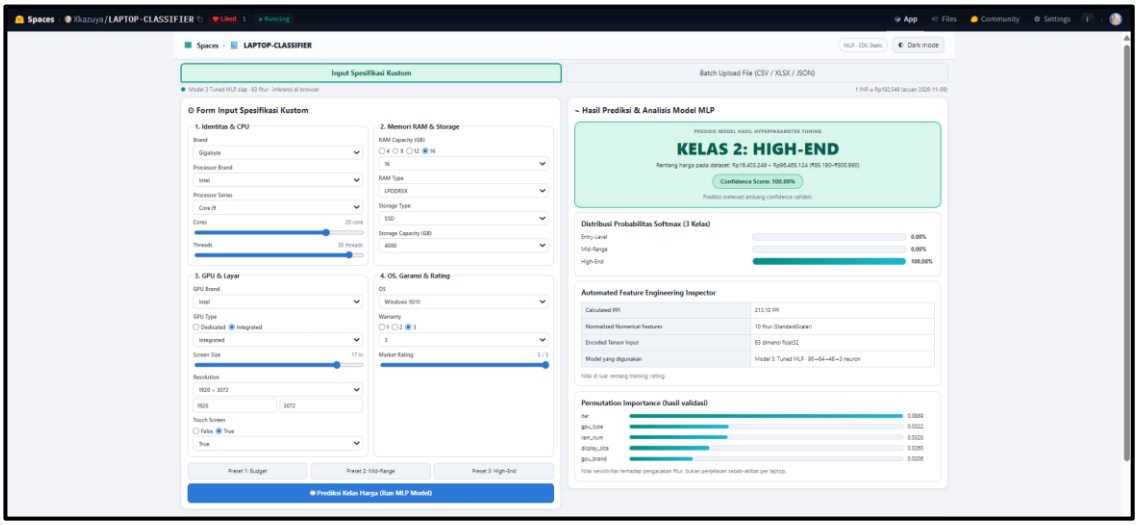
Fitur yang tersedia mencakup pemilihan tema terang/gelap (dual mode), konversi informasi rentang harga INR/IDR (dual price), input spesifikasi melalui dropdown, radio button dan slider, tiga preset kustom, preset katalog dari data latih, perhitungan PPI otomatis, grafik tiga probabilitas Softmax, serta panel permutation importance. Confidence threshold 0,70 memberi status Diterima atau Perlu Ditinjau; daftar fitur ini mengacu pada antarmuka dan source yang terdokumentasi, sedangkan demonstrasi langkah pengguna dapat dilihat pada video presentasi kelompok.



Gambar 12. Prediksi preset Budget pada tampilan gelap: kelas Entry-Level (98,59%)

Sumber: Tangkapan layar aplikasi LAPTOP-CLASSIFIER di Hugging Face Spaces; dokumentasi pengujian Kelompok 4, 9 November 2026.

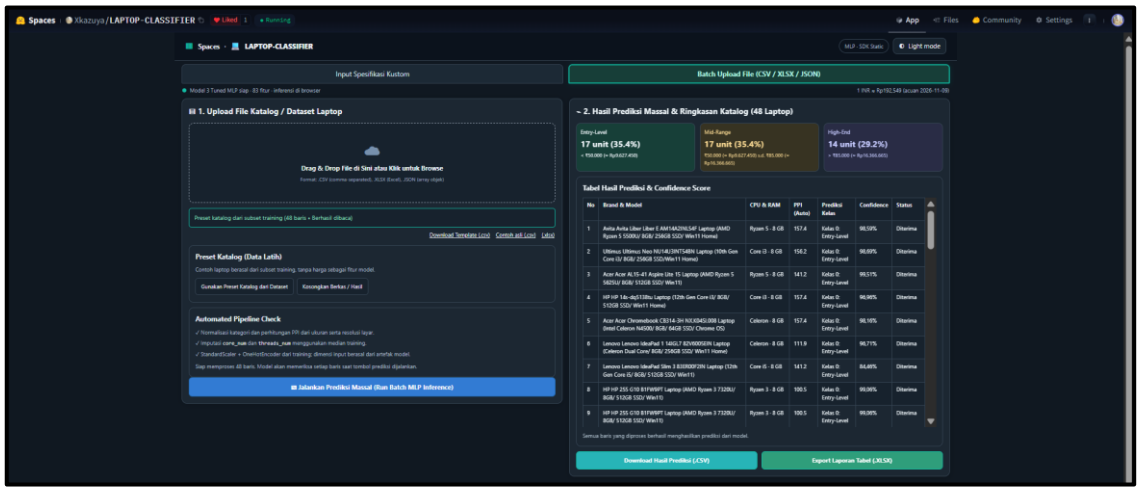
Pada Gambar 12, preset Budget menampilkan Avita dengan AMD Ryzen 5, delapan core, 12 thread, RAM 8 GB DDR4, SSD 256 GB, GPU AMD Integrated, layar 14 inci, dan garansi satu tahun. Hasilnya Kelas 0 (Entry-Level), dengan confidence 98,59%, probabilitas Mid-Range 1,41%, serta High-End 0,00%. PPI dihitung otomatis sebesar 157,35. Rentang yang ditunjukkan, ₹10.990–₹49.999 (sekitar Rp2.116.114–Rp9.627.257), merupakan rentang observasi kelas pada dataset, bukan penaksiran harga jual laptop masukan.



Gambar 13. Input kustom High-End pada tampilan terang: confidence 100,00% (Softmax)

Sumber: Tangkapan layar aplikasi LAPTOP-CLASSIFIER di Hugging Face Spaces; dokumentasi pengujian Kelompok 4, 9 November 2026.

Gambar 13 menunjukkan pengujian input kustom pada Light Mode dengan Gigabyte, Intel Core i9 (20 core dan 30 thread), RAM 16 GB LPDDR5X, SSD 4.000 GB, GPU Intel Integrated, layar 17 inci beresolusi 1920 × 3072, layar sentuh, garansi tiga tahun, serta rating 5/5. Model memprediksi Kelas 2 (High-End) dengan confidence yang ditampilkan 100,00% setelah pembulatan Softmax. Angka ini bukan akurasi pengujian 100%. Inspector juga menandai rating yang berada di luar rentang training sehingga ketidakpastian pada input ekstrem tetap perlu diperhatikan.



Gambar 14. Preset katalog 48 laptop dari data training pada tampilan gelap

Sumber: Tangkapan layar aplikasi LAPTOP-CLASSIFIER di Hugging Face Spaces; dokumentasi pengujian Kelompok 4, 9 November 2026.

Pada Gambar 14, fitur Preset Katalog dari Dataset memuat 48 laptop dari subset training dan berhasil menghasilkan 17 Entry-Level (35,4%), 17 Mid-Range (35,4%), serta 14 High-End (29,2%). Tampilan gelap memperlihatkan tabel berisi model laptop, spesifikasi CPU/RAM, PPI, kelas, confidence, dan status penerimaan. Preset data training dimaksudkan untuk memeriksa alur aplikasi dan tidak digunakan sebagai ukuran kemampuan generalisasi terhadap data testing.

8.4 Demonstrasi Prediksi Kustom, Batch, dan Video

Pada demo batch, pengguna memilih file CSV, XLSX, atau JSON melalui area unggah, lalu menekan “Jalankan Prediksi Massal”. Antarmuka membaca beberapa laptop sekaligus, menghitung PPI, menerapkan imputasi serta preprocessing training, dan menampilkan kelas, confidence, status peninjauan, serta jumlah laptop per kelas. Hasil prediksi dapat diekspor kembali sebagai CSV maupun XLSX.

Pengujian batch dilakukan menggunakan berkas CSV 18 laptop, XLSX 40 laptop, dan JSON 72 laptop dengan komposisi skenario yang berbeda. Rekapitulasi numerik disajikan

pada Tabel 21. Ketiga format memperlihatkan keberhasilan pembacaan data serta penyajian hasil dalam tabel; tersedia pula tombol unduh template, contoh asli, reset berkas, ekspor CSV, dan ekspor XLSX. Pengujian file sintetis tidak menyediakan ground truth, sehingga distribusi keluaran tidak boleh dibandingkan sebagai akurasi model.

Tabel 20. Contoh prediksi benar dan salah dari data testing notebook

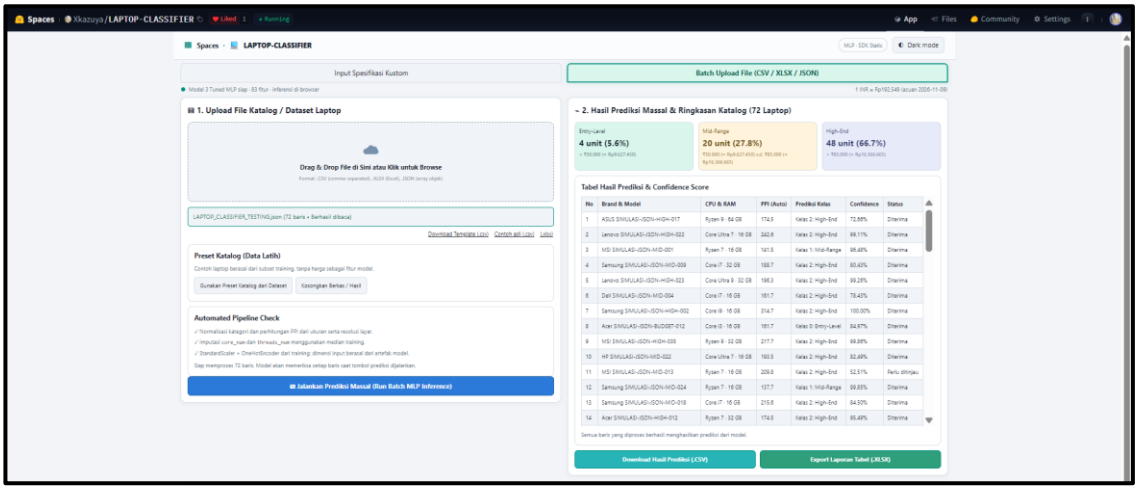
Contoh data berlabel	Harga asli / ekuivalen IDR	Kelas aktual → prediksi
Lenovo IdeaPad 3 82XQ008TIN	₹42.990 / ≈ Rp8.277.682	Entry-Level → Entry-Level (benar)
HP Victus 15-fa1274TX	₹84.990 / ≈ Rp16.364.740	Mid-Range → Mid-Range (benar)
HP Omen 16-xf0081AX	₹135.999 / ≈ Rp26.186.471	High-End → High-End (benar)
Infinix Zero Book Ultra AI PC	₹85.990 / ≈ Rp16.557.289	High-End → Mid-Range (salah)

Sumber: Notebook final Section 8: contoh data uji dengan harga dan label aktual, bukan skenario CSV/XLSX/JSON.

Tabel 21. Rekapitulasi pengujian batch pada aplikasi Hugging Face

Data input	Total	Entry-Level	Mid-Range	High-End
Preset katalog training	48	17 (35,4%)	17 (35,4%)	14 (29,2%)
CSV skenario	18	0 (0,0%)	13 (72,2%)	5 (27,8%)
XLSX skenario	40	2 (5,0%)	16 (40,0%)	22 (55,0%)
JSON skenario	72	4 (5,6%)	20 (27,8%)	48 (66,7%)

Sumber: Tangkapan layar hasil prediksi yang direkam kelompok pada aplikasi Hugging Face, 9 November 2026.



Gambar 15. Pengujian batch JSON 72 laptop pada tampilan terang

Sumber: Tangkapan layar aplikasi LAPTOP-CLASSIFIER di Hugging Face Spaces; dokumentasi pengujian Kelompok 4, 9 November 2026.

Gambar 15 memperlihatkan batch JSON berisi 72 laptop sintetis yang dibaca melalui tab Batch Upload pada tampilan terang. Hasil yang terlihat adalah empat Entry-Level (5,6%), 20 Mid-Range (27,8%), dan 48 High-End (66,7%). Misalnya, baris ASUS dengan

Ryzen 9 dan RAM 64 GB memperoleh High-End dengan confidence 72,66%, sedangkan contoh dengan confidence 52,51% ditandai Perlu Ditinjau. Hasil ini adalah distribusi prediksi atas data demonstrasi tanpa label harga aktual, sehingga tidak dapat dijadikan perhitungan akurasi.

Dari bukti ui yang tersedia, pengujian prediksi kustom, pergantian tema, preset katalog, dan pembacaan batch telah menghasilkan keluaran sesuai fungsi yang dicontohkan. Keberadaan tombol ekspor dan fitur tambahan juga ditampilkan pada aplikasi, tetapi tangkapan layar saja tidak membuktikan setiap kombinasi input dan seluruh fungsi bebas kegagalan. Verifikasi tambahan ditunjukkan melalui demonstrasi penggunaan aplikasi. Metrik akurasi 82,35% dan F1 makro 0,8256 hanya bersumber dari 153 sampel testing notebook, bukan dari demonstrasi website.

LAMPIRAN TEKNIS DAN BUKTI KODE

9.1 Screenshot Preprocessing dan Pencegahan Kebocoran Data

Screenshot berikut berasal langsung dari kode Section 3. Inti pengendaliannya adalah pemisahan data sebelum proses fit serta pemakaian pipeline yang dibekukan bagi validasi dan pengujian. Definisi lengkap GroupMedianImputer tersimpan dalam modul preprocessors.py yang ditulis oleh notebook.

Cuplikan kode aktual • Section 3 • baris 73-91

```
73  # 3. MEMBANGUN PIPELINE PRAPROSES TERPADU (IMPUTER + SCALER + ONE-HOT ENCODER)
74  # ------------------------------------------------------------------------------
75  col_transformer = ColumnTransformer(
76      transformers=[
77          ('num', StandardScaler(), num_features),
78          ('cat', OneHotEncoder(handle_unknown='ignore', sparse_output=False), cat_features)
79      ]
80  )
81
82  preprocessor = Pipeline([
83      ('group_imputer', GroupMedianImputer(group_col='iter', target_cols=('core_num', 'threads_num'), min_samples=3)),
84      ('feature_encoder', col_transformer)
85  ])
86
87  # Fit HANYA pada X_train, kemudian transform secara konsisten pada X_train, X_val, dan X_test
88  X_train_scaled = preprocessor.fit_transform(X_train).astype(np.float32)
89  X_val_scaled   = preprocessor.transform(X_val).astype(np.float32)
90  X_test_scaled  = preprocessor.transform(X_test).astype(np.float32)
91
```

Gambar 16. Screenshot kode pemisahan data dan preprocessing yang dipelajari dari training
Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(3).ipynb, kode Section 3, baris 73-91.

9.2 Screenshot Arsitektur Model dan Hyperparameter Tuning

Model pembanding serta model utama memakai TensorFlow/Keras. Model utama tidak didefinisikan secara manual setelah pencarian, melainkan dibangun dari best_hp hasil

KerasTuner. Struktur layer pada Screenshot ini sesuai dengan model.summary() dan jumlah parameter yang ditampilkan pada Section 7.

Cuplikan kode aktual • Section 5 • baris 18-56

```
18  # 2. Arsitektur Model 2: Regularized & BatchNorm MLP (128 -> 64 -> 32)
19  # ------------------------------------------------------------------------
20  def build_regularized_mlp(input_dim, num_classes):
21      model = tf.keras.Sequential([
22          tf.keras.layers.Input(shape=(input_dim,), name='input_layer'),
23
24          tf.keras.layers.Dense(128, kernel_regularizer=tf.keras.regularizers.l2(1e-4), name='dense_1'),
25          tf.keras.layers.BatchNormalization(name='bn_1'),
26          tf.keras.layers.Activation('relu', name='relu_1'),
27          tf.keras.layers.Dropout(0.3, name='dropout_1'),
28
29          tf.keras.layers.Dense(64, kernel_regularizer=tf.keras.regularizers.l2(1e-4), name='dense_2'),
30          tf.keras.layers.BatchNormalization(name='bn_2'),
31          tf.keras.layers.Activation('relu', name='relu_2'),
32          tf.keras.layers.Dropout(0.2, name='dropout_2'),
33
34          tf.keras.layers.Dense(32, kernel_regularizer=tf.keras.regularizers.l2(1e-4), name='dense_3'),
35          tf.keras.layers.BatchNormalization(name='bn_3'),
36          tf.keras.layers.Activation('relu', name='relu_3'),
37
38          tf.keras.layers.Dense(num_classes, activation='softmax', name='output_layer')
39      ], name='Model_2_Regularized_MLP')
40      return model
41
42  # Menampilkan ringkasan arsitektur kedua model
43  baseline_mlp = build_baseline_mlp(INPUT_DIM, NUM_CLASSES)
44  regularized_mlp = build_regularized_mlp(INPUT_DIM, NUM_CLASSES)
45
46  print("=== RINGKASAN ARSITEKTUR MODEL 1: BASELINE MLP (64 -> 32) ===")
47  baseline_mlp.summary()
48  print("\n=== RINGKASAN ARSITEKTUR MODEL 2: REGULARIZED & BATCHNORM MLP (128 -> 64 -> 32) ===")
49  regularized_mlp.summary()
50
51  # Pelatihan Model 1: Baseline MLP (SGD standar lr=0.01, 50 epoch)
52  tf.keras.utils.set_random_seed(SEED)
53  baseline_mlp.compile(
54      optimizer=tf.keras.optimizers.SGD(learning_rate=0.01),
55      loss=tf.keras.losses.SparseCategoricalCrossentropy(),
56      metrics=['accuracy']
```

Gambar 17. Screenshot fungsi arsitektur baseline dan regularisasi MLP

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(3).ipynb, kode Section 5, baris 18-56.

Cuplikan kode aktual • Section 6 • baris 49-75

```
49          loss=tf.keras.losses.SparseCategoricalCrossentropy(),
50          metrics=['accuracy']
51      )
52      return model
53
54  # Inisialisasi KerasTuner RandomSearch (10 Percobaan pada Data Validasi, 2 Eksekusi/Trial)
55  tuner = kt.RandomSearch(
56      hypermodel=build_tunable_mlp,
57      objective='val_accuracy',
58      max_trials=10,
59      executions_per_trial=2,
60      seed=SEED,
61      directory='kt_laptop_mlp_dir',
62      project_name='laptop_price_mlp_tuning',
63      overwrite=True
64  )
65
66  search_early_stop = tf.keras.callbacks.EarlyStopping(
67      monitor='val_loss', patience=8, restore_best_weights=True
68  )
69
70  print("Memulai pencarian Hyperparameter dengan KerasTuner RandomSearch (10 Trials, 2 Executions/Trial)...")
71  tuner.search(
72      train_ds,
73      validation_data=val_ds,
74      epochs=45,
75      callbacks=[search_early_stop],
```

Gambar 18. Screenshot kode penentuan ruang pencarian dan KerasTuner RandomSearch

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(3).ipynb, kode Section 6, baris 49-75.

9.3 Screenshot Dua Fitur Unik

Fitur confidence memisahkan prediksi yang diterima otomatis dari prediksi yang memerlukan pemeriksaan. Permutation importance mengacak fitur asli pada data validasi secara berulang, kemudian menghitung perubahan F1 makro. Keduanya memanfaatkan model hasil tuning yang sama, sehingga tidak ada pergantian model diam-diam antara evaluasi dan fitur unik.

Cuplikan kode aktual • Section 11 • baris 37-78

```
37      raise RuntimeError('Tidak ada ambang yang lolos syarat coverage 80%; periksa data validasi.')
38  chosen_threshold_row = eligible.sort_values(
39      ['Accepted Macro F1', 'Coverage', 'Threshold'],
40      ascending=[False, False, True], kind='stable'
41  ).iloc[0]
42  OPTIMAL_TAU = float(chosen_threshold_row['Threshold'])
43  print('=== FITUR 1: HASIL KALIBRASI AMBANG PADA DATA VALIDASI ===')
44  display(thresh_val_df.round(4))
45  print(f'Ambang dipilih dari validasi: tau={OPTIMAL_TAU:.2f}, '
46        f'coverage={chosen_threshold_row["Coverage"]:.2%}, '
47        f'accepted F1={chosen_threshold_row["Accepted Macro F1"]:.4f}')
48
49  # Satu evaluasi ambang terpilih pada data test, tanpa mengubah tau berdasarkan hasil test.
50  mask_test = max_conf_test >= OPTIMAL_TAU
51  n_accept = int(mask_test.sum())
52  if n_accept == 0:
53      raise RuntimeError('Ambang terpilih tidak menerima satu pun sampel pada data test.')
54  base_f1 = f1_score(y_test, pred_cls_test, average='macro', zero_division=0)
55  mask_err = y_test != pred_cls_test
56  threshold_test_df = pd.DataFrame([{
57      'Threshold dari validasi': OPTIMAL_TAU,
58      'Total test': int(len(y_test)),
59      'Diterima otomatis': n_accept,
60      'Ditinjau': int((~mask_test).sum()),
61      'Coverage test': float(mask_test.mean()),
62      'Akurasi semua test': float(accuracy_score(y_test, pred_cls_test)),
63      'F1 makro semua test': float(base_f1),
64      'Akurasi test yang diterima': float(accuracy_score(y_test[mask_test], pred_cls_test[mask_test])),
65      'F1 makro test yang diterima': float(f1_score(
66          y_test[mask_test], pred_cls_test[mask_test], average='macro', zero_division=0
67      )),
68      'Total kesalahan awal': int(mask_err.sum()),
69      'Kesalahan yang ditandai untuk tinjauan': int(np.sum(mask_err & (~mask_test))),
70      'Kesalahan yang masih diterima otomatis': int(np.sum(mask_err & mask_test)),
71  }])
72  print('\n=== FITUR 1: PENGUJIAN AMBANG TETAP PADA DATA TEST ===')
73  display(threshold_test_df.round(4))
74
75  # Fungsi yang sama dipakai dalam uji dan dapat digunakan oleh antarmuka SDK Static.
76  def predict_with_confidence_review(df_input, model_obj, prep_obj, tau=None):
77      tau = OPTIMAL_TAU if tau is None else float(tau)
78      raw = df_input.copy()
```

Gambar 19. Screenshot kode pengujian confidence threshold pada model hasil tuning

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(3).ipynb, kode Section 11, baris 37-78.

Cuplikan kode aktual • Section 11 • baris 91-116

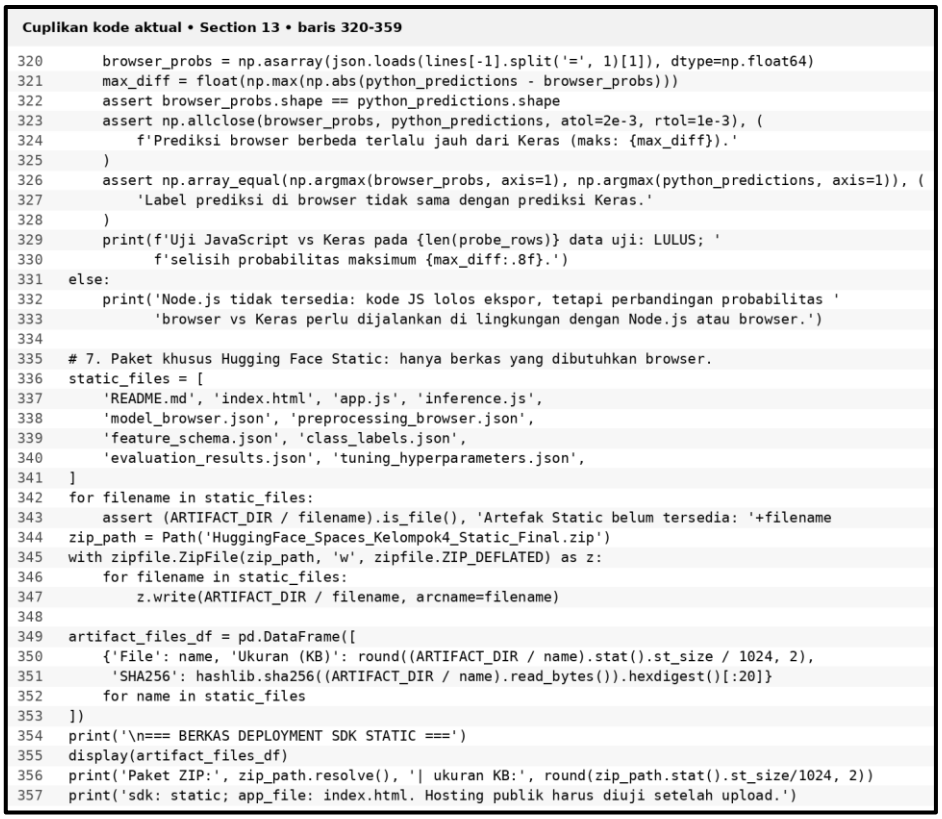
```
# Semua nilai yang ditampilkan berasal dari hasil prediksi yang baru dihitung.
all_original_features = num_features + cat_features
K_REPEATS = 10
baseline_val_f1 = f1_score(y_val, pred_cls_val, average='macro', zero_division=0)
rng_perm = np.random.default_rng(SEED)
permutation_rows = []
for col_name in all_original_features:
    drops = []
    for repeat in range(K_REPEATS):
        X_perm = X_val.copy()
        X_perm[col_name] = rng_perm.permutation(X_perm[col_name].to_numpy())
        transformed = preprocessor.transform(X_perm).astype(np.float32)
        perm_pred = final_model.predict(transformed, verbose=0).argmax(axis=1)
        perm_f1 = f1_score(y_val, perm_pred, average='macro', zero_division=0)
        drops.append(baseline_val_f1 - perm_f1)
    permutation_rows.append({
        'Nama Fitur Asli': col_name,
        'Jenis Fitur': 'Numerik' if col_name in num_features else 'Kategorikal',
        'Penurunan F1 Rata-rata': float(np.mean(drops)),
        'Simpangan Baku': float(np.std(drops, ddof=1)),
        'Jumlah Ulangan': K_REPEATS,
    })
perm_importance_df = pd.DataFrame(permutation_rows).sort_values(
    'Penurunan F1 Rata-rata', ascending=False
).reset_index(drop=True)
perm_importance_df.insert(0, 'Peringkat', np.arange(1, len(perm_importance_df)+1))
```

Gambar 20. Screenshot kode permutation importance pada data validasi

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(3).ipynb, kode Section 11, baris 91-116.

9.4 Screenshot Pembuatan Paket SDK Static

Kode pada Section 13 menyiapkan keluaran JavaScript dan JSON, serta mekanisme pengujian antarlapisan sebelum paket diunggah. Karena hasil eksekusi Section 13 tidak tersimpan pada berkas yang diberikan, lampiran ini merupakan bukti *implementasi kode yang dirancang*, bukan bukti deployment yang sudah selesai.



Cuplikan kode aktual • Section 13 • baris 320-359

```
320       browser_probs = np.asarray(json.loads(lines[-1].split('=', 1)[1]), dtype=np.float64)
321       max_diff = float(np.max(np.abs(python_predictions - browser_probs)))
322       assert browser_probs.shape == python_predictions.shape
323       assert np.allclose(browser_probs, python_predictions, atol=2e-3, rtol=1e-3), (
324           f'Prediksi browser berbeda terlalu jauh dari Keras (maks: {max_diff}).'
325       )
326       assert np.array_equal(np.argmax(browser_probs, axis=1), np.argmax(python_predictions, axis=1)), (
327           'Label prediksi di browser tidak sama dengan prediksi Keras.'
328       )
329       print(f'Uji JavaScript vs Keras pada {len(probe_rows)} data uji: LULUS; '
330             f'selisih probabilitas maksimum {max_diff:.8f}.')
331   else:
332       print('Node.js tidak tersedia: kode JS lolos ekspor, tetapi perbandingan probabilitas '
333             'browser vs Keras perlu dijalankan di lingkungan dengan Node.js atau browser.')
334
335   # 7. Paket khusus Hugging Face Static: hanya berkas yang dibutuhkan browser.
336   static_files = [
337       'README.md', 'index.html', 'app.js', 'inference.js',
338       'model_browser.json', 'preprocessing_browser.json',
339       'feature_schema.json', 'class_labels.json',
340       'evaluation_results.json', 'tuning_hyperparameters.json',
341   ]
342   for filename in static_files:
343       assert (ARTIFACT_DIR / filename).is_file(), 'Artefak Static belum tersedia: '+filename
344   zip_path = Path('HuggingFace_Spaces_Kelompok4_Static_Final.zip')
345   with zipfile.ZipFile(zip_path, 'w', zipfile.ZIP_DEFLATED) as z:
346       for filename in static_files:
347           z.write(ARTIFACT_DIR / filename, arcname=filename)
348
349   artifact_files_df = pd.DataFrame([
350       {'File': name, 'Ukuran (KB)': round((ARTIFACT_DIR / name).stat().st_size / 1024, 2),
351        'SHA256': hashlib.sha256((ARTIFACT_DIR / name).read_bytes()).hexdigest()[:20]}
352       for name in static_files
353   ])
354   print('\n=== BERKAS DEPLOYMENT SDK STATIC ===')
355   display(artifact_files_df)
356   print('Paket ZIP:', zip_path.resolve(), '| ukuran KB:', round(zip_path.stat().st_size/1024, 2))
357   print('sdk: static; app_file: index.html. Hosting publik harus diuji setelah upload.')
```

Gambar 21. Screenshot kode pemeriksaan dan daftar berkas SDK Static

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(3).ipynb, kode Section 13, baris 320-359.

9.5 Daftar Grafik dan Tabel Pendukung

Grafik utama evaluasi sudah ditampilkan pada bagian EDA dan hasil pengujian, yaitu distribusi kelas, histogram numerik, matriks korelasi, ranking tuning, perbandingan akurasi, kurva accuracy dan loss, confusion matrix, grafik confidence/permutation importance, serta ablasi. Gambar-gambar tersebut diambil dari output notebook final yang disimpan bersama file .ipynb dan tidak direkonstruksi menggunakan angka hasil perkiraan.

DAFTAR PUSTAKA

1. anshsahu111, “Laptop Specifications and Prices Dataset,” Kaggle. https://www.kaggle.com/datasets/anshsahu111/laptop-specifications-and-prices-dataset
2. Google, “TensorFlow: An End-to-End Platform for Machine Learning,” TensorFlow. https://www.tensorflow.org/
3. Keras Team, “Keras: The Deep Learning API,” Keras. https://keras.io/
4. T. O’Malley et al., “KerasTuner,” 2019. https://keras.io/keras_tuner/
5. Scikit-learn Developers, “Common Pitfalls and Recommended Practices,” scikit-learn. https://scikit-learn.org/stable/common_pitfalls.html
6. Scikit-learn Developers, “StandardScaler,” scikit-learn. https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.StandardScaler.html
7. Scikit-learn Developers, “OneHotEncoder,” scikit-learn. https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.OneHotEncoder.html
8. Keras Team, “EarlyStopping,” Keras. https://keras.io/api/callbacks/early_stopping/
9. Keras Team, “ReduceLROnPlateau,” Keras. https://keras.io/api/callbacks/reduce_lr_on_plateau/
10. Hugging Face, “Static HTML Spaces,” Hugging Face Docs. https://huggingface.co/docs/hub/spaces-sdks-static
11. Kelompok 4, “UTS-DEEP-LEARNING: Klasifikasi Kelas Harga Laptop Menggunakan MLP dengan Hyperparameter Tuning,” GitHub, 2026. https://github.com/x-kzy/UTS-DEEP-LEARNING
12. Kelompok 4, “LAPTOP-CLASSIFIER,” Hugging Face Spaces, 2026. https://huggingface.co/spaces/Xkazuya/LAPTOP-CLASSIFIER

TAUTAN LENGKAP PROYEK UTS

Bagian ini menyajikan tautan ke folder proyek dalam repository, repository utama, source notebook Google Colab, dataset Kaggle, serta website deployment Hugging Face, link video demo dan presentasi.

Tabel 22. Tautan publik proyek UTS Kelompok 4

Artefak	Tautan publik / status
Folder Onedrive Proyek	UTS - KELOMPOK 4 (DEEP LEARNING)
Repository Github Proyek UTS	https://github.com/x-kzy/UTS-DEEP-LEARNING
Notebook Google Colab (Source Code Model)	https://colab.research.google.com/drive/15Rw6EE2y7_UPxA60y1rCgyraN7wlydfl?usp=sharing
Dataset Kaggle	https://www.kaggle.com/datasets/anshsahu111/laptop-specifications-and-prices-dataset
Source Antarmuka SDK Static	https://github.com/x-kzy/UTS-DEEP-LEARNING/tree/main/web_static
Website LAPTOP-CLASSIFIER	https://huggingface.co/spaces/Xkazuya/LAPTOP-CLASSIFIER
Video Demo Website	https://youtu.be/_uKiwS9hGos?si=8sMoF8P6pyxENQDa
Video Demo Dan Penjelasan Proyek	https://www.youtube.com/watch?v=wBwoF_4HqoA