LAPORAN UTS
MACHINE LEARNING
DETEKSI ANOMALI PADA DATA SENSOR DAN KONDISI MESIN INDUSTRI MENGGUNAKAN DATASET METROPT-3

Dosen Pengampu: Dr. Al Hamidy Hazidar, S.Kom., M.I.T.

Mata Kuliah: Machine learning

Kelompok: 5

Project ID: B10

Disusun oleh:

Havidz Andrian

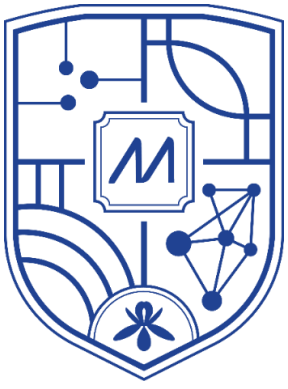
231111899

Fikri Anwar

231112145

Purba Tua Siregar

231112463



PROGRAM STUDI S-1 TEKNIK INFORMATIKA

FAKULTAS INFORMATIKA

UNIVERSITAS MIKROSKIL

MEDAN

2026

RINGKASAN PROYEK

Pada Proyek B10 ini, kami membangun sistem deteksi anomali untuk memantau kondisi mesin Air Production Unit (APU) menggunakan *dataset* sensor MetroPT-3. Karena data CSV dari sumbernya tidak memiliki label kerusakan di setiap baris waktu, kami menggunakan metode pendekatan *unsupervised learning*. Sistem menghasilkan skor anomali untuk setiap jendela lima menit. Alarm aktif setelah skor melampaui ambang pada tiga jendela berturut-turut, dan hitungan persistensi direset ketika terdapat jeda waktu. Hasil deteksi tersebut kemudian kami cocokkan dengan empat jadwal gangguan mesin yang tercatat pada laporan dokumentasi sumber.

Dari total 1.516.948 baris data mentah yang berasal dari 15 sensor, kami mengelompokkannya menjadi 50.276 jendela waktu (*time window*) berdurasi lima menit untuk keperluan eksperimen. Kami menguji dan membandingkan tiga model, yaitu K-Means, PCA + K-Means, dan Isolation Forest. Agar pengujiannya adil dan bebas dari kebocoran data (*data leakage*), proses pembelajaran fitur dilakukan pada data *training*, penentuan batas ambang alarm (persentil ke-99/P99) dihitung pada data kalibrasi, dan pemilihan model terbaik didasarkan pada data validasi berdasarkan urutan waktu. Dari tahap validasi tersebut, K-Means terpilih sebagai model utama dengan nilai *Average Precision* (AP) sebesar 0,2974. Saat diuji pada periode *benchmark*, K-Means berhasil mencapai AP 0,8685, *precision* 0,3362, *recall* 0,9872, dan F1-*score* 0,5016. Model ini mampu mendeteksi kedua periode gangguan yang ada pada data *benchmark*, meskipun masih terdapat 8 jendela waktu saat gangguan yang terlewat tanpa alarm, serta 1.218 jendela alarm yang menyala di luar jadwal laporan gangguan.

Secara keseluruhan, eksperimen awal ini membuktikan bahwa alur deteksi dan perbandingan metode *classical machine learning* yang kami rancang sudah berjalan dengan baik. Namun, sistem ini belum bisa langsung diklaim siap pakai untuk skala industri atau dijadikan sistem peringatan dini (*early warning*). Hal ini dikarenakan catatan laporan gangguan dari sumber datanya masih terbatas, rekaman hanya berasal dari satu unit kompresor, dan data *benchmark* sudah sempat diamati pada iterasi *notebook* sebelumnya. Oleh karena itu, fokus pengembangan kami menuju UAS nanti adalah memverifikasi ulang label pembanding, mengevaluasi kontribusi tiap fitur, menekan jumlah alarm palsu/berlebih, menguji algoritma kandidat tambahan, serta memastikan seluruh kode eksperimen mudah direproduksi.

Link Google Colab UTS [B10] **:** Source Code

Link Repository UTS [B10] **:** https://github.com/x-kzy/UTS-Machine-Learning

DAFTAR ISI

RINGKASAN PROYEK 1

BAB I PENDAHULUAN DAN FORMULASI MASALAH 6

1.1 *Problem Formulation*: Latar Belakang dan Urgensi Masalah 6

1.2 Rumusan Masalah 6

1.3 Tujuan Proyek 6

1.4 Manfaat dan Hasil 7

1.5 Ruang Lingkup dan Asumsi 7

BAB II PEMAHAMAN *DATASET* DAN ANALISIS EKSPLORATIF 8

2.1 *Dataset and Data Understanding*: Sumber dan Unit Observasi 8

2.2 Struktur dan Kamus Sensor 9

2.3 Audit Kualitas Data 10

2.4 *EDA and Initial Findings*: Statistik dan Distribusi Sensor *Training* 10

2.5 Korelasi dan Kondisi Digital 11

2.6 Temuan Awal dan Implikasi Pengolahan 13

BAB III METODOLOGI DAN RANCANGAN EVALUASI 14

3.1 Alur Eksperimen dan Pembagian Waktu 14

3.2 *Preprocessing*: Agregasi Kausal dan Kelayakan Jendela 15

3.3 *Pipeline Preprocessing* dan Pencegahan *Data leakage* 15

3.4 *Initial Feature Engineering*: Rekayasa Fitur Awal 16

3.5 *Baseline and Initial Candidate Models*: Model Pembanding Awal 16

3.6 Kalibrasi Ambang dan Alarm Persisten 17

3.7 *Evaluation Design*: Strategi Validasi dan Pemilihan Kandidat 18

3.8 Pembanding Laporan dan Metrik Evaluasi 18

BAB IV HASIL EKSPERIMEN AWAL DAN PEMBAHASAN 20

4.1 Eksperimen Jumlah *Cluster* dan Profil Operasi 20

4.2 Reduksi Dimensi dan Kalibrasi Kandidat 21

4.3 Kestabilan Lima *Fold* Temporal 22
4.4 *Initial Results and Analysis*: Pembandingan Kandidat pada Validasi 23
4.5 *Ablation* Fitur dan Sensitivitas Alarm 24
4.6 Hasil *Benchmark* dengan Konfigurasi Beku 25
4.7 Cakupan Laporan dan Waktu Deteksi 28
4.8 Diagnosis Kesalahan dan Pergeseran Distribusi 29
4.9 Proses Inferensi dan Pemeriksaan Integritas 30
4.10 Keterbatasan Eksperimen Awal 31
BAB V KESIMPULAN DAN RENCANA PENGEMBANGAN 32
5.1 Kesimpulan dan Capaian Milestone 1 32
5.2 *Documentation and Next Plan*: Rencana Pengembangan Untuk UAS 34
5.3 Keterkaitan Rencana dengan Materi Setelah UTS 35
5.4 Kontribusi Anggota 36
DAFTAR PUSTAKA 37
LAMPIRAN 39

DAFTAR TABEL

Tabel 2. 1 Identitas dan ukuran data yang dibaca 8
Tabel 2. 2 Variabel sensor dan maknanya 9
Tabel 2. 3 Statistik sensor analog pada *training* 10
Tabel 3. 1 Pembagian temporal dan jumlah jendela terpakai 14
Tabel 3. 2 Audit kelayakan jendela per bagian 15
Tabel 3. 3 Kelompok fitur dan alasan pembentukan 16
Tabel 3. 4 Konfigurasi model awal 17
Tabel 3. 5 Empat interval laporan kebocoran udara 18
Tabel 3. 6 Metrik dan alasan penggunaannya 19
Tabel 4. 1 Diagnostik K-Means pada ruang *training* yang sama 20
Tabel 4. 2 Profil *cluster baseline* dalam satuan asli 21
Tabel 4. 3 Dimensi dan ambang hasil kalibrasi 22
Tabel 4. 4 Jumlah jendela setiap *fold* referensi 22
Tabel 4. 5 Rerata dan simpangan baku respons lima *fold* 22
Tabel 4. 6 Evaluasi validasi temporal Maret sampai Mei 23
Tabel 4. 7 *Ablation* paket tiga fitur rekayasa pada validasi 24
Tabel 4. 8 Sensitivitas kuantil dan persistensi pada validasi 25
Tabel 4. 9 Evaluasi *benchmark* pada jendela yang sama 25
Tabel 4. 10 Beban alarm dan deteksi kejadian pada *benchmark* 27
Tabel 4. 11 Cakupan kualitas jendela pada interval laporan 28
Tabel 4. 12 Alarm pertama K-Means pada *benchmark* 28
Tabel 4. 13 Pemeriksaan konsistensi implementasi 30
Tabel 5. 1 Ringkasan ketercapaian tujuan 33
Tabel 5. 2 Rencana pengembangan mengikuti kontrak perkuliahan 35

DAFTAR GAMBAR

Gambar 2. 1 Distribusi sensor analog pada periode *training* 11
Gambar 2. 2 Korelasi sensor analog pada *training* 11
Gambar 2. 3 Hubungan tekanan serta mode arus motor dan suhu oli 12
Gambar 2. 4 Proporsi status digital pada *training* 12
Gambar 3. 1 Pembagian temporal dan posisi empat interval laporan gangguan 14
Gambar 4. 1 *Elbow* dan *silhouette* untuk K=2 sampai K=6 20
Gambar 4. 2 Proporsi varians tiap komponen dan varians kumulatif PCA 21
Gambar 4. 3 Kurva *precision recall* pada validasi temporal 24
Gambar 4. 4 *Confusion matrix proxy* K-Means pada *benchmark* 26
Gambar 4. 5 Timeline sensor dan skor relatif pada *benchmark* 27
Gambar 4. 6 Skor dan alarm K-Means di sekitar F03 dan F04 29

BAB I
PENDAHULUAN DAN FORMULASI MASALAH

1.1 *Problem Formulation*: Latar Belakang dan Urgensi Masalah

Air Production Unit (APU) memasok udara bertekanan untuk sistem pneumatik kereta. Perubahan tekanan, suhu oli, arus motor, dan status katup dapat memberikan informasi mengenai perubahan kondisi operasi. Pemantauan beberapa sensor secara bersama diperlukan karena penyimpangan tidak selalu dapat dijelaskan oleh satu nilai sensor yang melewati batas tetap.

Dataset MetroPT-3 menyediakan rekaman sensor APU beserta interval gangguan kebocoran udara dalam dokumentasi sumber. Data berbentuk deret waktu dengan kondisi operasi yang beragam, sedangkan CSV tidak memiliki label kerusakan pada setiap baris. Oleh sebab itu, proyek menggunakan *classical machine learning* tanpa pengawasan untuk mempelajari pola referensi dan memberi skor pada penyimpangan multivariat.

Milestone 1 difokuskan pada perumusan masalah, pemahaman data, pembentukan fitur, pembangunan *baseline*, pembandingan kandidat, dan evaluasi awal yang dapat ditelusuri. Deteksi yang dihasilkan merupakan indikasi penyimpangan untuk pemeriksaan lebih lanjut; penetapan penyebab kerusakan dan keputusan pemeliharaan belum menjadi keluaran yang terbukti.

1.2 Rumusan Masalah

Fokus utama permasalahan dalam proyek ini mencakup pembentukan alur deteksi penyimpangan multivariat pada sensor APU berdasarkan pola operasi periode referensi, perbandingan model K-Means, PCA + K-Means, serta Isolation Forest pada pembagian waktu yang sama, dan penilaian kesesuaian antara skor maupun alarm deteksi terhadap interval gangguan yang dilaporkan.

1.3 Tujuan Proyek

1. Mengaudit sumber, struktur, kualitas, dan karakteristik data sensor MetroPT-3.
2. Mengidentifikasi temuan EDA dan menghubungkannya dengan keputusan *Preprocessing*.
3. Membentuk fitur jendela lima menit secara kausal serta mengendalikan risiko *data leakage*.
4. Menghasilkan skor anomali dan alarm persisten melalui *baseline* dan kandidat *classical machine learning*.

5. Membandingkan model menggunakan validasi temporal, metrik pemeringkatan, metrik alarm, dan evaluasi interval.
6. Mendokumentasikan hasil, keterbatasan, reproduksi, dan rencana pengembangan menuju UAS.

1.4 Manfaat dan Hasil

Manfaat akademis proyek adalah menyediakan contoh penerapan alur *machine learning* pada data sensor berurutan, termasuk pembandingan representasi fitur dan pemisahan peran data. Manfaat praktis yang dituju adalah menyediakan indikasi penyimpangan untuk membantu peninjauan kondisi kompresor, tanpa menggantikan penilaian teknisi.

Hasil Milestone 1 meliputi *notebook* berisi kode dan hasil, audit *dataset*, fitur awal, tiga *Pipeline* kandidat, tabel evaluasi, visualisasi, contoh inferensi, dan rencana UAS. Keberhasilan tahap ini dinilai dari tersedianya alur serta bukti yang konsisten, bukan dari kewajiban mencapai nilai metrik tertentu.

1.5 Ruang Lingkup dan Asumsi

Data yang digunakan adalah MetroPT-3 versi CSV UCI pada rentang aktual 1 Februari sampai 1 September 2020. Unit pemodelan ialah jendela lima menit tidak bertumpang tindih. Eksperimen menggunakan K-*Mean*s, PCA + K-*Mean*s, dan *Isolation Forest*; *neural network*, *deep learning*, serta pembuatan target dari nomor *cluster* tidak digunakan.

Februari awal menjadi periode referensi *training*, Februari akhir menjadi kalibrasi, Maret-Mei menjadi validasi, dan Juni-akhir menjadi *benchmark*. Tidak adanya laporan pada *training* tidak membuktikan seluruh data sehat. Empat interval laporan dipakai sebagai pembanding evaluasi yang lemah, bukan sebagai label untuk melatih model. *Dataset* atau masalah tidak diganti hanya karena hasil awal kurang baik; perubahan yang diperlukan harus mengikuti persetujuan dosen.

Pemetaan komponen A-I ditampilkan melalui penamaan subbab utama: komponen A tercakup dalam Bab I, B-C dalam Bab II, D-G dalam Bab III, H dalam Bab IV, dan I dalam Bab V. Tabel L1 pada lampiran memuat lokasi setiap komponen beserta jejak *section notebook* yang relevan.

BAB II
PEMAHAMAN *DATASET* DAN ANALISIS EKSPLORATIF

2.1 *Dataset and Data Understanding*: Sumber dan Unit Observasi

Dataset diperoleh dari UCI *Machine learning* Repository dengan identitas 791 dan DOI 10.24432/C5VW3R. Lisensinya CC BY 4.0, sehingga atribusi sumber wajib dipertahankan. *Notebook* dapat membaca CSV atau ZIP lokal; jika sumber lokal tidak ditemukan, *notebook* mengunduh ZIP resmi UCI. *Run* yang dilaporkan menggunakan jalur unduhan resmi karena sumber lokal tidak ditemukan.

Satu baris mentah merepresentasikan pembacaan 15 sensor pada satu *timestamp*. CSV mempunyai 17 kolom, termasuk *timestamp* dan ID baris. Setelah agregasi, satu baris pemodelan merepresentasikan ringkasan sensor dalam satu jendela. *Timestamp* digunakan untuk urutan, pembagian data, dan pencocokan laporan; *timestamp* dan ID tidak dijadikan fitur *estimator*.

Tabel 2. 1 Identitas dan ukuran data yang dibaca

Atribut	Hasil
Sumber	UCI MetroPT-3, ID 791
Berkas CSV	MetroPT3(AirCompressor).csv
Observasi mentah	1.516.948
Kolom CSV	17, termasuk waktu dan ID
Sensor	15: 7 analog dan 8 digital
Awal data	1 Februari 2020 pukul 00.00.00
Akhir data	1 September 2020 pukul 03.59.50
Median interval sampel	10 detik
Target per baris	Tidak tersedia dalam CSV

Sumber: *UTS_Data Sensor dan Kondisi Mesin Industri (B10)_Kelompok5.ipynb*, *Section* 2.

Dokumentasi asal menyebut 15.169.480 observasi pada 1 Hz, sedangkan CSV yang dibaca berisi 1.516.948 observasi dengan median interval 10 detik. Laporan ini mengikuti ukuran dan resolusi aktual CSV. Artikel MetroPT tahun 2022 dipakai untuk konteks dan

atribusi penelitian, bukan untuk mengganti ukuran, periode, atau fitur versi MetroPT-3 yang dianalisis.

2.2 Struktur dan Kamus Sensor

Tujuh sensor analog memuat besaran fisik, sedangkan delapan sensor digital dibaca sebagai sinyal biner. Nilai rata-rata sinyal digital setelah agregasi diartikan sebagai proporsi aktif. Khusus Caudal_impulses, proporsi tersebut tidak ditafsirkan sebagai volume udara.

Tabel 2. 2 Variabel sensor dan maknanya

Sensor	Jenis dan satuan	Makna
TP2	Analog, bar	Tekanan kompresor
TP3	Analog, bar	Tekanan panel pneumatik
H1	Analog, bar	Tekanan terkait separator siklon
DV_pressure	Analog, bar	Tekanan terkait pembuangan pengering udara
Reservoirs	Analog, bar	Tekanan reservoir
Oil_temperature	Analog, °C	Suhu oli kompresor
Motor_current	Analog, A	Arus salah satu fase motor
COMP	Digital, 0/1	Sinyal katup *intake*
DV_eletric	Digital, 0/1	Sinyal katup *outlet*; ejaan sesuai CSV
Towers	Digital, 0/1	Status tower pengering
MPG	Digital, 0/1	Sinyal pengaktifan kompresor
LPS	Digital, 0/1	Sinyal tekanan rendah
Pressure_switch	Digital, 0/1	Sinyal *pressure switch*
Oil_level	Digital, 0/1	Sinyal level oli
Caudal_impulses	Digital, 0/1	Sinyal impuls aliran udara

Sumber: *UTS_Data Sensor dan Kondisi Mesin Industri (B10)_Kelompok5.ipynb*, *Section* 2.

2.3 Audit Kualitas Data

Audit menghasilkan nol *timestamp invalid*, nol *timestamp* duplikat, dan nol nilai sensor hilang setelah pemeriksaan. Terdapat 57.475 vektor sensor berulang pada *timestamp* berbeda. Vektor ini dipertahankan karena kondisi operasi yang sama pada waktu berbeda tetap merupakan observasi sah. Kebersihan nilai tidak berarti perekaman kontinu, sehingga jeda dan kelengkapan jendela tetap diperiksa.

Aturan pengolahan menghapus *timestamp invalid*, mengurutkan waktu, dan mempertahankan rekaman terakhir jika *timestamp* ganda ditemukan. Nilai *infinity* dan digital di luar 0/1 diperlakukan sebagai NaN dan dicatat. Aturan tersebut merupakan mekanisme pengendalian kualitas; tidak dinyatakan seluruh masalah tersebut terjadi pada data yang dibaca. Zona waktu sumber tidak diasumsikan maupun dikonversi.

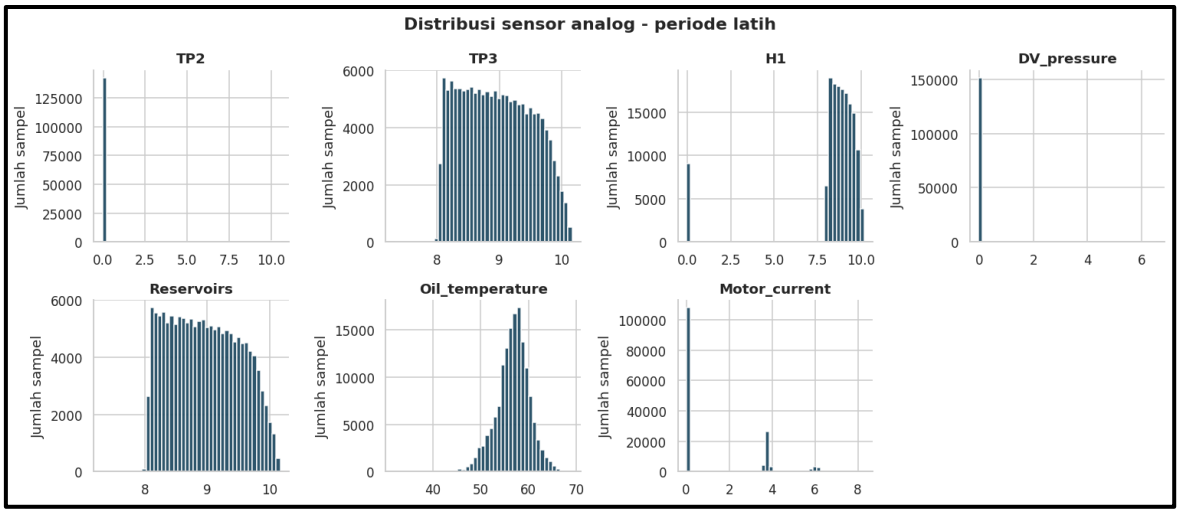
2.4 *EDA and Initial Findings*: Statistik dan Distribusi Sensor *Training*

EDA distribusi dilakukan pada data *training* agar pemahaman pola referensi tidak diarahkan oleh *benchmark*. Statistik memperlihatkan perbedaan skala antarsensor dan sebaran yang tidak selalu simetris. Arus motor memuat beberapa mode operasi, sehingga nilai ekstrem harus dibaca bersama konteks beban mesin.

Tabel 2. 3 Statistik sensor analog pada *training*

Sensor	Rerata	Simpangan baku	Minimum	Maksimum
TP2	0,5359	2,1938	-0,030	10,544
TP3	8,9636	0,5554	7,324	10,164
H1	8,4010	2,1981	-0,030	10,158
DV_pressure	-0,0155	0,1010	-0,028	6,530
Reservoirs	8,9659	0,5548	7,326	10,168
Oil_temperature	56,7739	3,4786	31,975	69,150
Motor_current	1,2412	1,9578	0,020	8,2925

Sumber: *UTS_Data Sensor dan Kondisi Mesin Industri (B10)_Kelompok5.ipynb*, *Section* 4.

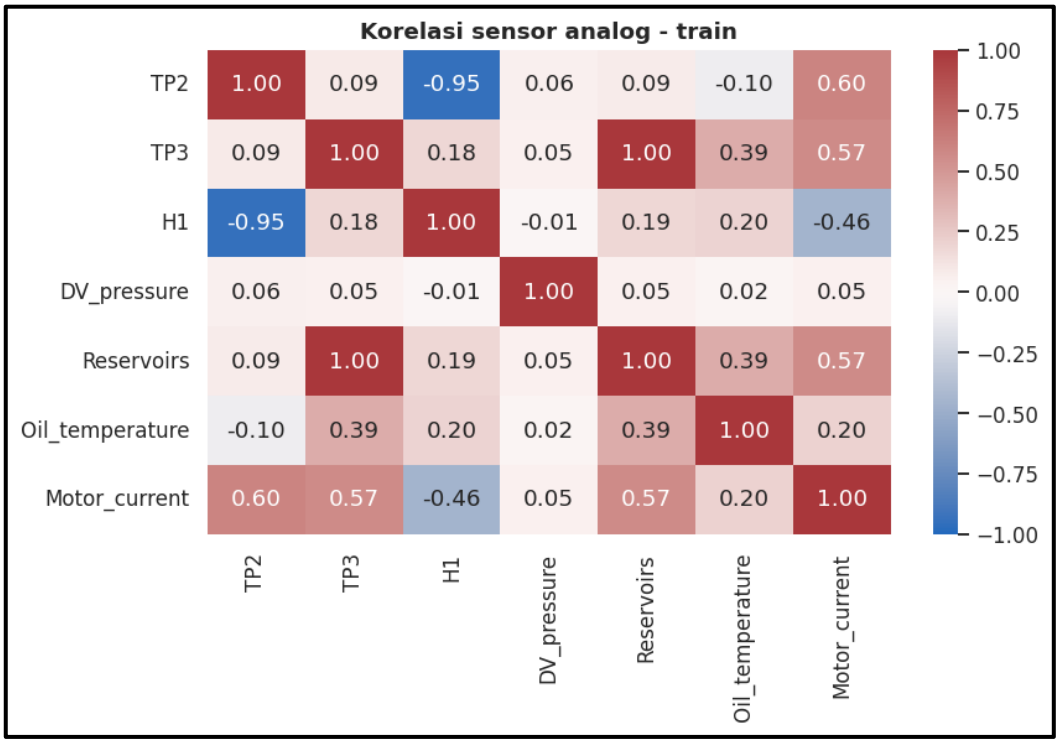


Gambar 2. 1 Distribusi sensor analog pada periode *training*

Sumber: *UTS_Data Sensor dan Kondisi Mesin Industri (B10)_Kelompok5.ipynb*, *Section* 4.

TP2 memiliki median sekitar -0,012 bar dan ekor distribusi hingga 10,544 bar. Suhu oli memiliki rerata 56,7739 °C, sedangkan arus motor memiliki rerata 1,2412 A dengan beberapa puncak distribusi. Perbedaan rentang ini mendukung penggunaan standardisasi sebelum model berbasis jarak. Standardisasi mengubah skala fitur, bukan menghapus nilai ekstrem.

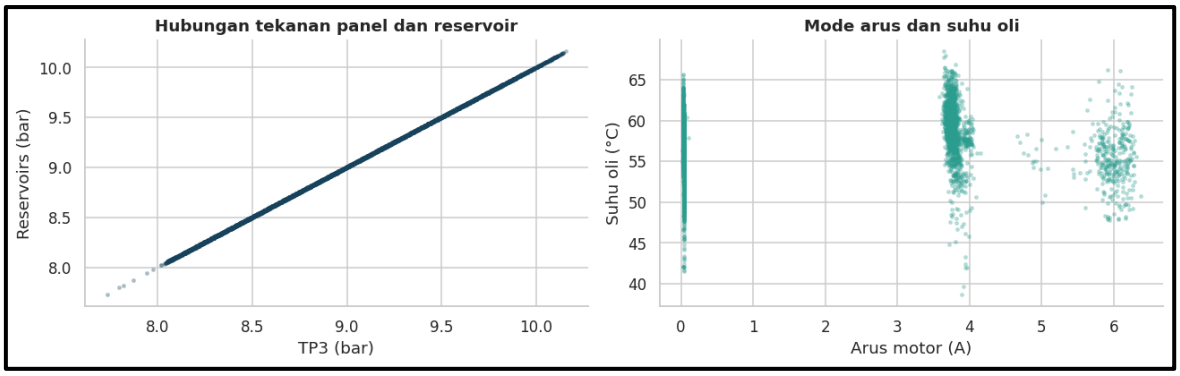
2.5 Korelasi dan Kondisi Digital



Gambar 2. 2 Korelasi sensor analog pada *training*

Sumber: *UTS_Data Sensor dan Kondisi Mesin Industri (B10)_Kelompok5.ipynb*, *Section* 4.

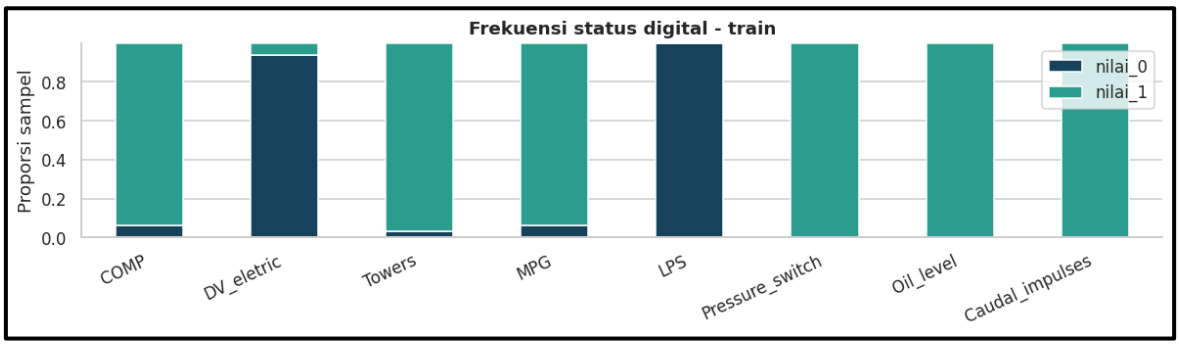
Korelasi TP3 dan Reservoirs pada *training* sebesar 0,999991 menunjukkan dua sensor tekanan merekam informasi yang hampir sama pada periode tersebut. Temuan ini menjadi alasan pembentukan selisih tekanan dan pengujian PCA. Korelasi tinggi tidak membuktikan kedua sensor identik secara fisik atau dapat saling menggantikan di semua kondisi.



Gambar 2. 3 Hubungan tekanan serta mode arus motor dan suhu oli

Sumber: *UTS_Data Sensor dan Kondisi Mesin Industri (B10)_Kelompok5.ipynb*, *Section* 4.

Diagram pencar TP3-Reservoirs menunjukkan pola hubungan linear yang sangat rapat, sedangkan hubungan arus motor dan suhu oli memperlihatkan beberapa kelompok kondisi operasi.. Hal tersebut mendukung interpretasi *cluster* sebagai profil operasi relatif. *Cluster* yang kecil tidak langsung diberi label rusak.



Gambar 2. 4 Proporsi status digital pada *training*

Sumber: *UTS_Data Sensor dan Kondisi Mesin Industri (B10)_Kelompok5.ipynb*, *Section* 4.

Oil_level dan Caudal_impulses konstan pada data mentah *training*. LPS mempunyai satu sampel aktif, tetapi fitur *duty* LPS menjadi konstan setelah seleksi jendela *training* yang layak. Karena itu, pemeriksaan konstansi pada data mentah dan pada matriks fitur tidak disamakan.

2.6 Temuan Awal dan Implikasi Pengolahan

Lima temuan utama ialah perbedaan skala sensor, korelasi tekanan yang sangat kuat, kondisi digital yang jarang berubah, nilai ekstrem yang dapat mewakili mode operasi, dan waktu perekaman yang tidak sepenuhnya teratur. StandardScaler digunakan untuk skala; PCA dan fitur selisih tekanan diuji untuk redundansi; filter konstan dipelajari pada *training*; nilai ekstrem dipertahankan; dan jendela tidak lengkap dikeluarkan secara eksplisit.

Pemeriksaan IQR menandai 31.624 nilai analog pada *training*, yaitu jumlah indikasi nilai pada sensor, bukan jumlah baris unik. Temuan ini tidak digunakan untuk menghapus atau melakukan *capping* otomatis. Menghapus ekor distribusi tanpa verifikasi berisiko menghilangkan sinyal yang justru ingin dideteksi.

BAB III
METODOLOGI DAN RANCANGAN EVALUASI

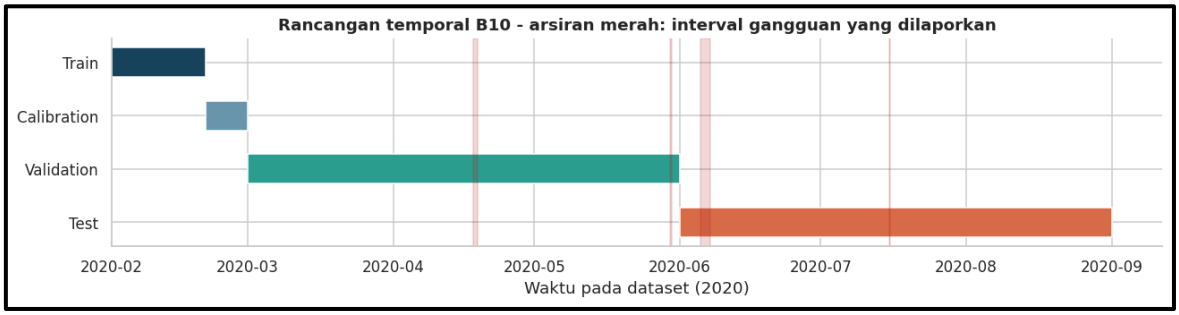
3.1 Alur Eksperimen dan Pembagian Waktu

Alur eksperimen mencakup akuisisi dan audit, agregasi kausal, pemisahan matriks fitur, fit *Pipeline*, kalibrasi ambang, pemilihan kandidat pada validasi, pembekuan konfigurasi, evaluasi *benchmark*, dan diagnosis hasil. Pembagian dilakukan menurut waktu agar data masa depan tidak menjadi sumber statistik *training*.

Tabel 3. 1 Pembagian temporal dan jumlah jendela terpakai

Bagian	Awal jendela	Batas akhir	Terpakai
Training	01-02-2020 00.00	21-02-2020 00.00	4.982
Kalibrasi	21-02-2020 00.05	01-03-2020 00.00	2.093
Validasi	01-03-2020 00.05	01-06-2020 00.00	21.286
Benchmark	01-06-2020 00.05	01-09-2020 04.00	21.915

Sumber: *UTS_Data Sensor dan Kondisi Mesin Industri (B10)_Kelompok5.ipynb*, *Section* 3 dan 5.



Gambar 3. 1 Pembagian temporal dan posisi empat interval laporan gangguan

Sumber: *UTS_Data Sensor dan Kondisi Mesin Industri (B10)_Kelompok5.ipynb*, *Section* 3.

Awal jendela pada tabel menyatakan batas kiri. Keputusan tersedia di akhir jendela, bukan pada awalnya. Satu jendela lima menit menjadi *embargo* pada tiap pergantian bagian. *Embargo* mengurangi kedekatan langsung antarbatas, tetapi tidak menghilangkan seluruh autokorelasi. Periode Juni-akhir disebut *benchmark* yang diuji ulang karena telah diperiksa pada versi *notebook* terdahulu.

3.2 *Preprocessing*: Agregasi Kausal dan Kelayakan Jendela

Agregasi menggunakan interval [awal, akhir), tidak bertumpang tindih, dan diberi indeks waktu akhir. Fitur hanya memakai sampel dalam jendela yang telah selesai. Pada akhir berkas, data dianggap tersedia satu *cadence training* setelah sampel terakhir; asumsi ini memungkinkan pemeriksaan jendela terakhir dan dicatat dalam implementasi.

Jendela dinyatakan layak jika mempunyai sedikitnya 20 sampel, jeda internal serta jeda kiri dan kanan tidak melebihi 60 detik, proporsi nilai hilang maksimum pada setiap sensor tidak melebihi 10%, dan jendela sudah selesai. *Cadence* acuan berasal dari median interval *training*, yaitu 10 detik. Aturan kualitas ditetapkan sebagai protokol, bukan dipilih berdasarkan skor *benchmark*.

Tabel 3. 2 Audit kelayakan jendela per bagian

Bagian	Seluruh jendela	Gagal kualitas	Terpakai
Training	5.760	778	4.982
Kalibrasi	2.591	498	2.093
Validasi	26.495	5.209	21.286
Benchmark	26.543	4.628	21.915

Sumber: *UTS_Data Sensor dan Kondisi Mesin Industri (B10)_Kelompok5.ipynb*, *Section* 5.

Total jendela terpakai pada empat bagian adalah 50.276. Tiga jendela *embargo* tidak dimasukkan ke eksperimen, termasuk satu yang lolos aturan kualitas. Satu jendela dapat melanggar beberapa aturan, sehingga jumlah alasan eksklusi tidak dijumlahkan sebagai jumlah unik jendela yang dibuang. Perubahan dari observasi mentah menjadi jendela merupakan perubahan unit analisis, bukan seluruhnya kehilangan data.

3.3 *Pipeline Preprocessing* dan Pencegahan *Data leakage*

Pipeline terdiri atas Simple*Imputer* median dengan keep_empty_features=True, *Variance*Threshold dengan threshold=0, StandardScaler, PCA jika digunakan, lalu *estimator*. *Imputer* tetap disediakan untuk fitur yang mungkin memiliki nilai kosong, meskipun audit sensor mentah tidak menemukan *missing values*. Median, daftar fitur konstan, rerata dan skala, komponen PCA, serta parameter *estimator* dipelajari hanya dari *training* atau *fold-training*.

Data kalibrasi hanya menghasilkan ambang skor, validasi menjadi dasar pembandingan dan diagnosis, sedangkan *benchmark* digunakan setelah konfigurasi

dibekukan. Label y_report dan event_number dipisahkan dari matriks fitur dan tidak diberikan ke fit. Hash *Pipeline* dan nilai ambang diperiksa kembali sebelum evaluasi. Audit kualitas global tidak digunakan untuk mempelajari transformasi atau memilih model.

StandardScaler menerapkan z = (x - rerata *training*) / simpangan baku *training*. Filter konstan membuang Caudal_impulses__*duty*, LPS__*duty*, dan Oil_level__*duty*. Ketiganya berubah pada validasi, sehingga filter menciptakan keterbatasan pada sinyal yang tidak bervariasi di referensi. Pembuangan fitur ini tidak berarti sensor tersebut tidak penting secara fisik.

3.4 *Initial Feature Engineering*: Rekayasa Fitur Awal

Tabel 3. 3 Kelompok fitur dan alasan pembentukan

Kelompok	Jumlah	Definisi dan tujuan
Statistik analog	14	*Mean* dan *sample std* (ddof=1) untuk 7 sensor; menangkap level dan variasi.
Duty digital	8	*Mean* sinyal 0/1; menangkap proporsi aktif dalam jendela.
pressure_gap_*mean*	1	*Mean*(TP3 - Reservoirs); mengukur perbedaan tekanan panel dan reservoir.
motor_load_fraction	1	Proporsi Motor_current >= 6 A; heuristik kondisi berbeban.
oil_temperature_range	1	Maksimum - minimum suhu oli; menangkap rentang perubahan dalam jendela.

Sumber: *UTS_Data Sensor dan Kondisi Mesin Industri (B10)_Kelompok5.ipynb*, *Section* 5.

Batas 6 A merupakan penemuan di antara mode arus sekitar 4 A dan 7 A dalam dokumentasi sumber, bukan label beban yang telah diverifikasi teknisi. Ketiga fitur tambahan diuji sebagai satu paket melalui *ablation*. Fitur *rolling* atau *lag* belum digunakan dalam eksperimen UTS ini.

3.5 *Baseline and Initial Candidate Models*: Model Pembanding Awal

K-Means K=3 menjadi *baseline* karena sederhana, dapat menjelaskan profil operasi melalui *centroid*, dan menghasilkan skor jarak yang dapat ditafsirkan. Skornya adalah jarak Euclidean kuadrat ke *centroid* terdekat setelah *Preprocessing*: s(x) = min_k ||z(x) -

*centroid*_k||². Skor lebih tinggi berarti lebih menyimpang dari pola referensi, bukan probabilitas kerusakan.

PCA + K-Means menggunakan StandardScaler sebelum PCA dan mempertahankan sekurang-kurangnya 95% varians *training*. Kandidat ini menguji manfaat reduksi redundansi, tetapi arah dengan varians kecil yang penting untuk anomali dapat terbuang. *Isolation Forest* menjadi pembanding *ensemble* pohon yang mengisolasi observasi melalui partisi acak; skor dibalik dari score_samples agar arah penyimpangan konsisten.

Tabel 3. 4 Konfigurasi model awal

Model	Konfigurasi utama	Peran
K-Means	K=3; k-means++; n_init=10; max_iter=300; *seed*=42	*Baseline*
PCA + K-Means	PCA 95%; svd_solver=full; konfigurasi K-Means sama	Kandidat representasi
Isolation Forest	200 pohon; max_samples=256; *contamination*=auto; *bootstrap*=False; *seed*=42	Kandidat *ensemble*

Sumber: *UTS_Data Sensor dan Kondisi Mesin Industri (B10)_Kelompok5.ipynb*, *Section* 6 dan 8.

Kontrol tanpa alarm menggunakan skor konstan nol dan tidak menghasilkan alarm. Kontrol tersebut menunjukkan perilaku pembanding paling sederhana dan dampak ketimpangan label. Nilai *contamination*=auto pada *Isolation Forest* tidak dipakai sebagai ambang alarm; seluruh kandidat menggunakan kalibrasi P99 yang terpisah.

3.6 Kalibrasi Ambang dan Alarm Persisten

Ambang tiap model adalah kuantil 0,99 skor kalibrasi dengan metode *higher*. Pelampauan dinyatakan jika skor lebih besar dari ambang, kemudian alarm baru aktif setelah tiga jendela pelampauan yang berurutan. Persistensi direset saat pelampauan bernilai nol, ada jeda waktu, atau bagian data baru dimulai. Jendela yang tidak layak tidak dianggap sebagai bukti kondisi normal.

P99 menyatakan asumsi tingkat pelampauan pada referensi, bukan jaminan *false positive rate* 1% pada periode berikutnya. Tiga jendela mewakili aturan keberlanjutan

sinyal pada unit lima menit, tetapi tidak menjamin keterlambatan tepat 15 menit dari awal laporan; rangkaian pelampauan dapat sudah dimulai sebelum interval laporan.

3.7 *Evaluation Design*: Strategi Validasi dan Pemilihan Kandidat

Validasi mempunyai dua fungsi yang dibedakan. Pertama, lima *fold expanding window* pada grid referensi Februari memeriksa kestabilan respons. TimeSeries*Split* menggunakan gap satu jendela. Pada bagian masa lalu setiap *fold*, sekitar 80% bagian awal menjadi fit dan sisanya menjadi kalibrasi, disertai jeda; kualitas jendela diperiksa pada tiap bagian. Kedua, *hold-out* temporal Maret-Mei membandingkan skor dengan interval laporan.

Metrik utama pemilihan adalah Average *Precision* (AP) *proxy* validasi, dengan *tie-break* berurutan berupa *recall* kejadian, F1, lalu nama model. *Fold* referensi tanpa laporan tidak digunakan untuk mengklaim *recall* gangguan atau AP deteksi. Karena *fold* berbagi riwayat *training*, simpangan baku antar*fold* bersifat deskriptif dan bukan ketidakpastian dari sampel independen.

3.8 Pembanding Laporan dan Metrik Evaluasi

Tabel 3. 5 Empat interval laporan kebocoran udara

ID internal	Awal laporan	Akhir laporan	Bagian
F01	18-04-2020 00.00	18-04-2020 23.59	Validasi
F02	29-05-2020 23.30	30-05-2020 06.00	Validasi
F03	05-06-2020 10.00	07-06-2020 14.30	*Benchmark*
F04	15-07-2020 14.30	15-07-2020 19.00	*Benchmark*

Sumber: *UTS_Data Sensor dan Kondisi Mesin Industri (B10)_Kelompok5.ipynb*, *Section* 3.

ID F01-F04 ditetapkan secara internal karena nomor #1 berulang dalam sumber. Tanggal *maintenance* yang tidak konsisten tidak digunakan untuk mengoreksi interval secara spekulatif. Suatu jendela memperoleh y_report=1 jika memuat sedikitnya satu sampel dalam interval sumber yang inklusif. Label 0 hanya berarti di luar laporan, bukan kondisi sehat yang terkonfirmasi.

Tabel 3. 6 Metrik dan alasan penggunaannya

Metrik	Makna dalam proyek
AP *proxy*	Rerata *precision* berbobot pertambahan *recall* pada peringkat skor; metrik utama untuk pembanding positif yang jarang.
Precision, *recall*, F1 *proxy*	Menilai alarm persisten terhadap label laporan; *precision*=TP/(TP+FP), *recall*=TP/(TP+FN), F1=2PR/(P+R).
ROC-AUC dan accuracy *proxy*	Metrik pendamping; accuracy tidak menjadi dasar utama karena pembanding timpang.
Recall kejadian dan delay	Jumlah interval teramati yang memiliki alarm saat laporan; selisih waktu alarm pertama terhadap awal laporan.
Episode di luar laporan	Rangkaian alarm berurutan yang tidak bertumpang tindih laporan, dibagi hari ekuivalen jendela terpantau.
Silhouette, DB, CH	Diagnostik struktur *cluster*; *silhouette*/CH lebih besar dan DB lebih kecil umumnya lebih baik pada ruang serta data yang sama.

Sumber: *UTS_Data Sensor dan Kondisi Mesin Industri (B10)_Kelompok5.ipynb*, *Section* 7 dan 9.

Deteksi kejadian hanya menghitung alarm dari jendela bersampel laporan dengan keputusan tersedia sebelum atau tepat akhir laporan. Jendela yang baru selesai setelah laporan dapat positif pada metrik jendela, tetapi tidak dihitung sebagai deteksi tepat waktu. Tidak dilakukan *point adjustment*. Cakupan kualitas dihitung dari jendela yang mempunyai durasi tumpang tindih positif terhadap interval, sehingga titik tepat di batas akhir tidak menambah durasi cakupan.

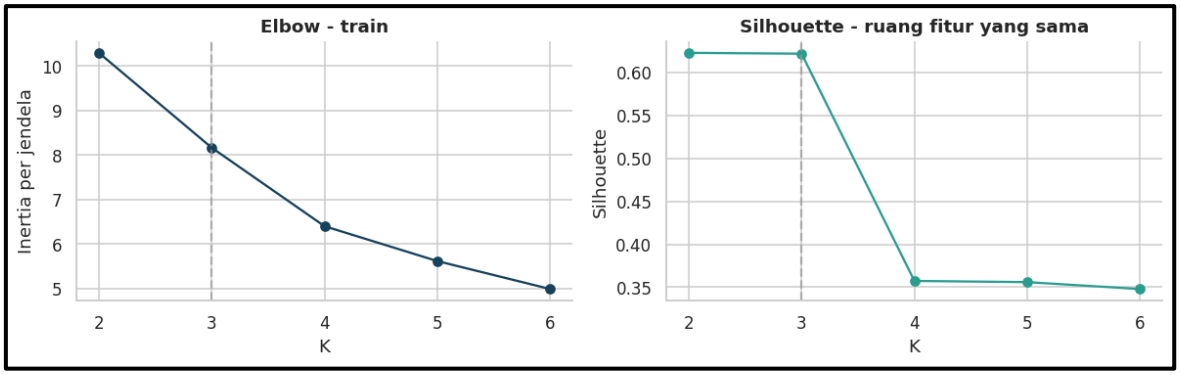
BAB IV
HASIL EKSPERIMEN AWAL DAN PEMBAHASAN

4.1 Eksperimen Jumlah *Cluster* dan Profil Operasi

Tabel 4. 1 Diagnostik K-Means pada ruang *training* yang sama

K	*Inertia* per jendela	*Silhouette*	Davies Bouldin	Calinski Harabasz
2	10,2967	0,6226	0,7643	5.660,3353
3	8,1656	0,6217	0,7142	4.217,8048
4	6,4026	0,3574	0,9638	4.042,3054
5	5,6190	0,3560	1,1093	3.627,3344
6	4,9912	0,3479	1,0078	3.391,3768

Sumber: *UTS_Data Sensor dan Kondisi Mesin Industri (B10)_Kelompok5.ipynb*, *Section* 7.



Gambar 4. 1 *Elbow* dan *silhouette* untuk K=2 sampai K=6

Sumber: *UTS_Data Sensor dan Kondisi Mesin Industri (B10)_Kelompok5.ipynb*, *Section* 7.

Silhouette tertinggi diperoleh pada K=2, yaitu 0,6226, sedikit di atas K=3 sebesar 0,6217. K=3 mempunyai Davies-Bouldin lebih rendah daripada K=2. *Inertia* tu*run* ketika K bertambah, tetapi penu*run*an ini tidak otomatis meningkatkan deteksi. *Baseline* K=3 tetap dipertahankan untuk pembandingan terkontrol; hasil diagnostik K belum digunakan untuk mengganti konfigurasi berdasarkan *benchmark*. *Silhouette* dihitung pada sampel tetap maksimal 1.500 jendela.

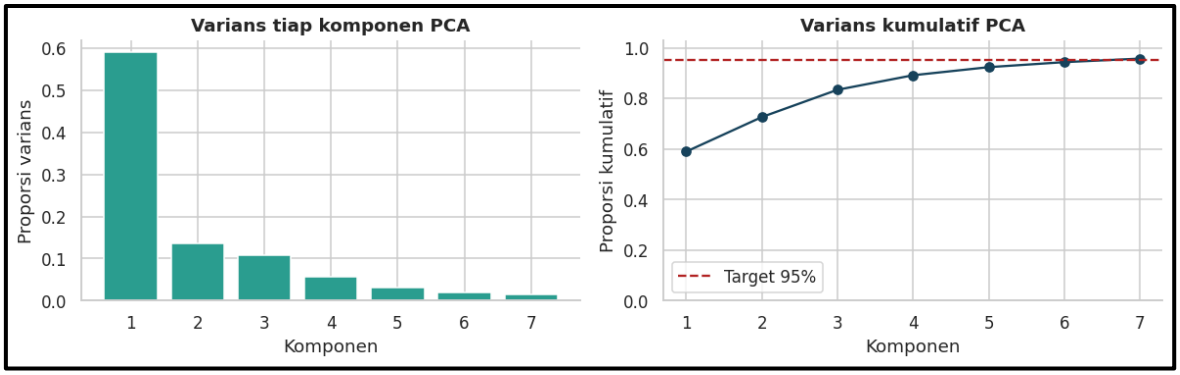
Tabel 4. 2 Profil *cluster baseline* dalam satuan asli

Cluster	**Jendela**	**Arus rerata A**	**Suhu oli rerata °C**	**Proporsi berbeban**
0	4.108	0,7731	56,7366	0,12%
1	795	3,3919	56,8950	16,85%
2	79	3,7446	58,0592	14,84%

Sumber: *UTS_Data Sensor dan Kondisi Mesin Industri (B10)_Kelompok5.ipynb*, *Section* 7.

Cluster 0 mencakup sekitar 82,46% jendela *training* dan memiliki arus rerata paling rendah. *Cluster* 1 dan 2 memuat kondisi dengan arus relatif lebih tinggi. Nomor *cluster* bersifat arbitrer, dan *cluster* 2 yang hanya berisi 79 jendela tidak langsung diartikan sebagai kerusakan. Profil ini menggambarkan pola operasi relatif pada referensi.

4.2 Reduksi Dimensi dan Kalibrasi Kandidat



Gambar 4. 2 Proporsi varians tiap komponen dan varians kumulatif PCA

Sumber: *UTS_Data Sensor dan Kondisi Mesin Industri (B10)_Kelompok5.ipynb*, *Section* 8.

Tujuh komponen PCA mempertahankan 95,692% varians dari 22 fitur nonkonstan; komponen pertama menjelaskan sekitar 58,939%. Kompresi menunjukkan redundansi representasi, tetapi bukan bukti peningkatan akurasi deteksi. Hasil tugas hilir tetap menjadi dasar menilai manfaat PCA.

Tabel 4. 3 Dimensi dan ambang hasil kalibrasi

Model	Dimensi model	Ambang P99	Waktu fit detik
K-Means	22	45,6311	0.1244
PCA + K-Means	7	36,7491	0.1037
Isolation Forest	22	0,6592	0.5271

Sumber: *UTS_Data Sensor dan Kondisi Mesin Industri (B10)_Kelompok5.ipynb*, *Section* 8.

Ambang memiliki skala berbeda antarmodel dan tidak dibandingkan sebagai tingkat keparahan kerusakan. Waktu fit hanya mencakup pemanggilan *Pipeline*.fit, tidak termasuk unduhan, EDA, agregasi, dan evaluasi. Pengukuran berasal dari satu lingkungan *run*, sehingga tidak digunakan sebagai *benchmark* perangkat keras yang terkontrol.

4.3 Kestabilan Lima *Fold* Temporal

Tabel 4. 4 Jumlah jendela setiap *fold* referensi

Fold	Fit	Kalibrasi	Evaluasi
1	656	192	734
2	1.311	272	865
3	1.962	485	772
4	2.595	624	906
5	3.219	906	855

Sumber: *UTS_Data Sensor dan Kondisi Mesin Industri (B10)_Kelompok5.ipynb*, *Section* 9.

Tabel 4. 5 Rerata dan simpangan baku respons lima *fold*

Model	Pelampauan rerata	Pelampauan SD	Alarm rerata
K-Means	1,53%	1,15 poin persen	0,00%
PCA + K-Means	1,71%	1,37 poin persen	0,00%
Isolation Forest	1,36%	0,99 poin persen	0,00%

Sumber: *UTS_Data Sensor dan Kondisi Mesin Industri (B10)_Kelompok5.ipynb*, *Section* 9.

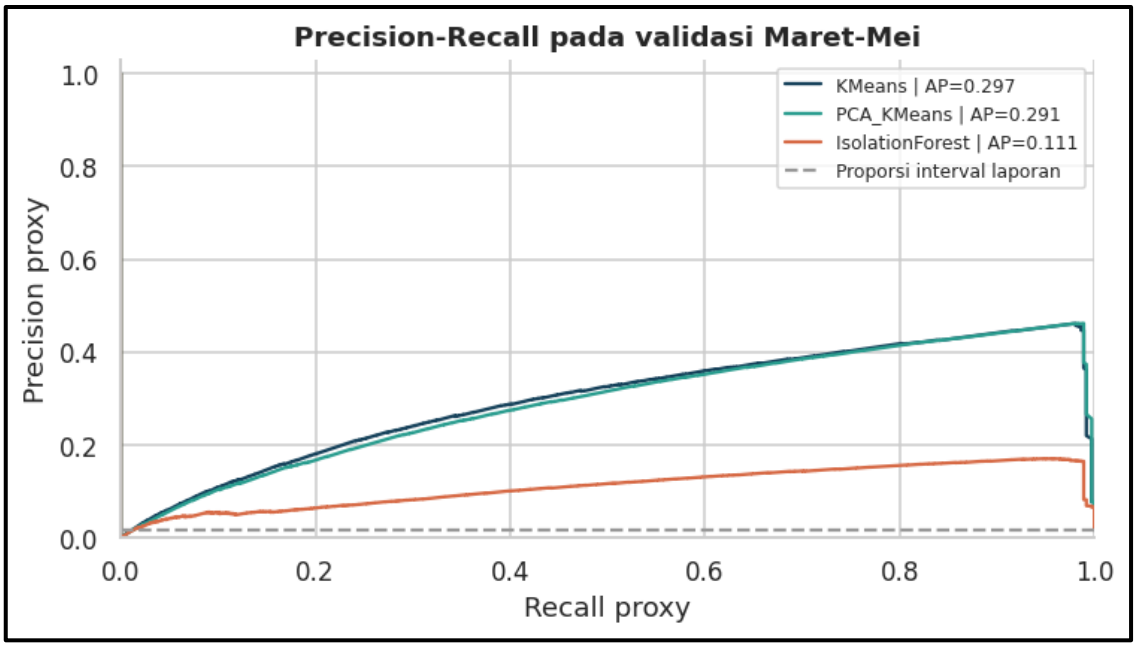
Pelampauan ambang pada seluruh model-*fold* berada sekitar 0,39%-3,81%, sedangkan alarm setelah persistensi bernilai nol pada semua *fold* referensi. Artinya, pelampauan yang muncul pada *fold* tersebut tidak membentuk rangkaian tiga jendela berturut-turut. Hasil ini tidak dapat ditafsirkan sebagai deteksi sempurna karena periode *fold* tidak memuat interval gangguan laporan.

4.4 *Initial Results and Analysis*: Pembandingan Kandidat pada Validasi

Tabel 4. 6 Evaluasi validasi temporal Maret sampai Mei

Model	AP	*Precision*	*Recall*	F1
Kontrol tanpa alarm	0,0171	0,0000	0,0000	0,0000
K-Means	0,2974	0,1499	0,9918	0,2604
PCA + K-Means	0,2907	0,1491	0,9945	0,2593
Isolation Forest	0,1105	0,2481	0,9835	0,3962

Sumber: *UTS_Data Sensor dan Kondisi Mesin Industri (B10)_Kelompok5.ipynb*, *Section* 9.



Gambar 4. 3 Kurva *precision recall* pada validasi temporal

Sumber: *UTS_Data Sensor dan Kondisi Mesin Industri (B10)_Kelompok5.ipynb*, *Section* 9.

Dari 21.286 jendela validasi, sebanyak 364 berkaitan dengan laporan. K-Means dipilih karena AP tertinggi, sedangkan *Isolation Forest* menghasilkan F1 tertinggi pada konfigurasi P99 dan persistensi tiga jendela. Ketiga kandidat mendeteksi dua interval validasi teramati. Pemeringkatan skor dan kualitas alarm pada satu ambang merupakan sasaran berbeda, sehingga tidak ada klaim dominasi pada seluruh metrik.

AP K-Means per bulan sebesar 0,9248 pada April dan 0,1007 pada Mei menunjukkan variasi hasil antarperiode. Maret tidak mempunyai jendela laporan positif sehingga AP bulanan tidak dihitung. Hasil *benchmark* yang lebih tinggi daripada validasi tidak otomatis membuktikan perbaikan model, karena keduanya mengevaluasi periode dan kejadian yang berbeda tanpa pelatihan ulang di antaranya.

4.5 *Ablation* Fitur dan Sensitivitas Alarm

Tabel 4. 7 *Ablation* paket tiga fitur rekayasa pada validasi

Fitur masukan	AP	*Precision*	*Recall*	F1
22 statistik dasar	0,29749	0,15090	0,99451	0,26203
25 fitur lengkap	0,29745	0,14985	0,99176	0,26037

Sumber: *UTS_Data Sensor dan Kondisi Mesin Industri (B10)_Kelompok5.ipynb*, *Section* 9.

Penambahan tiga fitur menghasilkan perubahan AP sekitar -0,00004. Dengan demikian, manfaat paket fitur belum terlihat pada kriteria utama. Angka 22 pada *ablation* menyatakan jumlah fitur dasar sebelum filter, sedangkan 22 pada *Pipeline* lengkap menyatakan fitur tersisa setelah filter; keduanya tidak boleh disamakan sebagai himpunan yang identik. Setiap *Pipeline ablation* dipelajari ulang pada set fiturnya sendiri.

Tabel 4. 8 Sensitivitas kuantil dan persistensi pada validasi

Kuantil	Persistensi	F1 *proxy*	Episode luar laporan per hari
0,975	1	0,10488	44,21610
0,975	3	0,24727	1,56948
0,975	6	0,26553	0,47355
0,990	1	0,14729	26,43766
0,990	3	0,26037	0,67650
0,990	6	0,26767	0,29766
0,995	1	0,16355	20,76858
0,995	3	0,26207	0,58179
0,995	6	0,26838	0,29766

Sumber: *UTS_Data Sensor dan Kondisi Mesin Industri (B10)_Kelompok5.ipynb*, *Section* 9.

Persistensi lebih panjang menu*run*kan episode alarm di luar laporan pada validasi, tetapi juga dapat menu*run*kan *recall* atau menunda keputusan. Pada kuantil 0,99, perubahan persistensi dari tiga ke enam jendela menaikkan F1 dari 0,26037 menjadi 0,26767 dan menu*run*kan episode luar laporan dari 0,67650 menjadi 0,29766 per hari terpantau. Konfigurasi utama tetap P99 dan tiga jendela; hasil sensitivitas tidak digunakan untuk mengganti konfigurasi *benchmark* dalam *run* ini.

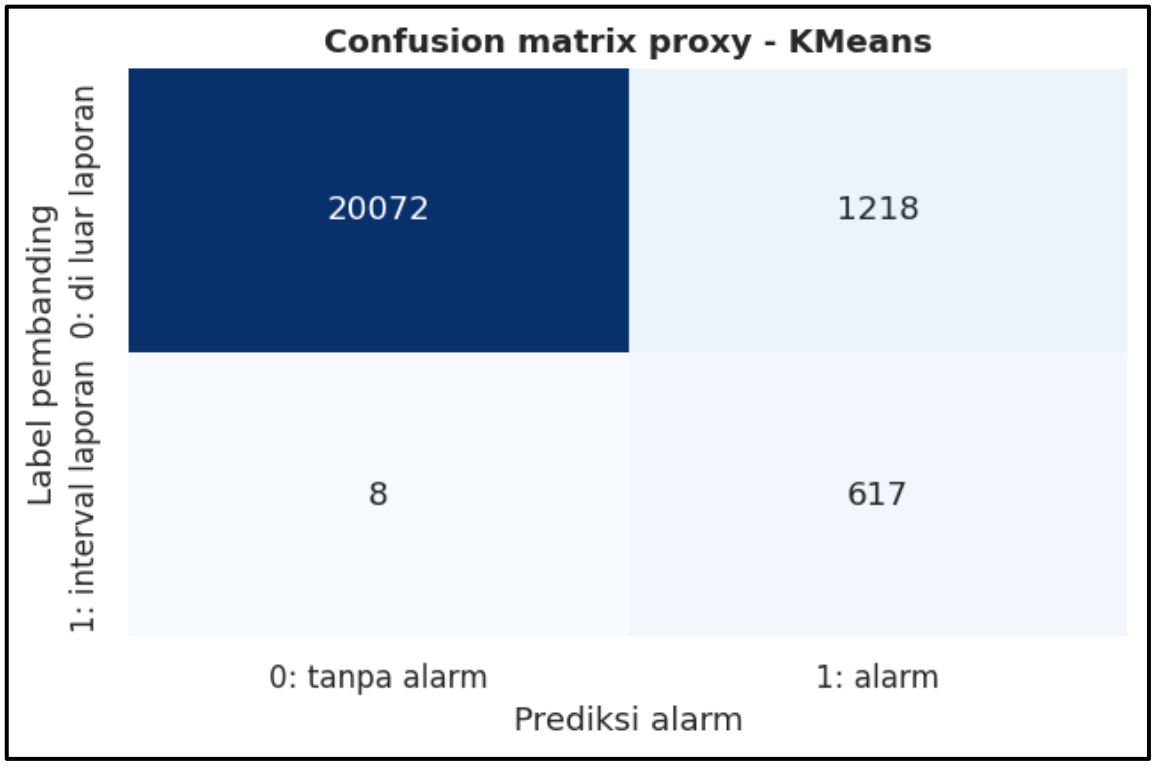
4.6 Hasil *Benchmark* dengan Konfigurasi Beku

Tabel 4. 9 Evaluasi *benchmark* pada jendela yang sama

Model	AP	*Precision*	*Recall*	F1
Kontrol tanpa alarm	0,0285	0,0000	0,0000	0,0000
K-Means	0,8685	0,3362	0,9872	0,5016
PCA + K-Means	0,8667	0,3342	0,9872	0,4994
Isolation Forest	0,4293	0,4350	0,9856	0,6036

Sumber: *UTS_Data Sensor dan Kondisi Mesin Industri (B10)_Kelompok5.ipynb*, *Section* 10 dan 14.

Benchmark terdiri atas 21.915 jendela layak, dengan 625 jendela berlabel laporan. K-Means mencapai AP 0,8685, *recall* 0,9872, dan F1 0,5016. AP kontrol sebesar 0,0285 mencerminkan proporsi positif ketika semua skor sama. Accuracy kontrol mencapai 97,15% walaupun tidak mendeteksi satu pun laporan; hal ini menjelaskan mengapa accuracy tidak dijadikan ukuran keberhasilan utama.



Gambar 4. 4 *Confusion matrix proxy* K-Means pada *benchmark*

Sumber: *UTS_Data Sensor dan Kondisi Mesin Industri (B10)_Kelompok5.ipynb*, *Section* 10.

Confusion matrix memuat 617 jendela laporan dengan alarm, delapan jendela laporan tanpa alarm, 1.218 jendela alarm di luar laporan, dan 20.072 jendela di luar laporan

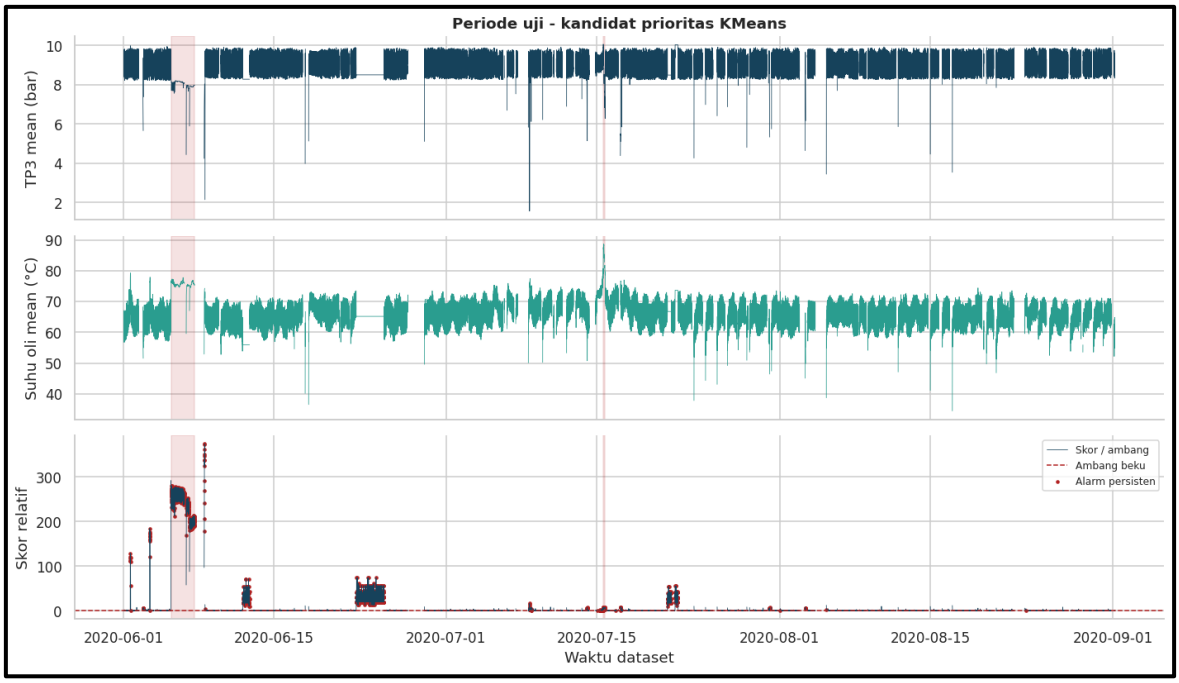
tanpa alarm. Angka tersebut menghasilkan proporsi alarm sekitar 8,37%. Komponen FP *proxy* belum merupakan *false alarm* aktual yang terverifikasi, sebab label di luar laporan tidak menjamin kondisi sehat.

Tabel 4. 10 Beban alarm dan deteksi kejadian pada *benchmark*

Model	Alarm jendela	Episode luar laporan	Episode per hari	Deteksi
K-Means	8,3733%	30	0,3943	2/2
PCA + K-Means	8,4235%	37	0,4862	2/2
Isolation Forest	6,4613%	12	0,1577	2/2

Sumber: *UTS_Data Sensor dan Kondisi Mesin Industri (B10)_Kelompok5.ipynb*, *Section* 10 dan 14.

K-Means menghasilkan 1.218 jendela alarm di luar laporan, tetapi hanya 30 episode yang sepenuhnya tidak bertumpang tindih laporan. Sebagian jendela di luar laporan dapat menjadi bagian episode yang bertumpang tindih suatu kejadian. Denominator episode per hari adalah 76,0938 hari ekuivalen jendela *benchmark* terpantau, bukan seluruh hari kalender.



Gambar 4. 5 Timeline sensor dan skor relatif pada *benchmark*

Sumber: *UTS_Data Sensor dan Kondisi Mesin Industri (B10)_Kelompok5.ipynb*, *Section* 10.

4.7 Cakupan Laporan dan Waktu Deteksi

Tabel 4. 11 Cakupan kualitas jendela pada interval laporan

Interval	*Overlap* durasi	Lolos kualitas	Cakupan
F01	288	286	99,31%
F02	78	78	100,00%
F03	630	571	90,63%
F04	54	53	98,15%

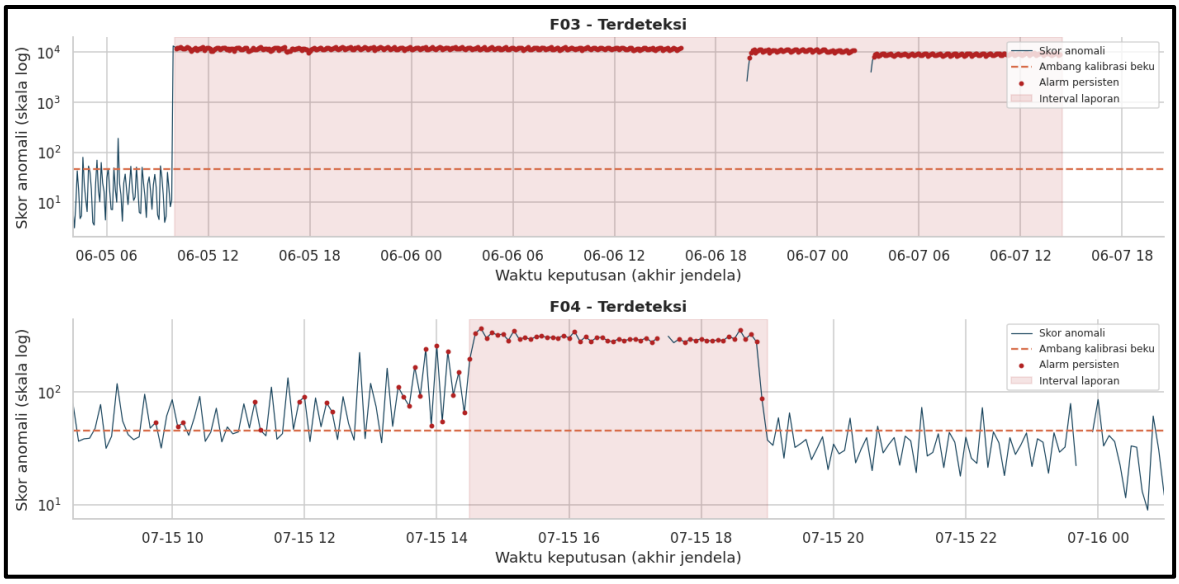
Sumber: *UTS_Data Sensor dan Kondisi Mesin Industri (B10)_Kelompok5.ipynb*, *Section* 9.

Kedua interval *benchmark* teramati sebagian, sehingga deteksi 2/2 tidak menyatakan seluruh durasi kejadian dipantau. Pada F04 terdapat 54 jendela bersampel laporan untuk metrik jendela, tetapi hanya 53 jendela yang lolos dan mempunyai durasi *overlap* positif. Perbedaan muncul karena sampel tepat pada batas akhir laporan mengikuti definisi label inklusif.

Tabel 4. 12 Alarm pertama K-Means pada *benchmark*

Interval	Awal laporan	Alarm pertama	Jeda menit
F03	05-06-2020 10.00	05-06-2020 10.05	5
F04	15-07-2020 14.30	15-07-2020 14.35	5

Sumber: *UTS_Data Sensor dan Kondisi Mesin Industri (B10)_Kelompok5.ipynb*, *Section* 14.



Gambar 4. 6 Skor dan alarm K-Means di sekitar F03 dan F04

Sumber: *UTS_Data Sensor dan Kondisi Mesin Industri (B10)_Kelompok5.ipynb*, *Section* 14.

Alarm pertama tersedia lima menit setelah awal masing-masing laporan. Angka ini mengukur waktu keputusan sejak awal interval sumber, bukan *lead time* sebelum mesin rusak atau berhenti. Karena pelampauan dapat mendahului interval laporan, hasil ini juga tidak bertentangan dengan aturan persistensi tiga jendela. Kemampuan peringatan dini masih perlu dirumuskan dan diuji terpisah.

4.8 Diagnosis Kesalahan dan Pergeseran Distribusi

Pada validasi, K-Means melewatkan tiga jendela laporan dan menghasilkan 2.048 jendela alarm di luar laporan. Pemeriksaan dikelompokkan menurut motor_load_fraction menjadi beban jarang, campuran, dan beban dominan. Pengelompokan ini membantu menelusuri konteks alarm, tetapi tetap merupakan heuristik fitur, bukan anotasi mode mesin dari teknisi.

Profil deviasi menunjukkan bahwa fitur DV_pressure__mean mempunyai nilai rata-rata absolute z-score sekitar 49,2004 pada jendela alarm, dibandingkan 6,4214 pada seluruh data validasi. Besarnya deviasi dapat dipengaruhi oleh variasi referensi yang kecil.

Rerata suhu oli *training* sekitar 56,7828 °C, sedangkan rerata fitur suhu pada Maret, April, dan Mei berturut-turut 62,1864; 59,4607; dan 62,2414 °C. Pergeseran tersebut menjadi alasan memeriksa distribusi antarperiode dan konteks beban menuju UAS. Analisis ini belum membuktikan pengaruh musim, perubahan lingkungan, maupun kerusakan tertentu.

Tiga fitur digital yang dibuang karena konstan pada *training* berubah pada validasi: Caudal_impulses__*duty* memiliki 14 nilai unik, LPS__*duty* 35, dan Oil_level__*duty* 21. Kondisi ini merupakan *blind spot* model yang perlu dievaluasi dengan periode referensi lebih representatif atau aturan pemantauan sensor tambahan, tanpa mempelajari transformasi dari *benchmark*.

4.9 Proses Inferensi dan Pemeriksaan Integritas

Demonstrasi inferensi menggunakan sensor mentah untuk membentuk fitur, menghitung skor, dan menghasilkan alarm tanpa fit ulang. Dua belas jendela contoh menghasilkan satu pelampauan ambang dan nol alarm persisten. Hasil ini menunjukkan pelampauan sesaat tidak langsung menjadi alarm.

Pengujian inferensi dilakukan menggunakan data sensor mentah untuk mengestraksi fitur, menghitung skor penalti, dan memicu alarm tanpa perlu melatih ulang model. Dari dua belas jendela sampel yang diuji, tercatat satu kali lonjakan data yang melewati ambang batas, namun tidak sampai memicu alarm persisten. Hasil pengujian ini membuktikan bahwa lonjakan data sesaat tidak serta-merta mengaktifkan sistem alarm.

Tabel 4. 13 Pemeriksaan konsistensi implementasi

Pemeriksaan	Hasil
Sensor mentah menjadi fitur dan skor konsisten dengan matriks eksperimen	Lulus
Serialisasi joblib mempertahankan skor dan alarm	Lulus
State antar*batch* konsisten pada batas persistensi	Lulus
Jeda waktu mereset persistensi	Lulus
Penambahan data masa depan tidak mengubah fitur jendela selesai	Lulus
Modul *file* mandiri bekerja tanpa variabel global *notebook*	Lulus

Sumber: *UTS_Data Sensor dan Kondisi Mesin Industri (B10)_Kelompok5.ipynb*, *Section* 12.

Pengujian logika batas menggunakan f*lag* buatan hanya untuk pemeriksaan fungsi dan tidak dimasukkan sebagai hasil eksperimen data mesin. Penggunaan *batch* mengharuskan jendela lengkap; pada *streaming*, sampel harus ditampung sampai jendela

selesai dan *state* persistensi diteruskan. Demonstrasi ini belum merupakan *deployment* sistem industri.

4.10 Keterbatasan Eksperimen Awal

Keterbatasan utama ialah label laporan yang tidak lengkap, hanya empat interval dengan dua interval *benchmark*, data satu kompresor, eksklusi jendela berkualitas rendah, satu *seed* utama, dan *benchmark* yang telah terlihat pada versi terdahulu. Periode referensi tanpa laporan tidak menjamin bebas anomali. Kemampuan memberi peringkat skor belum sama dengan ketepatan alarm, diagnosis penyebab, maupun kelayakan operasional.

PCA belum meningkatkan AP dibandingkan baseline pada eksperimen ini, dan tiga fitur tambahan belum memperbaiki AP validasi. Kelima fold referensi bukan pengulangan independen, sedangkan analisis deviasi dan pergeseran nilai rata-rata sensor masih bersifat deskriptif. Seluruh batas ini menjadi dasar perencanaan lanjutan, bukan alasan mengganti masalah atau menyembunyikan hasil yang kurang menguntungkan.

Untuk membaca angka evaluasi secara tepat, seluruh nilai *precision*, *recall*, F1, dan AP dalam proyek ini dipahami sebagai metrik *proxy* terhadap jendela yang bertumpang tindih dengan laporan gangguan. Alarm di luar interval tidak otomatis merupakan *false alarm* pada kondisi mesin sehat, sehingga hasil tidak boleh ditafsirkan sebagai akurasi diagnosis kerusakan tanpa verifikasi tambahan.

BAB V
KESIMPULAN DAN RENCANA PENGEMBANGAN

5.1 Kesimpulan dan Capaian Milestone 1

Proyek ini diawali dengan permasalahan pemantauan kondisi Air Production Unit (APU) berdasarkan sinyal sensor yang berubah mengikuti beban dan mode operasi. Dataset MetroPT-3 berisi 1.516.948 rekaman, 15 sensor, dan tidak menyediakan label kerusakan per baris. Kondisi tersebut menuntut pendekatan deteksi anomali tanpa pengawasan, sekaligus kehati-hatian ketika membandingkan keluaran model dengan interval gangguan yang hanya didokumentasikan pada tingkat kejadian. Audit data menemukan tidak ada *timestamp* tidak valid, duplikasi *timestamp*, maupun nilai sensor hilang; namun, ketakteraturan perekaman tetap diperhitungkan sebelum data diolah menjadi unit analisis yang dapat dibandingkan.

Setelah tahap eksplorasi, kelompok menemukan perbedaan rentang antarsensor, hubungan yang hampir sempurna antara TP3 dan Reservoirs pada periode *training*, beberapa mode arus motor, serta sejumlah sinyal digital yang tidak bervariasi pada referensi. Temuan tersebut diterjemahkan menjadi pembentukan jendela lima menit secara kausal, aturan kelayakan jendela, standardisasi berbasis *training*, seleksi fitur konstan, dan pengujian reduksi dimensi. Dari 25 fitur awal yang dibentuk, 22 fitur tetap digunakan setelah penyaringan varians; tujuh komponen PCA mampu mempertahankan 95,692% varians *training*. Sebanyak 50.276 jendela yang lolos pemeriksaan dibagi secara temporal menjadi *training*, kalibrasi, validasi, dan *benchmark*, disertai *embargo* antarbatas untuk mengurangi risiko kebocoran informasi.

Eksperimen awal membandingkan K-Means, PCA + K-Means, dan *Isolation Forest* dengan aturan kalibrasi ambang P99 serta alarm yang membutuhkan tiga pelampauan berturut-turut. Berdasarkan Average *Precision* (AP) *proxy* pada validasi Maret-Mei, K-Means dipilih sebagai kandidat awal dengan AP sekitar 0,2974. Pada periode *benchmark* Juni-awal September, model ini memperoleh AP 0,8685, *precision* 0,3362, *recall* 0,9872, dan F1 0,5016. Kedua interval gangguan *benchmark* yang teramati memiliki alarm saat periode laporan; tetapi terdapat delapan jendela laporan tanpa alarm dan 1.218 jendela alarm di luar laporan. *Isolation Forest* justru mencatat F1 *benchmark* yang lebih tinggi, yaitu 0,6036. Perbedaan ini memperlihatkan bahwa pemilihan model berdasarkan AP validasi tidak otomatis menjamin ketepatan alarm paling baik pada setiap metrik atau periode.

Dengan demikian, delapan capaian UTS telah ditunjukkan melalui perumusan masalah, dokumentasi dan audit data, EDA berinterpretasi, *Preprocessing* yang menjaga urutan waktu, rekayasa fitur, *baseline* dan dua kandidat tambahan, rancangan evaluasi, serta hasil eksperimen dan rencana lanjutan. Yang telah dibuktikan adalah keterlaksanaan *Pipeline* dan tersedianya bukti kuantitatif untuk menilai penyimpangan terhadap laporan gangguan, bukan diagnosis penyebab kebocoran, akurasi untuk kondisi sehat yang terverifikasi, atau kesiapan penerapan industri. Empat interval laporan masih menjadi pembanding lemah, jendela berkualitas rendah dikeluarkan, dan *benchmark* telah diperiksa pada versi *notebook* sebelumnya. Oleh karena itu, pekerjaan hingga UAS perlu memprioritaskan validasi pembanding, pengujian fitur dan ambang terhadap beban alarm, pemeriksaan perubahan distribusi, serta reproduksi pada data atau periode evaluasi yang benar-benar baru apabila tersedia.

Tabel 5. 1 Ringkasan ketercapaian tujuan

Capaian UTS (1-8)	**Status Capaian dan Rujukan Bab**
1. Formulasi masalah dan tujuan	Terpenuhi pada Bab I: masalah perubahan kondisi APU, pendekatan *unsupervised*, tujuan, ruang lingkup, dan indikator keluaran dijelaskan.
2. Sumber, struktur, dan kualitas *dataset*	Terpenuhi pada Bab II: sumber UCI ID 791, 1.516.948 observasi, 15 sensor, 17 kolom, unit observasi, dan audit data ditampilkan.
3. EDA beserta temuan awal	Terpenuhi pada Bab II: statistik, distribusi, korelasi, status digital, dan interpretasi yang ditautkan pada keputusan pengolahan.
4. *Preprocessing* tanpa *data leakage*	Terpenuhi pada Bab III: agregasi kausal, seleksi jendela, pembagian waktu, *imputer*, filter, scaler, dan PCA yang di-fit pada *training*.
5. Transformasi atau rekayasa fitur	Terpenuhi pada Bab III-IV: 25 fitur jendela, tiga fitur rekayasa, *ablation*, dan analisis dampaknya; hasil *ablation* negatif tetap dilaporkan.

Capaian UTS (1-8)	Status Capaian dan Rujukan Bab
6. *Baseline* dan kandidat awal	Terpenuhi pada Bab III-IV: kontrol tanpa alarm, *baseline* K-Means, PCA + K-Means, dan *Isolation Forest* dibandingkan dengan protokol konsisten.
7. Rancangan validasi dan metrik	Terpenuhi pada Bab III: *split* temporal, lima *fold expanding-window* referensi, AP *proxy*, *precision*, *recall*, F1, dan metrik tingkat kejadian.
8. Hasil eksperimen dan rencana menuju UAS	Terpenuhi untuk tahap awal pada Bab IV-V: tabel perbandingan, analisis *error*, keterbatasan, rencana evaluasi, serta kebutuhan dokumentasi dan reproduksi.

Sumber: *UTS_Data Sensor dan Kondisi Mesin Industri (B10)_Kelompok5.ipynb*, *Section* 2 sampai 14.

5.2 *Documentation and Next Plan*: Rencana Pengembangan Untuk UAS

1. Memverifikasi empat interval laporan, cakupan kualitas, dan sampel alarm di luar laporan bersama pihak yang memahami mesin apabila akses tersedia. Jika verifikasi eksternal tidak memungkinkan, ketidakpastian label dicatat dan sensitivitas batas interval diuji. Bukti penerimaan berupa catatan keputusan label, sampel yang diperiksa, serta alasan setiap perubahan.
2. Menguji kontribusi fitur secara individual dan menurut kondisi beban. Fitur *rolling* atau *lag* hanya ditambahkan jika dapat dibentuk tanpa informasi masa depan. Bukti penerimaan berupa tabel *ablation* temporal yang memisahkan manfaat fitur, perubahan beban alarm, dan pengaruh fitur digital yang sebelumnya konstan.
3. Menyepakati anggaran episode alarm per hari dan toleransi keterlambatan sebelum memilih ambang. Hasil sensitivitas UTS menyediakan dasar awal, tetapi belum menetapkan target operasional. Bukti penerimaan berupa aturan pemilihan konfigurasi, tabel *trade-off* validasi, dan konfigurasi yang dibekukan sebelum evaluasi akhir.

5.3 Keterkaitan Rencana dengan Materi Setelah UTS

Tabel 5. 2 Rencana pengembangan mengikuti kontrak perkuliahan

Minggu	Fokus pengembangan proyek	Bukti
9	Kandidat One-Class SVM sebagai pengayaan konsep *margin* dan *kernel*.	Perbandingan temporal yang sama; parameter dan biaya komputasi tercatat.
10	*Threshold tuning* dan interpretasi; *ablation* fitur dan kelompok sensor.	*Trade-off recall*, *precision*, delay, serta episode alarm terdokumentasi.
12	Kurva *precision-recall*, ROC pendamping, evaluasi per kejadian dan antarperiode.	Kurva, cakupan laporan, variasi hasil, dan analisis ambang tersedia.
13	Pemilihan parameter, pelacakan model, pemantauan distribusi dan reproduksibilitas.	Ruang eksperimen, konfigurasi, versi artefak, dan diagnosis *drift* dapat ditelusuri.
14	Penjelasan alarm; eksplorasi AutoML bila sesuai tugas dan pembagian temporal.	Contoh alarm disertai dasar sensor dan batas interpretasi.
15	Presentasi dan *defense* solusi classical ML dari awal sampai akhir.	Model final, laporan, repository, dan demo hasil.

One-Class SVM merupakan kandidat pengembangan yang berkaitan dengan materi SVM Minggu 9, bukan metode yang telah dijalankan pada UTS atau kewajiban eksplisit dalam kontrak. Materi NLP Minggu 11 tidak menjadi prioritas karena data utama berupa sensor numerik dan digital. *Probability calibration* tidak disamakan dengan kalibrasi kuantil skor anomali. Stratified K-*Fold* acak dan SMOTE tidak langsung diterapkan pada alur *unsupervised* temporal ini.

Materi Minggu 13 dalam kontrak juga mencakup *explainability*, pengelolaan siklus hidup model, *deployment*, *monitoring*, *data drift*, dan *model drift*. Pengembangan diarahkan pada bagian yang sesuai proyek. AutoML hanya dipertimbangkan jika mendukung *estimator unsupervised*, *Preprocessing* dalam *Pipeline*, dan pemisahan temporal yang dapat diaudit.

5.4 Kontribusi Anggota

1. **Havidz Andrian (231111899)**: Mengumpulkan, memeriksa, dan mengaudit kualitas dataset MetroPT-3. Melakukan Exploratory Data Analysis (EDA), menyusun statistik deskriptif, serta membuat visualisasi distribusi dan korelasi sensor yang menjadi dasar bagi pengembangan model.
2. **Fikri Anwar (231112145):** Mengembangkan dan mengintegrasikan kode program pada Google Colab, meliputi pembagian data temporal, *preprocessing*, rekayasa fitur, implementasi K-Means, PCA + K-Means, dan Isolation Forest, penyusunan alur eksperimen, kalibrasi ambang anomali, serta pengujian reproduksibilitas *notebook*.
3. **Purba Tua Siregar (231112463):** Melakukan pengujian dan evaluasi model menggunakan metrik AP, *precision*, *recall*, dan F1-score, analisis perbandingan performa dan kesalahan deteksi, identifikasi keterbatasan eksperimen, serta penyusunan pembahasan hasil, kesimpulan, rencana pengembangan UAS, dan pemeriksaan konsistensi laporan akhir.

DAFTAR PUSTAKA

1. N. Davari, B. Veloso, R. Ribeiro, dan J. Gama, "MetroPT-3 *Dataset*," UCI *Machine learning* Repository, 2021. DOI: 10.24432/C5VW3R. Lisensi CC BY 4.0. https://archive.ics.uci.edu/*dataset*/791/metropt+3+*dataset*

2. B. Veloso, R. P. Ribeiro, J. Gama, dan P. M. Pereira, "The MetroPT *dataset* for predictive *maintenance*," Scientific Data, vol. 9, artikel 764, 2022. DOI: 10.1038/s41597-022-01877-3.
https://doi.org/10.1038/s41597-022-01877-3

3. N. Davari, B. Veloso, R. P. Ribeiro, P. M. Pereira, dan J. Gama, "Predictive *maintenance* based on anomaly detection using *deep learning* for air production unit in the railway industry," 2021 IEEE 8th International Conference on Data Science and Advanced Analytics, hlm. 1-10, 2021. DOI: 10.1109/DSAA53316.2021.9564181. https://doi.org/10.1109/DSAA53316.2021.9564181

4. D. Arthur dan S. Vassilvitskii, "k-means++: The Advantages of Careful Seeding," Proceedings of the Eighteenth Annual ACM-SIAM Symposium on Discrete Algorithms, hlm. 1027-1035, 2007. http://www.cs.columbia.edu/~verma/classes/uml/ref/clustering_kmean_plusplus_arthur_vassilvitskii.pdf

5. F. T. Liu, K. M. Ting, dan Z.-H. Zhou, "*Isolation Forest*," 2008 Eighth IEEE International Conference on Data Mining, hlm. 413-422, 2008. DOI: 10.1109/ICDM.2008.17.
https://doi.org/10.1109/ICDM.2008.17

6. F. Pedregosa dkk., "Scikit-learn: *Machine learning* in Python," Journal of *Machine learning* Research, vol. 12, hlm. 2825-2830, 2011. https://jmlr.org/papers/v12/pedregosa11a.html

7. Scikit-learn developers, "*Pipeline*s and composite *estimator*s" dan "Common pitfalls and recommended practices," dokumentasi scikit-learn 1.6.1.
https://scikit-learn.org/1.6/modules/compose.html

8. Scikit-learn developers, "*Preprocessing* data," dokumentasi scikit-learn 1.6.1. Diakses 29 Oktober 2026. https://scikit-learn.org/1.6/modules/*Preprocessing*.html

9. Scikit-learn developers, "*Cluster*ing" dan "Decomposing signals in components," dokumentasi scikit-learn 1.6.1. https://scikit-learn.org/1.6/modules/*cluster*ing.html

10. Scikit-learn developers, “TimeSeries*Split*,” dokumentasi scikit-learn 1.6.1. https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.TimeSeriesSplit
11. Scikit-learn developers, “Metrics and scoring: quantifying the quality of predictions,” dokumentasi scikit-learn 1.6.1. https://scikit-learn.org/1.6/modules/model_evaluation.html
12. Scikit-learn developers, “Novelty and *Outlier* Detection” dan “Model persistence,” dokumentasi scikit-learn 1.6.1. https://scikit-learn.org/1.6/modules/*outlier*_detection.html

LAMPIRAN

Tabel L1 Pemetaan komponen laporan dan bukti *notebook*

Komponen	Lokasi laporan	*Section notebook*
A. *Problem Formulation*	1.1-1.5 (Bab I)	Pembuka dan *Section* 3
B. *Dataset and Data Understanding*	2.1-2.3 (Bab II)	*Section* 2 dan 13
C. *EDA and Initial Findings*	2.4-2.6 (Bab II)	*Section* 4
D. *Preprocessing*	3.1-3.3 (Bab III)	*Section* 3-6
E. *Initial Feature Engineering*	3.4; 4.5 (Bab III-IV)	*Section* 5, 9 dan 13
F. *Baseline and Initial Candidate Models*	3.5-3.6; 4.1-4.2	*Section* 6-8
G. *Evaluation Design*	3.7-3.8 (Bab III)	*Section* 3 dan 9-10
H. *Initial Results and Analysis*	4.1-4.10 (Bab IV)	*Section* 7-11 dan 14
I. *Documentation and Next Plan*	5.1-5.6 (Bab V); Lampiran	*Section* 1, 12 dan 14

Tabel L2 Lingkungan yang tercatat dalam *output run*

Pustaka	Versi	Pustaka	Versi
Python	3.13.18	NumPy	2.1.3
pandas	2.2.3	SciPy	1.16.3
scikit-learn	1.6.1	joblib	1.6.0
Matplotlib	3.10.0	seaborn	0.13.2

Sumber: *UTS_Data Sensor dan Kondisi Mesin Industri (B10)_Kelompok5.ipynb*, *Section* 1.