MINGGU 2

Output yang Dikumpulkan

Setiap kelompok mengumpulkan **satu notebook project** yang berisi:

- Project Identification
- Problem Formulation
- Dataset dan Sumber
- Data Understanding
- Exploratory Data Analysis
- Data Quality Findings
- Preprocessing Plan
- Initial Feature Engineering
- Initial Data Pipeline
- Kesimpulan dan Rencana Tahap Berikutnya

Repository

Notebook disimpan pada repository project kelompok.

Repository akan digunakan secara berkelanjutan sampai **UTS dan UAS**.

PROJECT TASK 02

Data Understanding, EDA, dan Persiapan Data Awal

- Pada tahap ini, setiap kelompok melanjutkan **Project ID dan topik yang telah ditetapkan** dengan mulai memahami data yang akan digunakan.

Tuliskan secara singkat:

- Project ID
- Topik project
- Masalah yang ingin dikaji
- Tujuan project
- Unit analisis
- Target/variabel yang akan dianalisis, jika ada

"Masalah apa yang ingin kami pahami atau selesaikan dengan Machine Learning?"

Cari dan Ajukan Dataset

Cari minimal **1 kandidat dataset** yang sesuai dengan Project ID.

Dataset harus memiliki:

- sumber yang jelas;
- deskripsi data yang dapat dipahami;
- variabel yang relevan dengan topik;
- jumlah data yang memadai;
- informasi mengenai atribut/variabel yang tersedia.

Data Understanding

Lakukan pemeriksaan awal terhadap dataset.

1. Struktur data

- Tampilkan dan jelaskan:
- jumlah baris dan kolom;
- nama variabel;
- tipe data;
- beberapa contoh data;
- variabel numerik;
- variabel kategorikal;
- variabel teks jika relevan.

2. Statistik dasar

- Untuk variabel numerik, periksa:
- mean;
- median;
- standard deviation;
- minimum;
- maksimum;
- quartile/IQR.

Untuk variabel kategorikal, periksa:

- jumlah kategori;
- frekuensi setiap kategori;
- kategori dominan atau sangat jarang.

Exploratory Data Analysis (EDA)

Gunakan visualisasi yang sesuai dengan karakteristik dataset. Minimal:

Data numerik

- Histogram
- Boxplot

Hubungan antarvariabel

- Scatter plot atau visualisasi lain yang sesuai

Hubungan antarvariabel numerik

- Correlation heatmap, jika relevan

Data kategorikal

- Bar chart atau visualisasi distribusi kategori

Tidak perlu membuat grafik sebanyak mungkin.

Setiap visualisasi harus menghasilkan **temuan dan interpretasi**.

Temuan → Bukti → Interpretasi → Implikasi

Mis: Distribusi variabel X menunjukkan pergerakan ke kanan. Sebagian kecil observasi memiliki nilai jauh lebih tinggi dibandingkan mayoritas data. Kondisi ini perlu dipertimbangkan dalam tahap preprocessing dan pemodelan.

Dokumentasikan

Informasi	Keterangan
Nama dataset	...
Sumber	...
Link sumber	...
Jumlah baris	...
Jumlah kolom	...
Variabel utama	...
Target, jika ada	...
Jenis data	Numerik/Kategorikal/Teks
Lisensi/keterangan penggunaan	...

Identifikasi Masalah dan Karakteristik Data

Identifikasi minimal 3 temuan penting dari dataset.

Temuan dapat berupa:

- missing value;
- outlier;
- distribusi yang sangat miring;
- kategori yang tidak seimbang;
- perbedaan skala;
- kategori yang terlalu banyak;
- data duplikat;
- korelasi tinggi antarfitur;
- ketidakkonsistenan data;
- karakteristik lain yang relevan.

Gunakan format:

No	Temuan	Bukti	Implikasi
1	...	...	...
2	...	...	...
3	...	...	...

Yang Belum Perlu Dikerjakan

Pada Project Task 02, **belum diwajibkan**:

- mencari model terbaik;
- hyperparameter tuning;
- membandingkan banyak algoritma;
- optimasi performa;
- deployment;
- membuat aplikasi;
- mengejar accuracy tertinggi.

Jika kelompok melakukan eksperimen awal untuk memahami data, hasilnya boleh dicatat.
Namun **fokus utama tahap ini tetap Data Understanding dan persiapan data**.

Rencana Preprocessing

Berdasarkan hasil Data Understanding dan EDA, tentukan rencana penanganan data.

Masalah	Variabel	Rencana Penanganan	Alasan
Missing value	...	...	...
Outlier	...	...	...
Data kategorikal	...	...	...
Perbedaan skala	...	...	...

Apa masalahnya → mengapa penting → bagaimana rencana penanganannya.

Feature Engineering Awal

Usulkan minimal **2 kandidat fitur baru** yang relevan dengan masalah project.

Fitur dapat berupa:

- rasio;
- interaksi antarvariabel;
- transformasi;
- pengelompokan nilai;
- atau bentuk lain yang relevan dengan masalah.

Kandidat Fitur	Dibentuk dari	Alasan
Fitur 1	...	...
Fitur 2	...	...

Standar Hasil Tahap 2

Tahap 2 dianggap selesai apabila kelompok dapat menjawab lima pertanyaan berikut:

1. **Masalah - Masalah apa yang ingin kami selesaikan?**
2. **Data - Data apa yang kami gunakan dan mengapa data tersebut sesuai?**
3. **Temuan - Apa yang kami temukan dari data?**
4. **Persiapan - Masalah apa yang terdapat pada data dan bagaimana rencana penanganannya?**
5. **Fitur - Fitur apa yang akan digunakan atau dibentuk sebelum modeling?**

Jika lima pertanyaan tersebut belum dapat dijawab, kelompok belum bisa melanjukan pada pemilihan algoritma.

Output yang Dikumpulkan

Setiap kelompok mengumpulkan **satu notebook project** yang berisi:

- Project Identification
- Problem Formulation
- Dataset dan Sumber
- Data Understanding
- Exploratory Data Analysis
- Data Quality Findings
- Preprocessing Plan
- Initial Feature Engineering
- Initial Data Pipeline
- Kesimpulan dan Rencana Tahap Berikutnya

Repository

Notebook disimpan pada repository project kelompok.

Repository akan digunakan secara berkelanjutan sampai **UTS dan UAS**.

MINGGU 3

PROJECT MILESTONE

Pertemuan 3: Mulai Membangun Model

1. Periksa Kembali Masalah

Pastikan kelompok sudah dapat menjawab:

- Apa masalah yang ingin diselesaikan?
- Apa tujuan penggunaan Machine Learning?
- Apa yang menjadi **target**?
- Apa saja fitur yang digunakan?
- Jenis masalahnya apa?
  - Regression
  - Classification
  - Unsupervised Learning
  - Text Mining

Data → Preprocessing → Baseline Model → Evaluasi Awal

Pada minggu ini setiap kelompok mulai menguji apakah data yang telah dipilih benar-benar dapat digunakan untuk menyelesaikan masalah yang dirumuskan.

2. Periksa Dataset

Lakukan pemeriksaan terhadap dataset yang digunakan:

- Jumlah data;
- Jumlah fitur;
- Tipe data setiap fitur;
- Target;
- Missing value;
- Data duplikat;
- Outlier apabila relevan;
- Distribusi data;
- Ketidakseimbangan kelas apabila relevan;
- Kualitas dan keterbatasan dataset.

Output:

Dataset sudah dapat dijelaskan berdasarkan bukti, **bukan** hanya berdasarkan nama dataset.

3. Lakukan Preprocessing

Terapkan preprocessing sesuai karakteristik dataset.

Contoh:

- Menangani Missing Value;
- Encoding Data Kategorikal;
- Scaling Jika Diperlukan;
- Menangani Outlier Jika Relevan;
- Pemisahan Data Training Dan Testing;
- Mencegah Data Leakage.
- Preprocessing Harus Dilakukan **Berdasarkan Kondisi Data**, Bukan Sekadar Mengikuti Contoh Dari Notebook.

Jenis Project	Contoh Baseline
Regression	Linear Regression
Classification	Logistic Regression / Decision Tree sederhana
Text Classification	TF-IDF + Logistic Regression
Unsupervised	K-Means dengan konfigurasi awal

Tidak semua kelompok harus menggunakan Linear Regression.

Model baseline harus sesuai dengan jenis masalah project.
Guideline project mensyaratkan setiap proyek memiliki baseline sebagai pembanding bagi model-model berikutnya.

5. Lakukan Evaluasi Awal

Setelah baseline dijalankan, kelompok harus menghasilkan **bukti awal**.

- **Regression**
  Minimal:
  - MAE
  - RMSE
  - R^2
- **Classification**
  Minimal:
  - Accuracy
  - Precision
  - Recall
  - F1-score
  - Tambahkan confusion matrix jika relevan.

OUTPUT PROJECT PERTEMUAN 3

Setiap kelompok mengumpulkan **1 notebook Google Colab** yang berisi:

A. Problem
- Rumusan masalah;
- Tujuan;
- Target;
- Fitur;
- Jenis masalah.

B. Dataset
- Sumber;
- Jumlah data;
- Fitur;
- Target;
- Kualitas data.

C. Preprocessing
- Langkah preprocessing;
- Alasan setiap langkah;
- Data setelah preprocessing.

D. Baseline
- Algoritma baseline;
- Proses training;
- Hasil prediksi.

5. Lakukan Evaluasi Awal

- **Text Mining**

  Minimal:

  - F1-score
  - Precision
  - Recall
  - Accuracy
  - serta pemeriksaan hasil prediksi beberapa contoh teks.

- **Unsupervised Learning**

  Minimal:

  - Jumlah Cluster;
  - Ukuran Setiap Cluster;
  - Karakteristik Cluster;
  - Metrik Yang Sesuai, Misalnya Silhouette Score Apabila Relevan.

Yang penting bukan hanya angka.
Kelompok harus dapat menjawab:

Apa arti hasil baseline tersebut terhadap masalah yang kami pilih?

OUTPUT PROJECT PERTEMUAN 3

E. Evaluasi Awal

- Metrik;
- Hasil;
- Interpretasi singkat.

F. Temuan Awal

Tuliskan minimal:

- Apa yang berhasil?
- Apa masalah yang ditemukan?
- Apa kelemahan baseline?
- Apa yang perlu diperbaiki pada tahap berikutnya?

Gunakan Project ID yang telah ditetapkan.

Project ID dan dataset yang telah dikunci tetap menjadi acuan kelompok.

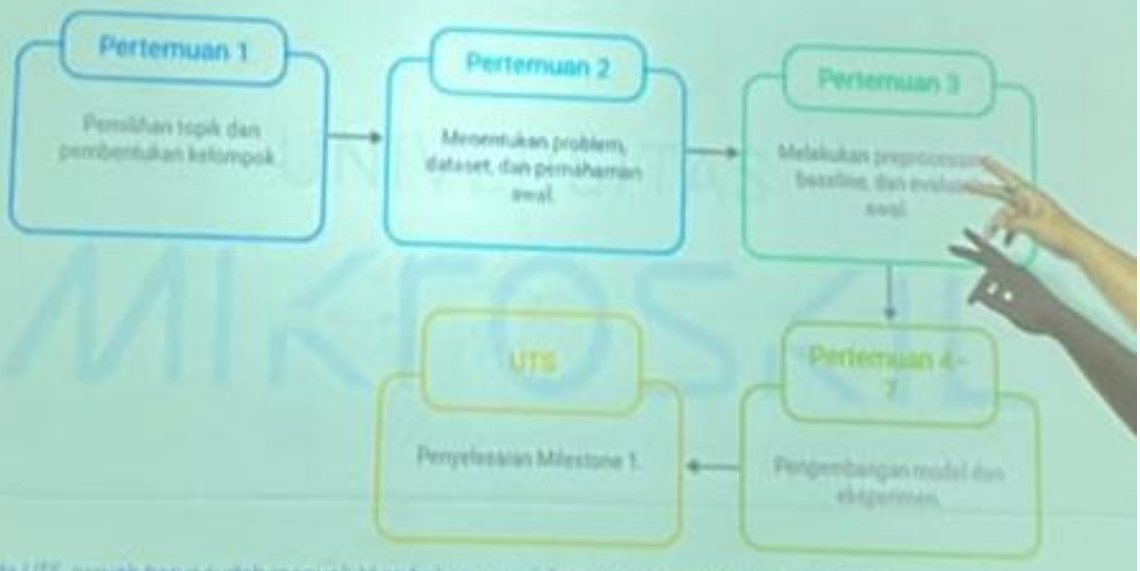
Aturan dasarnya:

Tidak boleh mengganti dataset atau mengambil project kelompok lain hanya karena dataset tersebut menghasilkan performa model yang lebih baik.

Proyek dianggap sama apabila domain, dataset, target, dan permasalahan utamanya sama.

HUBUNGAN DENGAN UTS

Project Milestone



Pada UTS, proyek harus sudah menunjukkan bahwa proyek **benar-benar berjalan**, bukan hanya proposal.

Jangan Bertanya:

"Algoritma apa yang paling bagus?"

Tanyakan:

"Masalah apa yang ingin kami selesaikan, apakah data kami mendukungnya, dan seberapa baik baseline dapat menyelesaikannya?"

MINGGU 4

TARGET PROJECT PERTEMUAN 4

Dari Baseline Menuju Kandidat Model

Pada Pertemuan 3, kelompok telah mulai:

Problem → Data → Preprocessing → Baseline → Evaluasi Awal

Pada Pertemuan 4, lanjutkan menjadi:

Baseline → Kandidat Model → Evaluasi → Perbandingan Awal

HUBUNGKAN DENGAN MATERI MINGGU INI

Apa yang Dipelajari? Classification

- Untuk masalah klasifikasi, kita belajar:
  - Logistic Regression;
  - K-Nearest Neighbours;
  - Decision Tree;
  - Confusion Matrix;
  - Accuracy;
  - Precision;
  - Recall;
  - F1-Score.

Tujuannya **bukan** menghafal algoritma.

Tujuannya adalah memahami:

Bagaimana memilih dan mengevaluasi model untuk masalah yang memiliki target kategori.

Target minggu ini

Setiap kelompok harus memiliki:

- Baseline yang sudah berjalan;
- Minimal satu kandidat model tambahan;
- Hasil evaluasi;
- Perbandingan awal;
- Catatan mengenai kelebihan dan kelemahan model.

Final model **belum perlu diputuskan**.

JIKA PROJECT - UNSUPERVISED

Untuk project clustering atau pola data:

- **Pertahankan:**
  - dataset;
  - tujuan analisis;
  - fitur;
  - preprocessing.
- **Kembangkan:**
  - baseline clustering;
  - kandidat metode clustering;
  - jumlah cluster;
  - karakteristik setiap cluster;
  - evaluasi cluster.

Contoh: **Baseline** K-Means → **Eksperimen** Beberapa nilai K → **Evaluasi** Elbow Method / Silhouette Score → **Interpretasi**

- Apa karakteristik setiap kelompok?

JIKA PROJECT - REGRESSION

Project Regression tetap dilanjutkan sebagai Regression.

Materi Classification digunakan untuk memahami konsep umum **pemilihan model dan evaluasi**, sedangkan eksperimen project mengikuti jenis masalah yang telah ditetapkan.

Minggu ini lakukan:

- Pertahankan baseline regression;
- Tambahkan kandidat model yang relevan;
- Lakukan evaluasi;
- Bandingkan hasil;
- Catat kelemahan baseline.

- Contoh: **Baseline** Linear Regression → **Kandidat** Polynomial / Ridge / Lasso → **Evaluasi** MAE + RMSE + R^2 → **Perbandingan awal**

Model mana yang lebih baik dan **mengapa?**

JIKA PROJECT - TEXT MINING

Fokus Tetap pada Masalah Teks

Untuk project berbasis teks:

- Pertahankan target dan tujuan;
- Lanjutkan preprocessing teks;
- Bentuk representasi fitur;
- Gunakan baseline;
- Coba kandidat model yang relevan;
- Evaluasi hasil.

Contoh alur: **Teks → Preprocessing → Representasi fitur → Baseline →Kandidat model → Evaluasi → Perbandingan**

Project Checkpoint - Pertemuan 4

6. Perbandingan

Model	Metrik 1	Metrik 2	Metrik 3
Baseline	...	...	...
Kandidat 1	...	...	...
Kandidat 2	...	...	...

7. Temuan Awal

Tuliskan **3–5 poin**:

- model mana yang memberikan hasil berbeda;
- metrik mana yang paling informatif;
- masalah apa yang ditemukan;
- apa yang perlu diperbaiki.

Project Checkpoint - Pertemuan 4

Setiap kelompok memperbarui **Notebook Project**.

Minimal berisi:

1. Dataset

- dataset yang digunakan;
- jumlah data;
- fitur;
- target.

2. Preprocessing

- langkah yang dilakukan;
- alasan penggunaannya.

3. Baseline

- model;
- hasil evaluasi.

4. Kandidat Model

- model tambahan;
- alasan pemilihan.

5. Evaluasi

- metrik yang digunakan;
- hasil setiap model.

TARGET AKHIR PERTEMUAN 4

Setelah Pertemuan 4

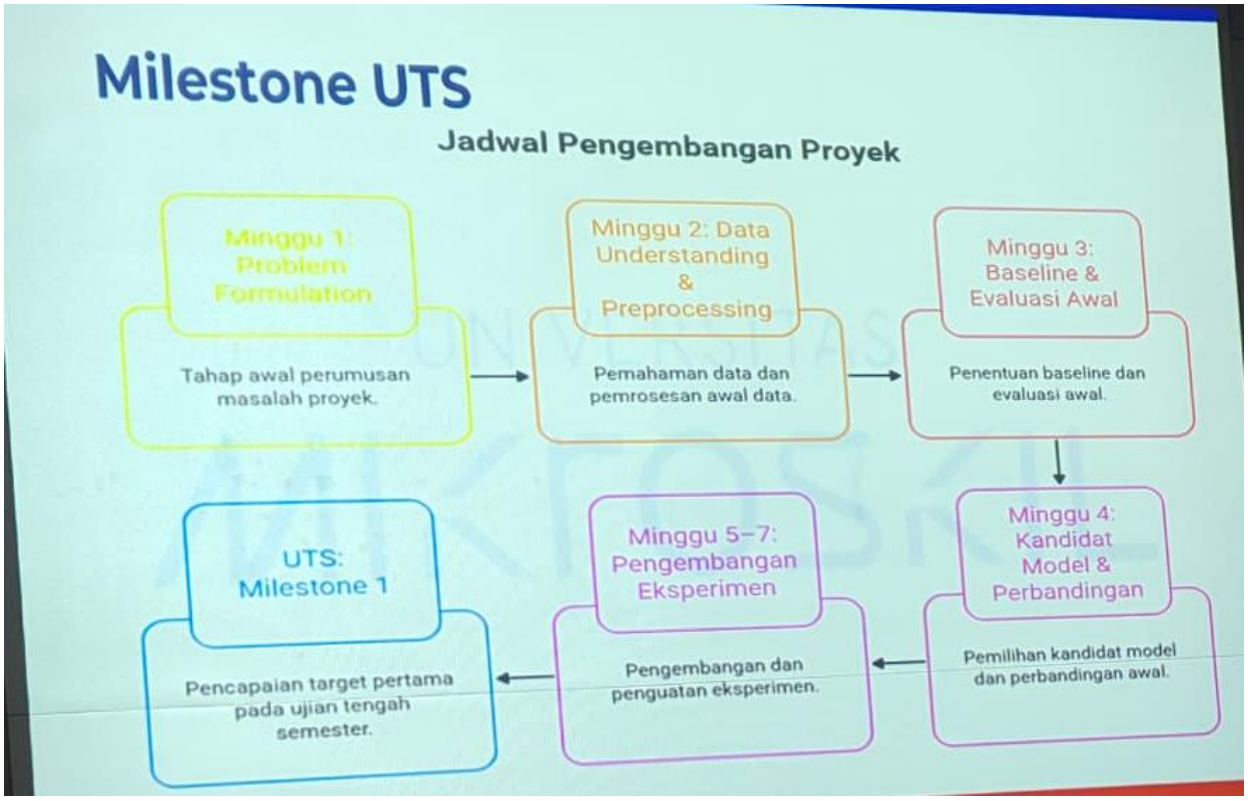
Setiap kelompok harus sudah dapat menunjukkan:

- ✓ **"Ini masalah kami."**
- ✓ **"Ini data kami."**
- ✓ **"Ini baseline kami."**
- ✓ **"Ini kandidat model kami."**
- ✓ **"Ini hasil evaluasi masing-masing."**
- ✓ **"Ini perbedaan performanya."**
- ✓ **"Ini temuan awal kami."**

Belum perlu menjawab:

"Model final kami adalah ..."

Karena model final baru dapat dipertanggungjawabkan setelah melalui validasi, error analysis, tuning, perbandingan model, dan proses seleksi. Struktur final project memang menempatkan tahapan tersebut setelah fondasi awal terbentuk.


Milestone UTS
Jadwal Pengembangan Proyek
Minggu 1: Problem Formulation
Tahap awal perumusan masalah proyek.
Minggu 2: Data Understanding & Preprocessing
Pemahaman data dan pemrosesan awal data.
Minggu 3: Baseline & Evaluasi Awal
Penentuan baseline dan evaluasi awal.
Minggu 4: Kandidat Model & Perbandingan
Pemilihan kandidat model dan perbandingan awal.
Minggu 5–7: Pengembangan Eksperimen
Pengembangan dan penguatan eksperimen.
UTS: Milestone 1
Pencapaian target pertama pada ujian tengah semester.

MINGGU 5

Perangkat audio dialihkan ke Senary Audio

PROJECT MILESTONE: PERTEMUAN 5

Dari Perbandingan Model Menuju Validasi

Pada Pertemuan 5, kelompok harus mulai menjawab tiga pertanyaan:

- Apakah performa model stabil ketika pembagian data berubah?
- Apakah ensemble learning dapat meningkatkan performa dibandingkan model awal?
- Apakah distribusi kelas memengaruhi hasil evaluasi? Jika project tidak menggunakan klasifikasi, fokuskan pada dua pertanyaan pertama yang relevan.

Alur project:

Baseline → Kandidat Model → Validasi → Ensemble (jika relevan) → Diagnosis Awal

TUGAS 1: AUDIT STRATEGI VALIDASI

Periksa Cara Model Dievaluasi

Setiap kelompok harus mendokumentasikan bagaimana data digunakan dalam eksperimen.

Periksa:

- Bagaimana data dibagi menjadi training dan testing?
- Apakah validation set diperlukan untuk tuning?
- Apakah pembagian data sesuai dengan jenis masalah?
- Apakah preprocessing dipelajari hanya dari data training?
- Apakah data test sudah digunakan berulang kali untuk memilih model?

Jika menggunakan hold-out

- Jelaskan fungsi masing-masing:
  - Training set: melatih model.
  - Validation set: memilih konfigurasi dan membandingkan kandidat model.
  - Test set: mengevaluasi model terpilih pada tahap akhir.
- Jika menggunakan Cross-Validation
  - Terapkan metode yang sesuai, misalnya 5-Fold Cross-Validation atau Stratified 5-Fold untuk klasifikasi dengan distribusi kelas yang perlu dijaga.

Output: diagram pembagian data dan alasan pemilihan strategi validasi.

TUGAS 2: UJI KESTABILAN MODEL

Apakah Hasil Model Konsisten?

Satu skor dari satu kali pembagian data belum tentu menggambarkan performa model secara stabil.

Kelompok diminta:

1. Menjalankan validasi yang sesuai.
2. Mencatat skor pada setiap fold jika menggunakan Cross-Validation.
3. Menghitung rata-rata skor.
4. Mengamati variasi skor antarfold.
5. Menjelaskan apakah performa model relatif stabil atau berubah cukup besar.

Contoh tabel hasil:

Fold	Skor evaluasi
Fold 1	...
Fold 2	...
Fold 3	...
Fold 4	...
Fold 5	...
Rata-rata	...
Standar deviasi	...

Gunakan metrik yang sesuai dengan project. Untuk regression, misalnya MAE atau RMSE; untuk classification, misalnya F1-score atau Recall jika relevan.

Output: tabel hasil validasi dan interpretasi kestabilan model.

TUGAS 3: ENSEMBLE LEARNING

Apakah Menggabungkan Model Memberikan Manfaat?

- Ensemble Learning menggabungkan prediksi beberapa model untuk memperoleh hasil yang berpotensi lebih baik atau lebih stabil.
- Kelompok memeriksa apakah ensemble sesuai dengan project dan dapat dibandingkan secara adil dengan baseline.

Contoh kandidat:

- Random Forest: ensemble berbasis banyak Decision Tree.
- Gradient Boosting: membangun model secara bertahap untuk memperbaiki kesalahan sebelumnya.
- XGBoost/LightGBM: kandidat lanjutan jika sesuai dengan ukuran data, lingkungan, dan kebutuhan eksperimen.

TUGAS 4: PERIKSA IMBALANCED DATA

Khusus Project Classification

Ketidakseimbangan kelas terjadi ketika jumlah contoh pada suatu kelas jauh lebih banyak daripada kelas lainnya.

Contoh: dari 1.000 transaksi, hanya 10 transaksi merupakan fraud. Model yang selalu memprediksi "**bukan fraud**" dapat memperoleh accuracy 99%, tetapi gagal mendeteksi seluruh fraud.

Yang harus dilakukan

1. Tampilkan jumlah dan persentase setiap kelas pada target.
2. Identifikasi apakah terdapat ketidakseimbangan yang bermakna.
3. Periksa confusion matrix dan metrik yang relevan.
4. Jika diperlukan, pilih satu strategi penanganan untuk diuji.

Output: distribusi kelas, metrik yang relevan, dan keputusan apakah penanganan imbalance diperlukan.

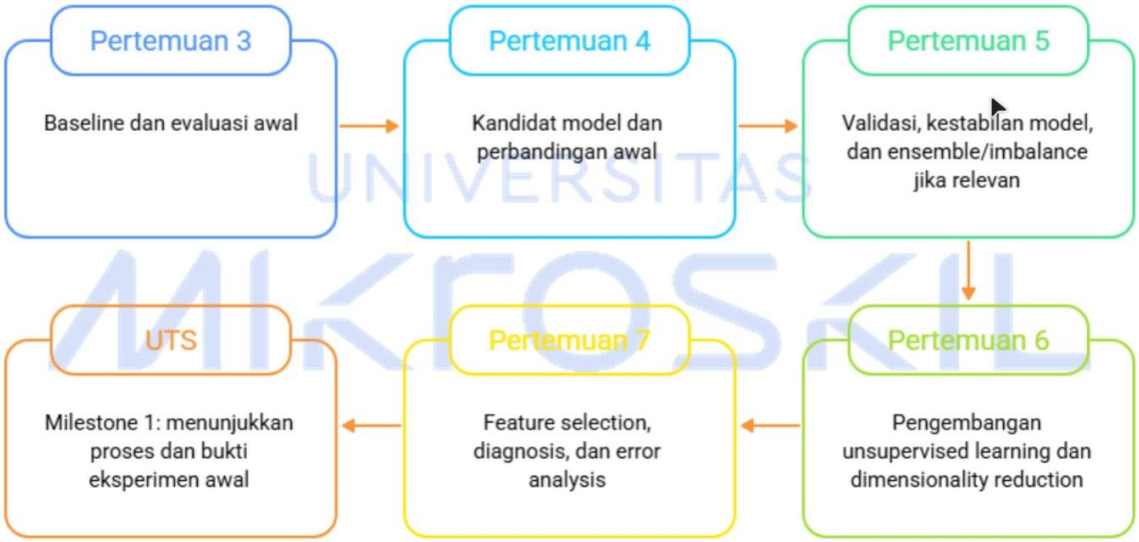
- Pertahankan baseline yang sudah ada.
- Pilih satu model ensemble yang relevan.
- Evaluasi baseline dan ensemble menggunakan strategi validasi yang sama.
- Bandingkan metrik yang sama.
- Jelaskan perbedaan hasil dan biaya komputasi jika relevan.

Output: satu perbandingan baseline versus ensemble, disertai alasan pemilihan model.

OUTPUT YANG WAJIB DIKUMPULKAN

- ❑Strategi validasi dan alasan pemilihannya
- ❑Hasil validasi atau Cross-Validation
- ❑Tabel perbandingan baseline dan kandidat model
- ❑Eksperimen ensemble jika relevan
- ❑Distribusi kelas dan analisis imbalance untuk classification
- ❑Interpretasi hasil dan keterbatasan eksperimen
- ❑Rencana eksperimen untuk Pertemuan 6-7

Tahapan Target Project



CHECKPOINT PERTEMUAN 5

Kelompok dinyatakan memenuhi checkpoint jika dapat menjelaskan:

- ✓ Validasi: bagaimana model diuji dan mengapa strategi tersebut dipilih?
- ✓ Kestabilan: apakah hasil evaluasi konsisten antar-fold atau pembagian data?
- ✓ Perbandingan: apakah kandidat baru memberi manfaat dibanding baseline?
- ✓ Imbalance: jika classification, apakah distribusi kelas memengaruhi evaluasi?
- ✓ Keputusan: apa yang akan diperbaiki dan apa bukti yang mendasari keputusan tersebut?

Minggu 6

Tindak Lanjut Proyek IF2116 – Pertemuan 6

- Setiap kelompok wajib melanjutkan proyek dengan Project ID, dataset, dan tujuan yang telah disetujui.
- Identifikasi apakah materi clustering atau PCA relevan dengan proyek kelompok.
- Jika proyek menggunakan **clustering**, dokumentasikan fitur yang digunakan, **preprocessing dan scaling, baseline clustering, pengujian parameter atau jumlah cluster, hasil evaluasi, serta profil dan interpretasi cluster**.
- Jika proyek menggunakan **PCA**, jelaskan alasan penggunaannya dan bandingkan hasil dengan pendekatan tanpa PCA menggunakan prosedur evaluasi yang sesuai.
- Jika materi ini tidak relevan secara langsung, jelaskan secara singkat alasan metodologisnya dan lanjutkan eksperimen yang sesuai dengan jenis proyek.
- Simpan kode, output, tabel hasil, dan penjelasan singkat di notebook. Perbarui laporan proyek berdasarkan hasil yang benar-benar diperoleh.
- **Jangan mengklaim** bahwa suatu metode lebih baik hanya berdasarkan visualisasi atau satu metrik. Sertakan bukti dan keterbatasan hasil.
- Luaran yang diharapkan adalah notebook eksperimen yang dapat diperiksa, tabel perbandingan hasil awal, dan ringkasan temuan yang menjelaskan keputusan metodologis kelompok.

PROYEK CLUSTERING

- ❑ Khususnya kelompok yang memang memiliki tujuan pengelompokan tanpa label.
- ❑ Menjelaskan mengapa masalah membutuhkan clustering dan fitur apa yang digunakan.
- ❑ Memeriksa kualitas data dan menerapkan scaling jika sesuai.
- ❑ Menjalankan baseline clustering, misalnya K-Means.
- ❑ Menguji beberapa nilai K dan menggunakan Elbow atau Silhouette sebagai bukti awal.
- ❑ Membandingkan algoritma alternatif bila bentuk cluster atau noise menunjukkan K-Means kurang sesuai.
- ❑ Membuat tabel ukuran dan profil cluster, kemudian menafsirkan hasilnya.
- ❑ Mencatat parameter, random seed, metrik, dan keterbatasan eksperimen.

PCA

- ❑ Menentukan alasan PCA diperlukan, bukan menerapkannya secara otomatis.
- ❑ Membandingkan jumlah fitur awal dengan jumlah komponen yang dipertahankan.
- ❑ Membaca explained variance ratio dan varians kumulatif.
- ❑ Menguji hasil dengan dan tanpa PCA menggunakan evaluasi yang sesuai.
- ❑ Menempatkan scaling dan PCA di dalam Pipeline untuk mencegah data leakage.
- ❑ Menjelaskan trade-off antara pengurangan dimensi dan kehilangan interpretabilitas.